

Hybride Optionsbewertung: Physics-Informed Neural Networks mit Black-Scholes-Regularisierung

Modulverantwortliche Professorin & modulverantwortlicher Professor
Prof. Dr. Tea Riedel & Prof. Dr. Christian Prinz

Modul:
Master Thesis

Studiengang:
Data Science & Analytics M.Sc.

Verfasser:
Alexander Ritsch, 2009057

Abstract

Die klassische Optionsbewertung nach Black-Scholes stößt aufgrund restriktiver Annahmen empirisch an ihre Grenzen, während rein datengetriebene Deep-Learning-Modelle oft unter mangelnder Generalisierbarkeit und fehlender theoretischer Fundierung leiden. Diese Arbeit begegnet dieser Lücke durch die Entwicklung und Evaluierung eines hybriden Ansatzes zur Bewertung europäischer Optionen: Physics-Informed Neural Networks (PINNs) mit Black-Scholes-Regularisierung.

Das Modell integriert die partielle Differenzialgleichung (PDE) von Black-Scholes als Regularisierungsterm in die Verlustfunktion eines neuronalen Netzes. Trainiert und getestet wird der Ansatz auf einem umfangreichen Datensatz von S&P 500 Index-Optionen aus dem Zeitraum 2019 bis 2024, wobei die Leistung separat für Call- und Put-Optionen analysiert wird.

Die Ergebnisse zeigen eine signifikante Überlegenheit des PINN-Ansatzes gegenüber dem klassischen Black-Scholes-Modell. Die hybriden Modelle reduzieren die Bewertungsfehler um mehrere Größenordnungen und eliminieren systematische Verzerrungen wie den *Volatility Smile*. Insbesondere in datenarmen Regionen des Optionsraums sorgt die Regularisierung für robuste und stabile Preisvorhersagen, wo das klassische Modell versagt. Die Arbeit demonstriert erfolgreich, dass die Fusion von finanzmathematischer Theorie und datengetriebener Flexibilität zu leistungsfähigeren, robusteren und realitätsnäheren Bewertungsmodellen für Finanzderivate führt.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	2
1.2	Zielsetzung der Arbeit	3
1.3	Aufbau der Arbeit	5
2	Theoretische Grundlagen	6
2.1	Klassische Modelle der Optionsbewertung	6
2.1.1	Einführung in die Optionsbewertung	6
2.1.2	Black-Scholes-Modell: Annahmen, Herleitung und Lösung	7
2.1.3	Preisformeln nach Black-Scholes	9
2.1.4	Grenzen und empirische Schwächen des Black-Scholes-Modells	10
2.2	Deep Learning in der Finanzökonomie	12
2.2.1	Grundlagen künstlicher neuronale Netze	12
2.2.2	Training mittels Backpropagation und Gradient Descent	15
2.2.3	Gradienteninstabilität in neuronalen Netzen	18
2.2.4	Anwendungen im Bereich der Optionsbewertung	19
2.3	Physics-Informed Neural Networks (PINNs)	21
2.3.1	Konzept und Motivation	21
2.3.2	Formale Herleitung und Architektur	22
2.3.3	Automatisches Differenzieren und Modellvarianten	24
2.3.4	PINNs im Finanzkontext: Stand der Forschung	25
3	Methodik	27
3.1	Datengrundlage und Data-Preprocessing	28
3.1.1	Beschreibung des Datensatzes	28
3.1.2	Datenbereinigung und Feature Engineering	28
3.1.3	Quantitative Beschreibung des Datensatzes	30
3.2	Explorative Datenanalyse	31
3.2.1	Univariate Datenanalyse	31
3.2.2	Zeitreihenanalyse	34
3.2.3	Bivariate Datenanalyse	36
3.3	Modellarchitektur des PINNs	38
3.3.1	Struktur des neuronalen Netzes	39
3.3.2	Gestaltung der Black-Scholes-informierten Verlustfunktion	42
3.3.3	Sampling der Rand-, End- und Kollokationspunkte	43

3.4	Training und Hyperparameter	47
3.4.1	Trainingsprozess und Batch-Strukturierung	47
3.4.2	Verlustfunktion und dynamische PDE-Gewichtung	48
3.4.3	Analyse der zentralen Hyperparameter	49
4	Ergebnisse	51
4.1	Trainings- und Testergebnisse	51
4.2	Einfluss der Black-Scholes-Regularisierung	57
4.3	Vergleich der Modelle mit dem klassischen Black-Scholes-Modell	60
4.4	Unterscheidung der Prognosegüte zwischen Call- und Put-Optionen	63
5	Diskussion	67
5.1	Zusammenfassung der zentralen Ergebnisse	67
5.2	Vorteile und Limitationen des Ansatzes	68
5.3	Implikationen der Arbeit für Theorie und Praxis	70
5.4	Fazit	70

Abbildungsverzeichnis

1	Schematische Darstellung eines Feedforward Neural Network (FNN) mit mehreren versteckten Schichten zur Abbildung eines Eingabevektors auf einen skalaren Output.	13
2	Darstellung eines einzelnen Neurons mit gewichteten Eingaben, Bias-Term und nicht-linearer Aktivierungsfunktion $\phi(a)$	15
3	Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.	32
4	Boxplots der Verteilung von Optionspreis V_{market} , impliziter Volatilität σ_{imp} und Moneyness (S/K)	33
5	Verlauf des S&P 500-Index (oben) und der durchschnittlichen impliziten Volatilität (unten) von 2019 bis Ende 2024. Der schattierte Bereich markiert den COVID-19-Crash Anfang 2020, in dem ein starker Kurseinbruch und ein sprunghafter Anstieg der Volatilität zu beobachten sind.	34
6	Zeitreihe der Veränderungen der impliziten Volatilität σ_{imp} von 2019 bis Ende 2024. Die Darstellung zeigt kurzfristige Schwankungen und Volatilitätsspitzen.	35
7	Korrelationsmatrix der Optionsvariablen. Dargestellt sind die linearen Zusammenhänge zwischen Optionspreis, Moneyness, Restlaufzeit, impliziter Volatilität, Basispreis, Ausübungspreis, risikofreiem Zinssatz, Dividende und Optionsvolumen. Starke positive und negative Korrelationen heben Beziehungen zwischen Preisparametern und Marktfaktoren hervor.	36
8	Zusammenhang zwischen Optionspreis V_{market} und zentralen Einflussgrößen für Call- (blau) und Put-Optionen (rot). Gezeigt sind die Beziehungen zu Moneyness (links), Restlaufzeit t (Mitte) und impliziter Volatilität σ_{imp} (rechts). Die logarithmische Skalierung verdeutlicht die Preisunterschiede über mehrere Größenordnungen hinweg.	37
9	Architektur des PINNs bestehend aus sechs verborgenen Schichten à 148 Neuronen und Tanh-Aktivierung. Die Ausgabe wird aufgeteilt und über Softplus zu $\hat{V}$ und $\hat{\sigma}$ transformiert.	41
10	Verteilung der Kollokationspunkte des Modells PINN Call mit Häufigkeit und Streuung um den ATM Bereich. Zur besseren Übersicht des Streudiagramms wurden 10.000 Punkte zufällig ausgewählt.	45
11	Verteilung der Kollokationspunkte des Modells PINN Put mit Häufigkeit und Streuung um den ATM Bereich. Zur besseren Übersicht des Streudiagramms wurden 10.000 Punkte zufällig ausgewählt.	45
12	Darstellung der Rand- und Endbedingungen für Call-Optionen. Links ist der Payoff zum Zeitpunkt $T = 25$ in Abhängigkeit der Moneyness (S/K) gezeigt, rechts die Randbedingung für $S = 0$ und $S \rightarrow \infty$. Zur besseren Übersicht wurden jeweils nur 2.500 Punkte zufällig ausgewählt.	46

13	Darstellung der Rand- und Endbedingungen für Put-Optionen. Links ist der Payoff zum Zeitpunkt $T = 25$ in Abhängigkeit der Moneyness (S/K) gezeigt, rechts die Randbedingung für $S = 0$ und $S \rightarrow \infty$. Zur besseren Übersicht wurden jeweils nur 2.500 Punkte zufällig ausgewählt.	46
14	Verlauf der Verluste $\mathcal{L}_{data}$, $\mathcal{L}_{pde}$ und $\lambda_{pde}\mathcal{L}_{pde}$ des Modells PINN Call über die Trainingsepochen.	51
15	Verlauf der Verluste $\mathcal{L}_{market}$, $\mathcal{L}_{tc}$ und $\mathcal{L}_{bc}$ des Modells PINN Call über die Trainingsepochen.	52
16	Verlauf der Gradientenverhältnisse und -normen von PDE- und Datenverlust über die Trainingsepochen für das Modell PINN Call.	52
17	Verlauf von MSE, MAE und Lernrate über die Trainingsepochen für das Modell PINN Call.	53
18	Verlauf von mittlerer, maximaler und minimaler Volatilität $\hat{\sigma}$ über die Trainingsepochen für das Modell PINN Call.	53
19	Verlauf der Verluste $\mathcal{L}_{data}$, $\mathcal{L}_{pde}$ und $\lambda_{pde}\mathcal{L}_{pde}$ des Modells PINN Put über die Trainingsepochen.	54
20	Verlauf der Verluste $\mathcal{L}_{market}$, $\mathcal{L}_{tc}$ und $\mathcal{L}_{bc}$ des Modells PINN Put über die Trainingsepochen.	54
21	Verlauf der Gradientenverhältnisse und -normen von PDE- und Datenverlust über die Trainingsepochen für das Modell PINN Put.	55
22	Verlauf von mittlerer, maximaler und minimaler Volatilität $\hat{\sigma}$ über die Trainingsepochen für das Modell PINN Put.	55
23	Verlauf von MSE, MAE und Lernrate über die Trainingsepochen für das Modell PINN Put.	56
24	Vergleich der Volatilitäts- und Optionspreisflächen des Modells PINN Call .	57
25	Gegenüberstellung der Modell-basierten Optionspreise $\hat{V}$ und empirischen Optionspreisen V_{market} für europäische Call-Optionen	58
26	Vergleich der Volatilitäts- und Optionspreisflächen des Modells PINN Put .	59
27	Gegenüberstellung der Modell-basierten Optionspreise $\hat{V}$ und empirischen Optionspreisen V_{market} für europäische Put-Optionen	60
28	Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.	61
29	Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.	62
30	Volatilitätsoberflächen verschiedener Markt Regime des Modells PINN Call im Vergleich zur impliziten Volatilität σ_{imp}	64
31	Volatilitätsoberflächen verschiedener Markt Regime des Modells PINN Put im Vergleich zur impliziten Volatilität σ_{imp}	66

Tabellenverzeichnis

1	Übersicht der im Datensatz enthaltenen Variablen für S&P 500 Optionen . . .	28
2	Deskriptive Statistik des bereinigten S&P 500 Optionsdatensatzes (Zeitraum: 2019-2024)	31
3	Konfiguration der Hyperparameter für die Modelle PINN Call und PINN Put	50
4	Vergleich der Prognosegüte zwischen PINN Call und Black-Scholes Call für Forschungsfrage (FQ1)	58
5	Vergleich der Prognosegüte zwischen PINN Put und Black-Scholes Put für Forschungsfrage (FQ1)	59
6	Vergleich der Modellgüte zwischen PINN Call und Black-Scholes Call	61
7	Vergleich der Modellgüte zwischen PINN Put und Black-Scholes Put	61

1. Einleitung

Die Bewertung von Finanzderivaten, primär von börsengehandelten Optionen, ist ein zentrales Thema der Finanzökonomie und der Finanzmathematik. Insbesondere die Arbeit von Black und Scholes (1973) sowie Merton (1976), die eine analytische Lösung für europäische Optionen entwickelten, führte zu einem Paradigmawechsel von risikobasierter Preismodelle, die auf einem Gleichgewichtsdenken basierten, wie dem *Capital Asset Pricing Model* (CAPM), hin zu arbitragebasierte Preismodelle (Heiner & Arend, 2008). Das Modell von Black und Scholes basiert auf der Annahme eines dynamischen, risikoneutralen Hedging-Ansatzes sowie der Voraussetzung arbitragefreier Märkte. Es handelt sich hierbei um ein klassisches Beispiel eines parametrischen Pricing-Modells, das explizit auf Annahme über die stochastische Dynamik des Basiswerts, speziell die konstante Volatilität und die logarithmische Normalverteilung der Renditen, angewiesen ist.

Obwohl das Black-Scholes-Modell aufgrund seiner theoretischen Konsistenz und praktischen Implementierbarkeit breite Akzeptanz in Wissenschaft und Praxis erlangte, zeigten bereits früh empirische Beobachtungen systematische Abweichungen zwischen Modellpreis und tatsächlichen Marktpreisen (Rubenstein, 1994; Jackwerth, 1996). Insbesondere Erscheinungen wie *Volatility Smiles* und *Volatility Skews* deuten auf grundlegende Inkonsistenzen zwischen den Annahmen des Modells und den tatsächlichen Eigenschaften der Finanzmärkte hin. Eine unzureichende Modellierung der zugrundeliegenden stochastischen Prozesse führt dabei regelmäßig zu strukturellen Bewertungsfehlern.

Um diese Limitationen zu überwinden, wurden in den letzten Jahrzehnten datengetriebene, nicht-parametrische Methoden wie neuronale Netze zunehmend als Alternative zu den klassischen Modellansätzen untersucht. Erste empirische Studien, etwa von Hutchinson et al. (1994) belegten, dass neuronale Netze in der Lage sind, komplexe Zusammenhänge zwischen Optionspreisen und Marktcharakteristika zu erfassen und klassische Modelle wie Black-Scholes auf Basis simulierter Daten nachzulernen. Folgestudien (Amilon, 2003; Bennell & Sutcliffe, 2004) bestätigen, dass neuronale Netze speziell bei der Optionsbewertung in realen Marktumfeldern eine hohe Pricing- und Hedging-Genauigkeit erreichen können.

Neuere Untersuchungen verdeutlichen zudem das wachsende Potenzial moderner Deep-Learning-Modelle: Liu et al. (2019) zeigen, dass künstliche neuronale Netze als effiziente approximative Lösungen für komplexe Bewertungsprobleme von Optionen eingesetzt werden können und dabei eine signifikante Reduktion der Rechenzeit ermöglichen. Ke & Yang (2019) demonstrieren darüber hinaus, dass Deep-Learning-Modelle die Vorhersage klassischer Modelle bei der Optionspreisbestimmung deutlich übertreffen.

Gleichwohl offenbaren weitere Untersuchungen auch Schwächen datengetriebener Ansätze: So hängt die Leistungsfähigkeit neuronaler Netzwerke häufig von der Marktvolatilität, der Datenverfügbarkeit und der Struktur des Trainingsdatensatzes ab (Malliaris & Salchenberger, 1993; Hanke, 1999; Yao et al., 2000). Jüngste Studien, wie die von Glende (2024), bestätigen diese Beobachtungen: seine Analyse der Direction-of-Change-Prognose bei Aktienkursen zeigt, dass datengetriebene Modelle, etwa neuronale Netze oder Random Forests,

insbesondere in Phasen hoher Volatilität sowie bei strukturellen Brüchen im Datensatz an Prognosegenauigkeit verlieren. Darüber hinaus mangelt es rein datenbasierten Modellen oftmals an ökonomischer Interpretierbarkeit sowie an struktureller Konsistenz, die bei klassisch modellbasierten Ansätzen von Natur aus gegeben ist. Auch Glende hebt hervor, dass neuronale Netze zwar eine hohe Flexibilität aufweisen, jedoch aufgrund ihrer geringen Transparenz bei der Ableitung ökonomischer Hypothesen und Entscheidungen deutliche Nachteile gegenüber ökonomischen fundierten Modellen aufzeigen.

Vor diesem Hintergrund entwickelt sich das Forschungsfeld der *Physics-Informed Neural Networks* (PINNs), die versuchen, domänenspezifisches Wissen, etwa die Black-Scholes-partielle Differenzialgleichung (Black-Scholes-PDE), als Regularisierer in das Training neuronaler Netze zu integrieren. Durch diese hybride Modellierung können potenziell die Vorteile beider Welten, die Flexibilität datengetriebener Ansätze und die Struktur klassischer Modelle, kombiniert werden. Erste Anwendungen im Finanzbereich belegen, dass PINNs in der Lage sind, sowohl die Genauigkeit der Optionsbewertung als auch die Interpretierbarkeit der Modelle zu verbessern (Sirignano & Spiliopoulos, 2018; Raissi et al., 2019). Noguer I Alonso & Antolin Camaerna (2023) demonstrieren anhand von Anwendungen auf das Black-Scholes- und Heston-Modell, dass PINNs in der Lage sind, analytische Lösungen präzise zu approximieren und zugleich ökonomische Modellannahmen systematisch zu berücksichtigen. Damit leisten PINNs einen wichtigen Beitrag zur Überwindung der traditionellen Trennung zwischen datengetriebenen Verfahren und theoriegeleiteten Modellansätzen in der Finanzmathematik.

1.1. Problemstellung

Der Problembereich dieser Arbeit liegt in der Bewertung europäischer Optionen unter Nutzung moderner Deep-Learning-Ansätzen, wobei das klassische Wissen der Finanzmathematik, insbesondere die Black-Scholes-PDE, systematisch in das Training neuronaler Netze integriert werden soll.

Trotz der weiten Verbreitung und der theoretischen Kohärenz des Black-Scholes-Modells zeigen empirische Beobachtungen signifikante Diskrepanzen, zwischen den theoretisch berechneten und den am Markt beobachteten Optionspreisen. Diese Abweichungen resultieren vorwiegend aus restriktiven Modellannahmen, wie etwa konstanter Volatilität und idealisierter Marktbedingungen, die in der Realität häufig nicht erfüllt sind. Klassische Modelle geraten dadurch in dynamischen Marktphasen oder bei strukturellen Brüchen an ihre Grenzen.

Parallel dazu bieten datengetriebene Ansätze wie Deep Learning eine hohe Flexibilität und Lernfähigkeit, um komplexe nicht-lineare Zusammenhänge in Marktpreisen zu erfassen. Jedoch leiden diese Modelle häufig an einem Mangel an ökonomischer Interpretierbarkeit, mangelnder Generalisierbarkeit und Überanpassung an historische Daten, speziell bei begrenzten oder volatilen Datensätzen.

Das zentrale Problem besteht somit darin, dass weder klassische parametrische Modelle noch rein datengetriebene Ansätze alleine eine zufriedenstellende Lösung für die präzise, robuste und ökonomisch interpretierbare Bewertung von Optionen bieten. Die Herausforderung besteht daher darin, beide Ansätze zu kombinieren: Das etablierte Wissen der Finanztheorie soll als strukturelle Regularisierung in moderne Deep-Learning-Modelle eingebunden werden, um die Stärken beider Welten zu vereinen und die Schwächen zu kompensieren.

Primär soll sich der Frage gestellt werden, wie neuronale Netze durch eine Black-Scholes-informierte Verlustfunktion („Black-Scholes-informed Loss“) dazu befähigt werden können, Optionspreise sowohl präzise vorherzusagen als auch finanzmathematische Prinzipien systematisch zu respektieren. Hier setzt die Arbeit an.

1.2. Zielsetzung der Arbeit

Ziel dieser Arbeit ist die Entwicklung, Implementierung und Evaluierung eines hybriden Deep-Learning-Ansatzes zur Bewertung europäischer Optionen, der die Black-Scholes-PDE in das Training neuronaler Netze integriert. Hierzu werden zwei Modelle auf Basis von PyTorch implementiert, das eine kombinierte Verlustfunktion verwendet: Diese setzt sich aus einem datengetriebenen Fehlerterm (basierend auf beobachteten Marktpreisen) sowie einem Regularisierungsterm (basierend auf der partiellen Differenzialgleichung des Black-Scholes-Modells inkl. Randbedingungen) zusammen.

Die Modelle werden auf historischen Marktdaten für S&P 500 Index-Optionen im Zeitraum von 2019 bis 2024 trainiert. Der Datensatz umfasst sowohl Call- als auch Put-Optionen und enthält die jeweilige implizite Volatilität sowie vergangene US-Staatsanleihen-Renditen zur Abbildung des risikofreien Zinssatzes. Zur differenzierten Untersuchung wird das neuronale Netz in drei Trainingsvarianten evaluiert:

1. ausschließlich auf Put-Optionen;
2. ausschließlich auf Call-Optionen.

Zur Sicherstellung einer homogenen Trainingsbasis werden ausschließlich Optionen berücksichtigt, deren Moneyness in einem vordefinierten Bereich liegt. Optionen mit extremen Preisrelationen oder geringer Liquidität werden im Rahmen eines strukturierten Preprocessings entfernt.

Die Leistung der entwickelten Modelle wird anhand folgender Metriken evaluiert:

- Mean Squared Error (MSE),
- Root Mean Squared Error (RMSE),
- Mean Absolute Error (MAE).

Als Vergleich dient das klassische Black-Scholes-Modell bzw. dessen analytische Lösung, wobei auf Basis der im Datensatz enthaltenen impliziten Volatilitäten theoretische Optionspreise berechnet werden.

Ein weiterer Fokus der Arbeit liegt auf der Analyse, wie sich die Black-Scholes-basierte Regularisierung auf die Stabilität und Generalisierungsfähigkeit der Modelle auswirkt, insbesondere in Bereichen des Optionsraums, die trotz Filterung weiterhin durch relativ geringere Datendichte charakterisiert sind (etwa bei sehr kurzen Laufzeiten oder Randbereichen der definierten Moneyness-Spanne). Darüber hinaus wird untersucht, inwieweit der Widerspruch zwischen der Annahme konstanter Volatilität des Black-Scholes-Modells und den empirisch beobachtbaren Volatilitätsstrukturen (*Volatility Smile* und *Volatility Skew*) die Lern- und Generalisierungsfähigkeit der Modelle beeinflusst.

Zur systematischen Beantwortung dieser Fragestellung werden im Rahmen der Arbeit folgende zentrale Forschungsfragen und Hypothesen untersucht:

- Forschungsfrage (FQ1): Welche Wirkung hat die Black-Scholes-informierte Regularisierung auf die Generalisierungsfähigkeit der Modelle in datenarmen Regionen innerhalb des zugelassenen Optionsraums (Restlaufzeit: 1-90 Tage, Moneyness: $[0,5;1,5]$)?

Hypothese (H1): Beide Modelle erzielen auch in datenarmen Bereichen des gefilterten Optionsraums stabilere und robuste Vorhersagen als das klassische Black-Scholes-Modell, bedingt durch die Regularisierung mittels Black-Scholes-PDE.

- Forschungsfrage (FQ2): Wie genau kann ein auf realen Marktpreisen trainiertes PINN Modell europäische Optionen im Vergleich zum Black-Scholes-Modell bewerten?

Hypothese (H2): Beide Modelle erzielen über den gesamten Testdatensatz hinweg signifikante geringere mittlere Fehlermaße (MSE, MAE, RMSE) als das Black-Scholes-Modell mit impliziter Volatilität.

- Explorative Forschungsfrage (FQ3): Unterscheidet sich die Modelleistung von PINNs zwischen Call- und Put-Optionen?

Hypothese (H3): Das Modell zeigt geringere Prognosegüte bei Put-Optionen, insbesondere in rückläufigen Märkten, was auf asymmetrische Liquiditätsverteilungen und Volatilitätsverzerrungen zurückzuführen ist.

1.3. Aufbau der Arbeit

Die vorliegende Arbeit ist in fünf Kapitel untergliedert:

Kapitel 1 führt in das Thema ein, stellt die Motivation und Relevanz der Fragestellung dar, formuliert die Problemstellung und leitet daraus die Zielsetzung sowie die zentrale Forschungsfrage ab.

Kapitel 2 widmet sich den theoretischen Grundlagen. Es werden zunächst klassische Ansätze der Optionsbewertung, insbesondere das Black-Scholes-Modell, vorgestellt und kritisch hinsichtlich ihrer praktischen Anwendbarkeit reflektiert. Im Anschluss erfolgt eine Einführung in die Methodik des maschinellen Lernens sowie eine detaillierte Darstellung von PINNs im Kontext der Finanzmathematik.

Kapitel 3 beschreibt die methodische Umsetzung der Arbeit. Neben der Entwicklung der Modellarchitektur werden die verwendete Datengrundlage, der Preprocessing-Prozess sowie die Trainingskonfiguration der Modelle ausführlich erläutert.

Kapitel 4 enthält die empirische Analyse. Es werden die Ergebnisse der entwickelten Modelle präsentiert, mit einer analytischen Lösung nach Black-Scholes verglichen sowie weitere Analysen durchgeführt. Die Resultate werden abschließend im Hinblick auf ihre theoretische und praktische Bedeutung diskutiert.

Kapitel 5 schließt die Arbeit mit einer Zusammenfassung der zentralen Erkenntnisse, einer kritischen Reflexion der Limitationen sowie einem Ausblick auf mögliche zukünftige Forschungsrichtungen ab.

2. Theoretische Grundlagen

2.1. Klassische Modelle der Optionsbewertung

Dieses Kapitel widmet sich den klassischen Modellen der Optionsbewertung, die die Grundlage für das Verständnis moderner, komplexer Ansätze bilden. Insbesondere wird das Black-Scholes-Modell, als das prominenteste Modell, detailliert vorgestellt und seine mathematischen Grundlagen sowie Implikationen erläutert. Abschließend werden die inhärenten Limitationen des Black-Scholes-Modells diskutiert, um die Notwendigkeit und Motivation für die Entwicklung hybrider Bewertungsansätze, wie sie im Rahmen dieser Arbeit erforscht werden, aufzuzeigen.

2.1.1. Einführung in die Optionsbewertung

Eine Option ist ein Finanzkontrakt, der dem Käufer das Recht, aber nicht die Pflicht einräumt, einen bestimmten Basiswert (z.B. eine Aktie) zu einem festgelegten Preis (Ausübungspreis oder Strike-Preis K) zu kaufen (Call-Option) oder zu verkaufen (Put-Option). Die Ausübbarkeit definiert zwei Haupttypen von Optionen:

- Europäische Optionen: Diese können ausschließlich am Verfallstag (T) ausgeübt werden.
- Amerikanische Optionen: Diese können jederzeit bis zum Verfallstag (T) ausgeübt werden, einschließlich des Verfallstags selbst.

Diese zusätzliche Flexibilität der vorzeitigen Ausübung verleiht amerikanischen Optionen in der Regel einen höheren oder zumindest gleichwertigen Wert im Vergleich zu europäischen Optionen mit identischen Parametern.

Ein zentrales Konzept in der Theorie der Optionsbewertung ist das Prinzip der Arbitragefreiheit. Dieses besagt, dass unter idealisierten Marktbedingungen, wie vollständiger Information, fehlenden Transaktionskosten und sofortiger Handelbarkeit, keine risikolosen Gewinnmöglichkeiten bestehen dürfen (Harrison & Kreps, 1979; Delbaen & Schachermayer, 1994). Diese Annahme ermöglicht die Konstruktion replizierender Portfolios, die die Auszahlungsstruktur einer Option durch dynamische Kombinationen aus dem Basiswert S und einem risikofreien Asset r (z.B. Staatsanleihen) nachbilden. Der Preis der Option muss daher dem Preis des Replikationsportfolios entsprechen, da ansonsten Arbitrage möglich wäre (Cox, Ross & Rubenstein, 1979).

Auf dieser Grundlage basiert die sogenannte risikoneutrale Bewertung: Unter einem transformierten Wahrscheinlichkeitsmaß, dem risikoneutralen Maß Q , ergibt sich der faire Preis einer Option $V(S, t)$ als diskontierter Erwartungswert ihres Payoffs:

$$V(S, t) = e^{-r(T-t)} \mathbb{E}_Q[h(S_T)] \quad (2.1)$$

wobei $h(S_T)$ die Auszahlungsfunktion (z.B. $\max(S_T - K, 0)$ für eine Call-Option) zum Verfallszeitpunkt T beschreibt. Die risikoneutrale Bewertung bildet die Grundlage analytischer Modelle wie dem Black-Scholes-Modell.

2.1.2. Black-Scholes-Modell: Annahmen, Herleitung und Lösung

Das von Black und Scholes (1973) sowie Merton (1976) entwickelte Modell zur analytischen Bewertung von Optionen führte zu einem Paradigmenwechsel von risikobasierter Preismodelle, die auf einem Gleichgewichtsgedanken basierten, wie dem CAPM, hin zu arbitragebasierten Preismodellen (vgl. Heimer & Arend, 2008, S. 6). Die Arbeit von Black, Scholes & Merton wurde 1997 mit dem Alfred-Nobel-Gedächtnispreis für Wirtschaftswissenschaften gewürdigt und bildet bis heute die Grundlage für die Preisbildung an den Derivatemarkten.

Das Modell basiert auf einer Reihe idealisierter Annahmen über den Finanzmarkt und das Verhalten des Basiswertes (vgl. Hull, 2022, S. 348):

- Kursentwicklung: Der Basispreis S folgt einer geometrischen Brown'schen Bewegung mit einem deterministischen Anteil $\mu S dt$ (Drift), der die durchschnittliche erwartete Rendite pro Zeiteinheit beschreibt, und σ als Volatilität, die die Intensität der zufälligen Schwankungen misst, wobei dW als differentielles Inkrement eines Wiener-Prozesses darstellt:

$$dS = \mu S dt + \sigma S dW. \quad (2.2)$$

- Marktbedingungen: Der Markt ist friktionslos, d.h., es gibt keine Transaktionskosten, Steuern oder Leerverkaufsbeschränkungen. Alle Vermögenswerte sind perfekt teilbar.
- Zinssatz: Es existiert ein konstanter, risikofreier Zinssatz r , zu dem Kapital geliehen und verliehen werden kann.
- Dividenden: Der Basiswert schüttet während der Restlaufzeit t der Option keine Dividenden aus (diese Annahme kann durch Modifikation des Modells gelockert werden).
- Arbitragefreiheit: Es existieren keine risikolosen Gewinnmöglichkeiten (wie zuvor dargelegt).
- Optionsart: Das Modell gilt in seiner ursprünglichen Form für europäische Optionen, die nur am Fälligkeitsdatum ausgeübt werden können.

Unter diesen Annahmen lässt sich durch die Konstruktion eines risikofreien, sich selbst finanzierenden Replikationsportfolios eine partielle Differenzialgleichung herleiten. Gesucht ist eine Funktion $V(S, t)$, die den fairen Preis einer Option angibt. Der Preis des zugrunde liegenden Basiswertes $S(t)$ wird von Black, Scholes & Merton als stochastischer Prozess modelliert. Ein stochastischer Prozess ist eine Familie von Zufallsvariablen, welche die zeitliche Entwicklung eines Modells unter Unsicherheit beschreiben. Da die Kursbewegungen von Finanzinstrumenten maßgeblich durch unvorhersehbare externe Einflüsse geprägt sind, ist eine deterministische Modellierung nicht realistisch. Stattdessen ist bereits bekannt, dass $S(t)$ einem geometrischen Brown'schen Bewegungsprozess folgt.

Zu Beschreibung der Dynamik des Optionswertes $V(S, t)$, der von einem stochastischen Prozess, dem sogenannten Itô-Prozess, abhängt, wird Itô's Lemma verwendet. Während der

Itô-Prozess die zufällige Entwicklung des Basiswerts modelliert, erlaubt Itô's Lemma die Ableitung der stochastischen Änderung einer Funktion, die vom Prozess abhängt. Somit ergibt sich:

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial S} dS + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (dS)^2 \quad (2.3)$$

Um den Ausdruck vollständig aufzulösen, ist es notwendig, das Quadrat von dS zu bestimmen. Hier kommt eine zentrale Eigenschaft des Wiener-Prozesses ins Spiel: Im Itô-Kalkül gilt:

$$(dW)^2 = dt, (dt)^2 = 0, dt * dW = 0 \quad (2.4)$$

Durch Einsetzen von dS und $(dS)^2$ ergibt sich:

$$dV = \left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \sigma S \frac{\partial V}{\partial S} dW \quad (2.5)$$

Die Gleichung enthält weiterhin den deterministischen Anteil dt sowie den stochastischen Anteil dW .

Zur Herleitung einer geschlossenen Preislösung wird im Rahmen der Theorie von Black, Scholes & Merton ein risikofreies Replikationsportfolio, das die exakt gleiche Preisentwicklung wie die Option aufweist, konstruiert. Dies besteht aus zwei Komponenten: einer dynamischen angepassten Position Δ im Basiswert S sowie einer Position in einem risikofreien Geldmarktinstrument, das mit dem Zinssatz r verzinst wird. Der Gesamtwert des Portfolios Π ergibt sich somit zu:

$$\Pi(t) = \Delta S(t) + B(t) \quad (2.6)$$

Um den zufälligen Anteil dW zu eliminieren und exakt den deterministischen Anteil dt der Option zu replizieren ist die richtige Wahl von Δ ausschlaggebend:

$$\Delta = \frac{\partial V}{\partial S} \quad (2.7)$$

Somit ist das Portfolio vollständig gegen Marktbewegungen abgesichert und der verbleibende Renditezuwachs des Portfolios ist rein deterministisch. Das Portfolio ist damit risikolos und muss sich im arbitragefreien Markt mit dem risikofreien Zinssatz r verzinsen. Der Portfoliowert Π muss daher folgende Entwicklung erfüllen:

$$d\Pi = rV dt \quad (2.8)$$

wobei angenommen werden darf, dass das Portfolio exakt die Option repliziert

$$\Pi(t) = V(S, t) \text{ für alle } t \quad (2.9)$$

und somit auch die Änderungen identisch ist:

$$d\Pi = dV = rV dt \quad (2.10)$$

Die beiden Ausdrücke für dV , einer aus dem Itô's Lemma, der andere aus dem risikofreien Portfolio, müssen für den deterministischen Anteil dt übereinstimmen. Der zufällige Anteil dW wird durch das Hedging neutralisiert und somit vergleicht man nur die dt -Terme:

$$\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} = rV \quad (2.11)$$

Da das Portfolio jedoch risikolos ist, darf die erwartete Rendite μ des Basiswerts nicht berücksichtigt werden, da dieser ein Marktrisiko beinhaltet. In einem risikoneutralen Bewertungsrahmen wird daher μ durch den risikofreien Zinssatz r ersetzt. Das führt zur klassischen Form der Black-Scholes-PDE:

$$\frac{\partial V}{\partial t} + rS \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} - rV = 0 \quad (2.12)$$

Diese partielle Differenzialgleichung ist die Grundlage für die Preisbildung europäischer Optionen unter Annahme eines arbitragefreien Marktes, konstanter Volatilität und risikoneutraler Bewertung.

2.1.3. Preisformeln nach Black-Scholes

Die analytische Lösung der Black-Scholes-PDE (2.12) mündet in einer geschlossenen Preisformel für europäische Optionen. Diese Preisformeln ermöglichen eine direkte Berechnung des Optionspreises auf Basis beobachtbarer Marktparameter.

Preis einer europäischen Call-Option:

$$C(S_t, t) = S_t N(d_1) - K e^{(-r(T-t))} N(d_2). \quad (2.13)$$

Preis einer europäischen Put-Option:

$$P(S_t, t) = K e^{(-r(T-t))} N(-d_2) - S_t N(-d_1). \quad (2.14)$$

Wobei die Preisformeln aus folgenden Parametern bestehen:

- S_t : der Preis des Basiswerts zum Zeitpunkt t , bzw. der Basispreis;
- K : der Ausübungspreis;
- $T - t$: Restlaufzeit der Option in Jahren. In der Arbeit auch als t definiert;
- r : der risikofreier Zinssatz;
- σ : die konstante Volatilität der Renditen des Basiswerts;
- $N(\cdot)$: die kumulative Verteilungsfunktion (KVF) der Standardnormalverteilung.

Wobei $N(\cdot)$ die Wahrscheinlichkeit ausdrückt, dass eine Standard-normalverteilte Zufallsvariable einen Wert kleiner oder gleich dem Argument annimmt.

Die Terme d_1 und d_2 sind standardisierte Maße, die wie folgt berechnet werden:

$$d_1 = \frac{\ln(\frac{S_t}{K}) + (r + \frac{\sigma^2}{2})(T - t)}{\sigma\sqrt{T - t}} \quad (2.15)$$

$$d_2 = d_1 - \sigma\sqrt{T - t} \quad (2.16)$$

Die Preisformel für eine Call-Option (2.13) lässt sich intuitiv als Differenz zweier Barwerte interpretieren: dem erwarteten Nutzen aus dem Erhalt des Basiswerts und den erwarteten Kosten der Ausübung der Option. Wobei $N(d_2)$ die risikoneutrale Wahrscheinlichkeit meint, dass die Option am Ende der Laufzeit, am Verfallstag T , *im Geld* notiert, sprich, dass der Basispreis am Verfallstag S_T über dem Ausübungspreis K liegt.

Der Barwert der erwarteten Ausübungskosten wird durch den Term $Ke^{(-r(T-t))}N(d_2)$ repräsentiert. Der Ausübungspreis K wird mit dem risikofreien Zinssatz r auf den heutigen Tag diskontiert $e^{(-r(T-t))}$ und mit der Wahrscheinlichkeit gewichtet, dass diese Zahlung tatsächlich fällig wird $N(d_2)$.

Als letzter Term stellt $S_tN(d_1)$ den Barwert des bei Fälligkeit erwarteten Wertes des Basiswerts, bedingt darauf, dass die Option ausgeübt wird, dar. Dabei ist $N(d_1)$ nicht nur eine reine Wahrscheinlichkeit, sondern fungiert als Delta der Option. Der heutige Basispreis wird so gewichtet, dass er den heutigen Wert des bedingten Anspruchs auf den Basiswert zum Verfallstag T widerspiegelt.

Zusammenfassend stellt die Formel den heutigen Wert eines Portfolios dar, dass aus dem Kauf von $N(d_1)$ Anteilen des Basiswerts und der Aufnahme eines Kredits in Höhe von $Ke^{(-r(T-t))}N(d_2)$ besteht. Dieses Portfolio repliziert exakt den Auszahlungswert der Call-Option am Verfallstag T (vgl. Hull, 2022, S. 352).

In der vorliegenden Arbeit dient diese analytische Lösung als primärer Referenzwert (Benchmark), um die Genauigkeit der zu implementierenden Modelle zu bewerten.

2.1.4. Grenzen und empirische Schwächen des Black-Scholes-Modells

Das Black-Scholes-Modell, wie im vorangegangenen Kapitel detailliert hergeleitet, basiert auf idealisierten Annahmen über Marktbedingungen, die eine geschlossene Lösung der Optionspreisgleichung erlauben. Diese Annahmen führen jedoch zu strukturellen Schwächen, die in der praktischen Anwendung zu systematischen Bewertungsfehlern führen können. Im Folgenden werden diese Begrenzungen aus theoretischer und empirischer Perspektive untersucht und verdeutlicht die Notwendigkeit für erweiterte oder hybride Bewertungsansätze.

Das Black-Scholes-Modell basiert auf mehreren restriktiven Annahmen (siehe 2.1.2): konstante Volatilität, keine Transaktionskosten, kontinuierlicher Handel, Arbitragefreiheit, risikofreier Zinssatz als Konstante und keine Dividendenzahlung. Speziell die Annahme, dass die Volatilität des Basiswerts über die gesamte Laufzeit der Option und für alle Ausübungspreise identisch ist, widerspricht zahlreicher empirischen Beobachtungen: Finanzmärkte weisen spezielle Charakteristika von Zeitreihen, wie Volatilitätscluster, Kurtosis und

Skewness, auf (Cont, 2001). Diese Charakteristika werden durch das Black-Scholes-Modell nicht erfasst und führen zu Inkonsistenzen in der Preisbildung. Wenn die Black-Scholes-PDE (2.12) invertiert wird, um aus den am Finanzmarkt beobachteten Optionspreisen die implizite Volatilität, also die vom Markt erwartete Schwankungsbreite, zurückzurechnen, kann festgestellt werden, dass diese keineswegs konstant ist. Dieses Phänomen wird als *Volatility Smile* bzw. *Volatility Skew* bezeichnet:

- Volatility Smile: Bei Optionen mit derselben Restlaufzeit weisen Optionen, die weit *aus dem Geld* (out-of-the-money) oder *tief im Geld* (in-the-money) sind, eine signifikante höhere implizite Volatilität auf als Optionen *am Geld* (at-the-money). Grafisch betrachtet ergibt sich eine u-förmige Kurve, die einem Lächeln ähnelt (Derman & Kani, 1994).
- Volatility Skew: Speziell bei Aktienindexoptionen, wie die im Rahmen dieser Arbeit untersuchten S&P 500-Optionen, ist das „Lächeln“ oft asymmetrisch und zu niedrigeren Ausübungspreisen hin geneigt (ein „Skew“). Dies impliziert, dass Marktteilnehmer bereit sind, für Put-Optionen eine höhere Prämie zu zahlen, was auf eine höhere implizite Volatilität bei fallenden Märkten hindeutet. Dieses Phänomen wurde besonders nach dem Börsencrash von 1987, dem sogenannten „Schwarzen Montag“, zu einem immer wiederkehrenden Merkmal (Rubenstein, 1994; Jackwarth, 2002).

Diese empirischen Beobachtungen widerlegen die fundamentale Annahme, einer konstanten Volatilität, des Modells. Die Folge sind signifikante Bewertungsfehler für Optionen mit extremen Ausübungspreisen.

Die Annahme der geometrischen Brown’schen Bewegung für den Preis des Basiswerts impliziert, dass die logarithmischen Renditen normalverteilt sind. Die Realität zeigt jedoch, dass extreme Kursbewegungen, sowohl nach oben als auch nach unten, weitaus häufiger auftreten, als es die Normalverteilung vorhersagt. Bereits Mandelbrot (1963), Fama (1965) sowie Cont (2001) konnten nachweisen, dass Renditen typischerweise „fat tails“ aufweisen. Hierbei wird auch von sogenannter Kurtosis gesprochen, bedeutet, dass die Wahrscheinlichkeit extreme Schwankungen von der Normalverteilung systematisch unterschätzt werden.

Neben den dominanten Problemen der konstanten Volatilität und Renditeverteilung tragen weitere idealisierte Annahmen zur begrenzten praktischen Anwendbarkeit des Black-Scholes-Modells bei. Das Black-Scholes-Modell geht von einem konstanten und für alle Laufzeiten gleichen risikofreien Zinssatz r aus. In der Realität unterliegen Zinsen jedoch eigenen stochastischen Schwankungen und bilden eine Zinskurve, die weder flach noch konstant ist. Des Weiteren ist die Annahme eines vollkommen liquiden Marktes ohne Transaktionskosten, Steuern oder Leerverkaufsbeschränkungen eine starke Vereinfachung. Insbesondere die für die Herleitung dynamische Hedging-Positionen ist in der Praxis aufgrund von Transaktionskosten und diskreten Handelsintervallen nicht perfekt und friktionsfrei umsetzbar. Zudem berücksichtigt die ursprüngliche Gleichung (siehe 2.12) keine Dividendenzahlung während der Laufzeit, was bei langfristigen Optionen auf dividendenzahlende Aktien zu

Bewertungsfehlern führt.

Die Summe dieser Limitationen führt dazu, dass das Black-Scholes-Modell allein keine optimale Lösung für eine präzise und robuste Optionsbewertung darstellt. Zwar bieten vielfältige Erweiterungen des Black-Scholes-Modells, wie das *Heston Model* (Heston, 1993), das *Merton Jump Diffusion Model* (Merton, 1976) oder das *Local Volatility Model* (Dupire, 1994), eine bessere Anpassung an beobachtete Marktphänomene, sind jedoch analytisch komplexer, weniger transparent und meist nur numerisch lösbar. Alternativ rücken datengetriebene, nicht-parametrische Verfahren, wie neuronale Netze in den Fokus. Hutchinson et al. (1994) zeigen bereits früh, dass neuronale Netze die nicht-lineare Preisstruktur von Optionen erlernen können, ohne explizite Annahmen über die zugrunde liegende Dynamik zu treffen. Jedoch leiden rein datengetriebene Modelle an mangelnder ökonomischer Interpretierbarkeit und zeigen in datenarmen Bereichen oftmals instabile oder wenig robuste Ergebnisse.

Die empirischen Schwächen des Black-Scholes-Modells und die bereits vorhanden alternativen Ansätze motivieren den in dieser Arbeit verfolgten hybriden Ansatz. Es soll die Flexibilität datengetriebener neuronaler Netze mit den strukturellen Vorgaben kombinieren, indem die Black-Scholes-PDE (2.12) als Regularisierung in die Verlustfunktion integriert wird (Raissi et al., 2019; Sirignano & Spiliopoulos, 2018).

2.2. Deep Learning in der Finanzökonomie

Neuronale Netze können als *Universal Approximators* beliebiger stetiger Funktionen fungieren (Hornik, 1991), was sie für nicht-lineare Regressionsprobleme wie Optionsbewertung besonders geeignet macht. In der Finanzökonomie werden neuronale Netze eingesetzt zur Modellierung impliziter Volatilitäten, zur Prognose von Asset Returns sowie zur Approximation partieller Differenzialgleichung im Rahmen hybrider Bewertungsansätze wie PINN eingesetzt.

Im folgenden Abschnitt werden die zentralen Konzepte neuronaler Netze erläutert, mit besonderem Fokus auf Feedforward-Architekturen, Trainingsalgorithmen und Optimierungsherausforderungen, wie dem *Vanishing Gradient*.

2.2.1. Grundlagen künstlicher neuronale Netze

Künstlich neuronale Netze sind Rechenmodelle, die sich an der Struktur und Funktionsweise des menschlichen Gehirns orientieren. Diese Modelle bestehen aus miteinander verbundenen Schichten (*Layer*) von Neuronen, die jeweils einfache mathematische Operationen ausführen. Durch gezielte Trainings- bzw. Kalibrierungsprozesse können neuronale Netze Muster und Zusammenhänge in Daten erkennen und lernen, wobei sich die Architektur des Netzes je nach praktischer Anwendung unterscheiden kann. Während des Trainings passt das Modell die (Verbindungs-) Gewichte zwischen den Neuronen an, um eine definierte Verlustfunktion (*Loss Function*), die den Fehler zwischen Modellprognose und tatsächlichen Wert misst, basierend auf einem gegebenen Datensatz von Eingabe- und Ausgabevariablen

zu minimieren.

Das am weitesten verbreitete Basismodell neuronaler Netze ist das sogenannte *Feedforward Neural Network* (FNN), auch als *Multi-Layer Perceptron* (MLP) bekannt. Ein FNN definiert eine Abbildung $y : \mathbb{R}^D \rightarrow \mathbb{R}^K$, die einen Eingabevektor $x \in \mathbb{R}^D$ auf einen Ausgabevektor $y(x; w) \in \mathbb{R}^K$ abbildet. Die Transformation wird durch eine Sequenz von affinen Transformationen (gewichtete Summe) und nicht-linearen Aktivierungsfunktionen realisiert, wobei w die Menge aller trainierbaren Modellparameter (Gewichte und Biases) darstellt. Im Rahmen dieser Arbeit ist die Zielgröße ein einzelner Optionspreis, weshalb die Dimension des Ausgaberaums $K = 1$ beträgt.

In einem FNN fließt die Information unidirektional von der Eingabeschicht (*Input Layer*) über eine oder mehrere verborgene Schichten (*Hidden Layers*) zur Ausgabeschicht (*Output Layer*). Es gibt keine zyklischen Verbindungen oder Rückkopplungen, wie sie bspw. in rekurrenten Modellen auftreten, wodurch die Ausgabe eine deterministische Funktion der Eingabe ist (vgl. Bishop, 2006, S. 230).




Abbildung 1: Schematische Darstellung eines Feedforward Neural Network (FNN) mit mehreren versteckten Schichten zur Abbildung eines Eingabevektors auf einen skalaren Output.

Jedes Neuron j eines Hidden Layers oder des Output Layers erhält die gewichtete Ausgabe der Neuronen des vorhergehenden Layers. Für den ersten Hidden Layer stammen die Eingabevariablen x_i direkt aus dem Input Layer. Die Eingabevariable $a_j^{(1)}$ für ein Neuron j des ersten Hidden Layers ergibt sich somit zu:

$$a_j^{(1)} = \sum_{i=1}^D w_{ji}^{(1)} x_i + b_j^{(1)} \quad (2.17)$$

wobei D die Dimension der Eingabevariable, $w_{ji}^{(1)}$ die Gewichte und $b_j^{(1)}$ die Baises des ersten Hidden Layer darstellen. Jede Eingabevariable wird anschließend durch eine differenzierbare, nicht-lineare Aktivierungsfunktion $\phi(\cdot)$ transformiert, um die Ausgabe $z_j^{(1)}$ des Neurons zu berechnen:

$$z_j^{(1)} = \phi(a_j^{(1)}) \quad (2.18)$$

Für alle nachfolgenden Hidden Layer l wird die Ausgabe $z_j^{(l-1)}$ des vorherigen Hidden Layer als Eingabevariable verwendet:

$$a_j^{(l)} = \sum_i w_{ji}^{(l)} z_i^{(l-1)} + b_j^{(l)} \quad \text{und} \quad z_j^{(l)} = \phi(a_j^{(l)}) \quad (2.19)$$

Die Nichtlinearität der Aktivierungsfunktion ist hierbei essenziell. Wäre die Aktivierungsfunktion $\phi(\cdot)$ linear, würde das FNN trotz mehrerer Layer lediglich eine lineare Abbildung darstellen, da die Zusammensetzung linearer Funktionen wiederum linear ist. In diesem Fall ginge die Fähigkeit zur Approximation komplexer, nicht-lineare Zusammenhänge verloren (vgl. Goodfellow et al., 2016, S. 168). Gängige Aktivierungsfunktionen sind die Sigmoid-Funktion, die *Tangens Hyperbolicus* (*Tanh*) sowie die in modernen Architekturen weit verbreitet *Rectified Linear Unit* (*ReLU*).

Die Ausgaben der Neuronen des letzten Hidden Layers, $z_j^{(L)}$, werden linear kombiniert und bilden die Eingabe für den Output Layer. Im Fall der Optionsbewertung und der Vorhersage eines einzelnen Preises besteht der Output Layer aus nur einem einzigen Neuron. Dessen Eingabe $a^{(out)}$ berechnet sich als:

$$a_{out} = \sum_j w_j^{(out)} z_j^{(L)} + b_{(out)} \quad (2.20)$$

Um den endgültigen Ausgabevektor $y(x; w)$ zu erhalten, wird dieser Wert durch eine geeignete Ausgabefunktion $f(\cdot)$ transformiert. Bei Regressionsproblemen wird hierfür häufig die Identität ($f(a) = a$) verwendet: um die endgültige Netzwerkausgabe $y(x; w)$ zu erzeugen:

$$y(x; w) = f(a^{(out)}) \quad (2.21)$$

Der Ausgabevektor ist somit ein Skalar, der den modellierten Optionspreis darstellt.

Der in den vorherigen Gleichungen beschriebene Ablauf der Gewichtung, Summation und Aktivierung lässt sich anschaulich in Abbildung 2 darstellen.




Abbildung 2: Darstellung eines einzelnen Neurons mit gewichteten Eingaben, Bias-Term und nicht-linearer Aktivierungsfunktion $\phi(a)$.

2.2.2. Training mittels Backpropagation und Gradient Descent

Das Training eines neuronalen Netzes erfolgt typischerweise im Rahmen der Maximum-Likelihood-Methode, welche eine statistisch fundierte Grundlage für die Definition der Verlustfunktion bietet. Für Regressionsprobleme, wie bspw. der Optionsbewertung, wird angenommen, dass die Zielvariable t für eine gegebene Eingabe x einer Normalverteilung folgt. Der Mittelwert dieser Verteilung wird durch die Ausgabe des neuronalen Netzes $y(x; w)$ modelliert, während die Varianz als konstant angenommen wird und durch β^{-1} repräsentiert ist (vgl. Bishop, 2006, S. 233). Die bedingte Wahrscheinlichkeit für einen einzelnen Datenpunkt (x_n, t_n) lautet:

$$p(t_n | x_n, w, \beta) = \mathcal{N}(t_n | y(x_n, w), \beta^{-1}) \quad (2.22)$$

Diese Likelihood beschreibt die Wahrscheinlichkeitsdichte für den tatsächlichen Optionspreis t_n , gegeben die Eingabevariablen x_n und die Modellparameter $w \in \mathbb{R}^m$. Die Modellparameter w umfassen sämtliche in den Layern des neuronalen Netzes erhaltenen Gewichte und Biases. Formal kann die Netzabbildung wie folgt beschrieben werden:

$$y(\cdot; w) : \mathbb{R}^D \rightarrow \mathbb{R}, \quad (2.23)$$

wobei D die Dimension des Eingaberaums bezeichnet.

Dies bedeutet, dass die tatsächlichen Werte t_n um die Vorhersage des neuronalen Netzes $y(x_n; w)$ streuen und dieser Streuung eine Normalverteilung $\mathcal{N}$ mit Varianz β^{-1} zugrunde liegt.

Unter der Annahme, dass N Datenpunkte eines Datensatzes unabhängig und identisch verteilt sind (i.i.d.), ergibt sich die Likelihood-Funktion für den gesamten Datensatz als

Produkt der einzelnen bedingten Dichten (vgl. Bishop, 2006, S. 233):

$$p(t|X, w, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | y(x_n; w), \beta^{-1}) \quad (2.24)$$

Dieser Ausdruck, die *Likelihood*, quantifiziert, wie „plausibel“ die aktuellen Modellparameter w angesichts des gesamten Datensatzes sind. Da die einzelnen Wahrscheinlichkeiten als unabhängig angenommen werden, ergibt sich die Gesamtwahrscheinlichkeit als Produkt der Wahrscheinlichkeitsdichten der einzelnen Beobachtungen.

Das Ziel der Maximum-Likelihood-Methode besteht darin, die Parameter w (und ggf. β) so zu bestimmen, dass die Likelihood-Funktion maximiert wird.

Bei unabhängigen und identisch verteilten Datenpunkten ergibt sich die Likelihood als Produkt der bedingten Wahrscheinlichkeitsdichten $p(t_n | x_n, w)$ aller Beobachtungen. Da aber dieses Produkt bei relativ großen Datensätzen aus vielen kleinen Faktoren besteht, kann es numerisch instabil werden.

Zur Verbesserung der numerischen Stabilität und zur Vereinfachung der Berechnungen wird der Logarithmus der Likelihood angewendet, wodurch das Produkt in eine Summe von Log-Wahrscheinlichkeiten transformiert wird. Um aus der Maximierungsaufgabe eine für gängige Optimierungsverfahren geeignete Minimierungsaufgabe zu machen, wird zusätzlich das Vorzeichen gewechselt. Dies führt zur sogenannten negativen Log-Likelihood-Funktion (NLL), die im Training von FNN als Verlustfunktion dient:

$$\begin{aligned} -\ln p(t | X, w, \beta) &= -\sum_{n=1}^N \ln \mathcal{N}(t_n | y(x_n; w), \beta^{-1}) \\ &= \frac{\beta}{2} \sum_{n=1}^N (y(x_n; w) - t_n)^2 - \frac{N}{2} \ln \beta + \frac{N}{2} \ln(2\pi) \end{aligned} \quad (2.25)$$

Für die Bestimmung der Modellparameter w kann bei konstanter Varianz β die NLL um alle Terme gekürzt werden, die nicht von w abhängen. Es verbleibt ein Termin, der bis auf den konstanten Faktor $\frac{\beta}{2}$ der Summe der Residuenquadrate (*Sum of Squared Errors*) (SSE) entspricht. Da dieser Faktor bei der Optimierung nach w keinen Einfluss auf die Lage des Minimums hat, ist die Maximierung der Likelihood in diesem Fall äquivalent zur Minimierung der SSE (vgl. Bishop, 2006, S. 233). Die SSE wird oft mit einem Faktor $\frac{1}{2}$ zur Vereinfachung der Ableitung, als Verlustfunktion $\mathcal{L}(w)$ definiert:

$$\mathcal{L}(w) = \frac{1}{2} \sum_{n=1}^N \|y(x_n; w) - t_n\|^2 \quad (2.26)$$

Da die Netzfunktion $y(x; w)$ aufgrund der nicht-linearen Aktivierungsfunktion eine nicht-konvexe Funktion der Modellparameter w ist, existiert in der Regel keine geschlossene analytische Lösung für die Minimierung von $\mathcal{L}(w)$. Stattdessen werden iterative Optimierungsverfahren auf Basis des sogenannten Gradientenverfahrens (eng. Gradient Descent)

eingesetzt (vgl. Goodfellow et al., 2016, S. 172). Hierbei werden die Modellparameter w iterativ in die entgegengesetzte Richtung des Gradienten der Verlustfunktion aktualisiert:

$$w^{(k+1)} = w^{(k)} - \eta \nabla_w \mathcal{L}(w^{(k)}), \quad (2.27)$$

wobei $\eta > 0$ die Lernrate bezeichnet.

Für ein einzelnes Gewicht w_j ergibt sich die partielle Ableitung (Gradient) der Verlustfunktion $\mathcal{L}(w)$ zu

$$\frac{\partial \mathcal{L}(w)}{\partial w_j} = \sum_{n=1}^N (y(x_n; w) - t_n) \frac{\partial y(x_n; w)}{\partial w_j} \quad (2.28)$$

Der erste Faktor $(y(x_n; w) - t_n)$ stellt den *Fehler* dar, welcher die Abweichung der Modellvorhersage vom tatsächlichen Wert beschreibt. Der zweite Faktor $\frac{\partial y(x_n; w)}{\partial w_j}$ ist die partielle Ableitung der Netzausgabe in Bezug auf das Gewicht w_j und quantifiziert damit dessen Einfluss auf die Modellvorhersage.

Der vollständige Gradientenvektor

$$\nabla_w \mathcal{L}(w) = \left(\frac{\partial \mathcal{L}(w)}{\partial w_1}, \dots, \frac{\partial \mathcal{L}(w)}{\partial w_m} \right)^\top \quad (2.29)$$

stellt den Vektor aller partiellen Ableitungen dar und gibt die Richtung des steilsten Anstiegs der Verlustfunktion $\mathcal{L}$ im Parameterraum $\mathbb{R}^m$ an, wobei m die Anzahl der Modellparameter bezeichnet.

In mehrschichtigen bzw. tiefen FNN ist die direkte Berechnung aller partiellen Ableitungen sehr rechenintensiv und ineffizient, da jeder Parameter über komplexe nicht-lineare Abhängigkeiten mit der Netzausgabe verbunden ist. Das sogenannte Backpropagation (Rumelhart et al., 1986) adressiert dieses Problem, indem es die Kettenregel der Differenzialrechnung nutzt, um die partielle Ableitung $\frac{\partial (y(x_n; w))}{\partial w_j}$ schrittweise vom Output-Layer zurück zum Input-Layer zu propagieren.

Hierbei wird der Gradient effizient als Matrix-Vektor-Produkt:

$$\nabla_w \mathcal{L}(w) = J_y(w)^\top r(w) \quad (2.30)$$

berechnet, wobei $J_y(w)$ der Jacobian-Matrix der Netzausgabe nach den Modellparametern w bezeichnet und

$$r(w) = (y(x_1; w) - t_1, \dots, y(x_N; w) - t_N)^\top \quad (2.31)$$

den Residuenvektor darstellt.

Das Backpropagation ermittelt hierbei direkt das Produkt $J_y(w)^\top r(w)$, ohne die vollständige Jacobian-Matrix explizit zu konstruieren, wodurch die Rechenkomplexität proportional zum Forward-Pass des Netzes bleibt.

2.2.3. Gradienteninstabilität in neuronalen Netzen

Wie zuvor erörtert stellt das Backpropagation einen effizienten Ansatz zur Berechnung der Gradienten in neuronalen Netzen dar. Jedoch kann das Training eines neuronalen Netzes, insbesondere von mehrschichtigen Netzen, durch das Problem instabiler Gradienten ineffizient werden. Bereits Hochreiter (1991; Hochreiter et al., 2001) konnte zeigen, dass Gradienten während des Backpropagations dazu neigen, entweder exponentiell zu schrumpfen (engl. *Vanishing Gradients*) oder exponentiell zu wachsen (engl. *Exploding Gradients*).

Das Problem der Vanishing Gradients entsteht, wenn die partiellen Ableitungen der Aktivierungsfunktionen Werte kleiner als eins annehmen. Ein Beispiel hierfür ist die Sigmoid-Funktion, deren Ableitung im Bereich $[0; 0.25]$ liegt. Die wiederholte Multiplikation kleiner Werte führt dazu, dass der Gradient beim Durchlaufen vieler Layer exponentiell abnimmt. Dadurch werden die Gewichte in frühen Layer kaum angepasst, was das Lernen grundlegender Merkmale des Datensatzes stark negativ beeinflusst (vgl. Glorot & Bengio, 2010).

Das Problem der Exploding Gradients tritt auf, wenn die wiederholte Multiplikation mit Werten größer als ein zu einem exponentiellen Wachstum der Gradienten führt. Dies führt zu extrem großen Aktualisierungen der Gewichte, was das Training destabilisiert und zu numerischen Überläufen führen kann. Auch in diesem Fall kann das Netz nicht konvergieren.

Zur Begrenzung der beschriebenen Stabilitätsprobleme werden in der Praxis mehrere Ansätze verfolgt. Eine weit verbreitete Methode ist das Gradient Clipping, bei dem die Norm des Gradienten auf einen definierten Schwellenwert beschränkt wird, um übermäßige Anpassungen der Gewichte und numerische Instabilitäten zu vermeiden (Pascanu et al., 2013). Auch ist die Wahl einer für das Netz und dessen Aufgabe geeigneten Aktivierungsfunktion, bspw. die Rectified Linear Unit (ReLU), da ihre Ableitung für positive Eingaben konstant 1 beträgt und dadurch das Problem von Vanishing Gradients reduziert wird.

Darüber hinaus wird in der Praxis oftmals das sogenannte *Batch Normalization* angewendet, bei dem die Daten vor Weitergabe in den nächsten Layer während des Trainings normalisiert werden. Dadurch bleiben Mittelwert und Varianz innerhalb eines stabilen Bereichs, was eine gleichmäßige Verteilung der Gradienten ermöglicht.

Neben den erörterten Ansätzen wurden in den letzten Jahren zudem neue Netzarchitekturen entwickelt, die den Verlauf der Gradienten strukturell stabilisieren. Dazu zählen unter anderem Residual Networks (ResNets), die zusätzliche Verknüpfungen zwischen nicht direkt aufeinanderfolgenden Layers einführen und dadurch Informationen sowie Gradienten direkt an spätere Schichten weitergeben können sowie Architekturen wie Long Short-Term Memory (LSTM), die mithilfe spezieller Steuermechanismen entscheiden, welche Informationen über längere Zeiträume gespeichert, weitergeleitet oder verworfen werden, und so ein stabiles Training auch bei langen Abhängigkeiten ermöglichen.

2.2.4. Anwendungen im Bereich der Optionsbewertung

Aufbauend auf den vorherigen Kapiteln, insbesondere den dargestellten Grundlagen neuronaler Netze in Kapitel 2.2.1, hat sich deren Anwendung zur Optionsbewertung in den letzten Jahren signifikant weiterentwickelt. Frühere Arbeiten, wie die von Hutchinson et al. (1994), lieferten zunächst den Nachweis, dass neuronale Netze grundsätzlich in der Lage sind, Optionspreise zu modellieren. Dieser grundlegende Ansatz, durch Einsatz von FNNs oder MLPs die nicht-lineare Beziehung zwischen Input und Output direkt aus empirischen Daten zu lernen, wird weiterhin in zahlreichen Studien verfolgt und ist mittlerweile zu einem dynamischen Forschungsfeld herangewachsen.

Liu et al. (2019) demonstrieren, dass bereits optimierte MLPs die analytische Black-Scholes-Preisformel mit hoher Genauigkeit approximieren kann, was die prinzipielle Eignung von neuronalen Netzen als universelle Funktionsapproximatoren in diesem Kontext bestätigt. Ke & Yang (2021) erweitern diesen Ansatz und zeigen, dass Deep-Learning-Modelle klassische Modelle in der Preisprognose übertreffen können. Sie untersuchen verschiedene Architekturen, darunter MLPs und LSTM Netze, und stellen fest, dass insbesondere Modelle, die die zeitliche Komponente der Daten berücksichtigt, Vorteile bieten.

Eine zentrale Herausforderung für rein datengetriebene Modelle ist jedoch deren Umgang Risikokennzahlen wie der Volatilität und das Lernen von Mustern aus diesen Kennzahlen. Viele frühe Modelle nutzen historische oder implizite Volatilitäten als externen Input, während neuere Ansätze versuchen die Dynamik der Volatilität direkt zu modellieren. Pimentel et al. (2025) setzen bspw. ein LSTM Netz ein, um aus Zeitreihen von Options- und Basiswertpreisen implizit die kurzfristige Volatilität zu erfassen. Ihre Ergebnisse deuten darauf hin, dass die sequentielle Verarbeitung von Informationen des LSTM Netzes es dem Modell ermöglicht, robustere Preisprognosen zu erstellen ohne Abhängig von externen, potenziell fehlerhaften historischen Volatilitätswerten zu sein.

Ein weiterer signifikanter Trend ist die Entwicklung hybrider Ansätze, die neuronale Netze nicht als vollständigen Ersatz, sondern als Ergänzung zu etablierten finanzmathematischen Modellen verstehen. Almeida et al. (2022) schlagen eine zweistufige Methode vor, bei der ein neuronales Netz darauf trainiert wird, die systematischen Fehler bei der Optionsbewertung (Residuen) von parametrischen Modelle (z.B. Black-Scholes oder Heston) zu korrigieren. Dieser Ansatz des „Model-Guided Nonparametric Correction“ zeigt, dass die Kombination aus der strukturellen Vorgabe eines parametrischen Modells und der Flexibilität eines neuronalen Netzes zu einer signifikant höheren Prognosegüte führt. Die Korrektur eines spezifizierten Heston-Modells führt dabei zu den besten Ergebnissen.

Die Arbeit von Li (2022) analysiert ein breites Spektrum eingesetzter Machine-Learning und Deep-Learning-Modelle, das von *Support Vector Machines* (SVM) bis hin zu diversen Architekturen von neuronalen Netzen reicht, und bestätigt den allgemeinen Konsens, dass datengetriebene Ansätze traditionelle parametrische Modelle in der Regel übertreffen. Aufbauend auf dieser Erkenntnis stellt sich die Frage, welche spezifischen Architekturen am besten für die Optionsbewertung geeignet sind. Van Mieghem et al. (2023) gehen dieser

Frage systematisch nach und untersuchen, wie die spezifische Architektur neuronaler Netze die Genauigkeit beeinflusst. Sie vergleichen klassische MLPs mit neueren Architekturen wie ResNets, *Highway Networks* sowie *Generalized Highway Networks*, die ursprünglich für komplexe Aufgaben wie die Bilderkennung entwickelt wurden. Ihre empirische Analyse zeigt auf, dass für die Optionsbewertung nach Black-Scholes und Heston das *Generalized Highway Network* alle anderen untersuchten Varianten von neuronalen Netzen hinsichtlich der Genauigkeit, gemessen am MSE, und der Trainingseffizienz übertrifft.

Zusammenfassend lässt sich festhalten, dass die aktuelle Forschung mehrere vielversprechende Trends verfolgt. Dabei ist ein zentraler Trend der Einsatz von komplexeren und spezialisierten Architekturen neuronaler Netze, wie LSTMs zur Erfassung zeitlicher Abhängigkeiten oder ResNets zur Optimierung der Backpropagation. Gleichzeitig gewinnt die hybride Modellierung an Bedeutung, bei der etablierte parametrische Modelle aus der Finanzmathematik mit der datengetriebenen Flexibilität neuronaler Netze kombiniert wird, um die jeweiligen Schwächen der beiden Ansätze auszugleichen. Sowie der Einsatz von Faktormodellen, die darauf abzielen, latente, aber entscheidende Variablen wie die Volatilität nicht als externen Input vorauszusetzen, sondern deren Dynamik direkt aus den empirischen Daten zu erlernen.

Der dargelegte Forschungsstand verdeutlicht, dass die Verknüpfung von finanzmathematischen Modelle und datengetriebenen Methoden zukünftig bei der Entwicklung neuer Ansätze zur Optionsbewertung eine wichtige Rolle spielt. Während rein empirische Ansätze an ihre Grenzen stoßen, wenn es um Generalisierbarkeit und ökonomische Zusammenhänge geht, bieten hybride Modelle einen vielversprechenden Weg, die Stärken beider Wissensgebiete zu vereinen. Die Herausforderung besteht darin, über eine reine nachträgliche Verbesserung der Fehlerquote eines Modells hinauszugehen und theoretische Ansätze aus der Finanztheorie in die Architektur und somit in das Training von neuronalen Netzen zu integrieren. Solch ein Ansatz könnte Modelle hervorbringen, die nicht nur eine hohe Prognosegüte vorweisen, sondern auch strukturell robust und im Einklang mit fundamentalen ökonomischen Prinzipien wie bspw. der Arbitragefreiheit sind. Die folgende Arbeit wird sich im Folgenden tiefer mit dieser Fragestellung auseinandersetzen und einen Ansatz aufzeigen, wie diese Integration methodisch umgesetzt werden kann.

2.3. Physics-Informed Neural Networks (PINNs)

Die vorangegangenen Kapitel haben die jeweiligen Stärken und Schwächen der klassischen, modellbasierten Optionsbewertungsmodelle (Kapitel 2.1.4) sowie die rein datengetriebenen Ansätze des Deep Learnings (Kapitel 2.2.1) analysiert. Während das Black-Scholes-Modell eine theoretisch fundierte, aber in seinen Annahmen, wie in Kapitel 2.1.2 dargelegt, restriktive Struktur vorgibt, bieten neuronale Netze hohe Flexibilität, leiden jedoch unter mangelnder Interpretierbarkeit und potenziell geringer Generalisierungsfähigkeit bei limitierten Daten.

PINNs sind eine Klasse von neuronalen Netze, die externes Wissen in Form von physikalischen Gesetzen, oder in dieser Arbeit finanzmathematischen Modellen, direkt in den Trainingsverlauf des Netzes integrieren. Anstatt das Modell ausschließlich auf Basis beobachteter Daten zu trainieren, wird die Verlustfunktion um einen zusätzlichen Term erweitert. Dieser Term quantifiziert die Einhaltung einer zugrundeliegenden partiellen Differenzialgleichung (PDE), wie der Black-Scholes-Gleichung (2.12). Der Ansatz zielt darauf ab, die Flexibilität von neuronalen Netzen mit der strukturellen Konsistenz klassischer Modelle zu kombinieren. Die Arbeit von Raissi, Perdikaris & Karniadakis (2019) beschreibt diese Methode und demonstriert ihre Wirksamkeit bei der Lösung und Identifikation nicht-linearer PDEs.

2.3.1. Konzept und Motivation

Die Motivation für den Einsatz von PINNs ergibt sich aus den Limitationen rein datengetriebener Modelle sowie klassischer numerischer Lösungsverfahren für PDEs. Klassische Verfahren wie die Finite-Differenzen-Methode (FDM) oder die Finite-Elemente-Methode (FEM) erfordern eine Diskretisierung des Lösungsraums in ein Gitter oder Netz (engl. *mesh*) und sind insbesondere in höheren Dimensionen sehr rechenintensiv (sog. „curse of dimensionality“).

Die Motivation für den Einsatz von PINNs in dieser Arbeit ergibt sich aus den in Kapitel 2.2.1 beschriebenen Limitationen rein datengetriebener Modelle. Einfache neuronale Netze, wie bspw. das FNN, approximieren Funktionen, indem sie Muster aus Trainingsdaten extrahieren, ohne ein explizites Verständnis der zugrunde liegenden systematischen Zusammenhänge zu besitzen. Dies kann zu mehreren Problemen führen: Zum einen erfordert das Erlernen komplexer und dynamischer Zusammenhänge oft sehr große Datenmengen, die im Finanzkontext oftmals sehr teuer oder nur spärlich verfügbar sind. Zum anderen für die alleinige Abhängigkeit von historischen Daten zu einer mangelnden Generalisierungsfähigkeit, speziell bei Marktbedingungen, die von den historischen Trainingsdaten signifikant abweichen. Schließlich fehlt den Vorhersagen rein datengetriebener Modelle oft das theoretische Wissen, wodurch bspw. fundamentale ökonomische Prinzipien wie die Arbitragefreiheit verletzt werden können, da diese nicht explizit im Modell verankert sind.

PINNs adressieren diese Schwächen, indem sie die zugrundeliegende PDE als strukturelle Vorgabe in die Modellierung einbeziehen. Hierzu wird die PDE in Form einer Neben-

bedingung als zusätzlicher Regularisierungsterm in die Verlustfunktion aufgenommen, sodass datengetriebene neuronale Netze nicht nur die empirischen Daten approximiert, sondern zugleich die Residuen der PDE minimiert. Auf diese Weise werden Abweichungen von der durch die PDE spezifizierten Modellannahme, bspw. der Preisdynamik in der Black-Scholes-PDE, explizit bestraft.

Raissi et al. (2019) unterscheiden dabei zwei primäre Anwendungsfälle für PINNs:

1. Data-driven solutions of PDEs (Forward Problem): Hierbei ist die PDE inklusive ihrer Parameter (z.B. Zinssatz r , Volatilität σ) vollständig bekannt. Das Ziel ist es, eine Lösung der PDE zu finden, die zusätzlich mit einer Menge von beobachteten Datenpunkten konsistent ist. Das PINN agiert in diesem Fall als data-driven PDE Solver.
2. Data-driven discovery of PDEs (Inverse Problem): In diesem Fall ist die strukturelle Form der PDE bekannt, jedoch sind einer oder mehrere ihrer Parameter unbekannt. Das Ziel ist es, aus den Daten nicht nur die Lösungsfunktion, sondern gleichzeitig auch die unbekannten Parameter zu erschließen. Im Kontext der Optionsbewertung könnte dies bspw. die Ermittlung einer impliziten Volatilität sein, die am besten zu den beobachteten Marktpreisen passt.

Die vorliegende Arbeit konzentriert sich auf den zweiten Anwendungsfall, das *Inverse Problem*. Es wird die Kapitel 2.1.2 hergeleitete Black-Scholes-PDE verwendet, um ein neuronales Netz zu Regularisieren, das auf Basis von Marktdaten den Preis sowie die Volatilität europäischer Optionen bestimmt. Das neuronale Netz lernt somit nicht nur eine Abbildung von Inputs zu Outputs, sondern zwei Lösungsfunktion der PDE selbst, die mit den historischen Daten konsistent ist.

2.3.2. Formale Herleitung und Architektur

Die Architektur eines PINN basiert auf einem FNN, wie in Kapitel 2.2.1 beschrieben. Dieses neuronale Netz, im Folgenden als $V_{NN}(S, t; w)$ definiert, wird als universeller Funktionsapproximator (Hornik, 1991) genutzt, um die Lösungsfunktion der Black-Scholes-PDE anzunähern. Die Eingabevariablen sind die unabhängigen Variablen der PDE, hier bspw. der Preis des Basiswerts S und die Zeit t . Der Output ist der geschätzte Optionspreis V . Die Parameter des neuronalen Netzes, also die Gewichte und Biases w , werden durch die Minimierung einer strukturierten Verlustfunktion optimiert.

Die Verlustfunktion $L(w)$ setzt sich aus mehreren Termen zusammen und umfasst typischerweise drei Teile: einen datengetriebenen Fehler, einen PDE-basierten Fehler und einen Fehlerterm für die Randbedingungen.

$$\mathcal{L}(w) = \lambda_{data}\mathcal{L}_{data}(w) + \lambda_{PDE}\mathcal{L}_{PDE}(w) + \lambda_{BC}\mathcal{L}_{BC}(w), \quad (2.32)$$

wobei die λ -Terme Gewichtungsfaktoren darstellen, die die relative Bedeutung jeden Term der Verlustfunktion während der Optimierung steuern.

Der Term $\mathcal{L}_{data}$ stellt die Verbindung zu den historischen Marktdaten her. Er ist identisch mit der Verlustfunktion eines einfachen FNN für Regressionsaufgaben (siehe Gleichung 2.26) und misst den mittleren quadratischen Fehler zwischen den vom neuronalen Netz vorhergesagten Preisen $V_{NN}(S_i, t_i; w)$ und den historischen Marktdaten $\hat{V}_i$ an N_{data} Trainingspunkten:

$$\mathcal{L}_{data} = \frac{1}{N_{data}} \sum_{i=1}^{N_{data}} |V_{NN}(S_i, t_i; w) - \hat{V}_i|^2 \quad (2.33)$$

Der PDE-Verlust $\mathcal{L}_{pde}$ erzwingt die Einhaltung der zugrundeliegenden partiellen Differenzialgleichung. Im vorliegenden Beispiel misst der Term, wie gut die vom neuronalen Netz approximierte Funktion V_{NN} die Black-Scholes-PDE erfüllt. Dazu wird das Residuum der PDE, $f(S, t)$, definiert:

$$f(S, t) := \frac{\partial V_{NN}}{\partial t} + rS \frac{\partial V_{NN}}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V_{NN}}{\partial S^2} - rV_{NN} \quad (2.34)$$

Der PDE-Verlust $\mathcal{L}_{pde}$ der mittlere quadratische Fehler des Residuums, gemessen an einer großen Anzahl N_{pde} von Kollokationspunkten S_j, t_j , die im Lösungsraum verteilt sind:

$$\mathcal{L}_{pde} = \frac{1}{N_{pde}} \sum_{j=1}^{N_{pde}} |f(S_j, t_j)|^2 \quad (2.35)$$

Die Kollokationspunkte sind unabhängig von erhobenen Marktdaten und fungieren als direkte Referenzpunkte, an denen die Erfüllung der partiellen Differenzialgleichung überprüft und in die Optimierung integriert wird.

Ferner ist jede PDE nur in Verbindung mit ihren Rand- und Anfangs- bzw. Endbedingungen eindeutig lösbar. Der Lösungsraum der Black-Scholes-PDE ist durch den Preis des Basiswerts S und die Zeit t definiert, d.h. $(S, t) \in [0, \infty) \times [0, T]$. Für eine eindeutige Lösung müssen Bedingungen an den Rändern dieses Lösungsraums spezifiziert werden. Hierbei wird zwischen der Endbedingung (engl. Terminal Condition), die den Wert der Option bei Fälligkeit beschreibt, und den Randbedingungen (engl. Boundary Conditions), die das Verhalten der Option für extreme Werte des Preises des Basiswerts S definieren. Für eine europäische Call-Option sind dies bspw.:

- Terminal Condition (bei $t = T$): Der Wert der Option am Fälligkeitstag entspricht ihrer Auszahlungsfunktion $V(S, t) = \max(S - K, 0)$.
- Boundary Conditions (für $t \in [0, T]$):
 - Für $S = 0$: Der Wert einer Call-Option ist null, wenn der Basiswert wertlos ist: $V(0, t) = 0$
 - Für $S \rightarrow \infty$: Der Wert der Option nähert sich dem Wert des Basiswerts abzüglich des diskontierten Ausübungspreises an: $V(S, t) \rightarrow S - Ke^{-r(T-t)}$

Folglich misst der Verlust der Rand- und Endbedingungen ($\mathcal{L}_{bc}$) die Abweichung der Vorhersages des neuronalen Netzes von diesen Bedingungen an N_{bc} Punkten entlang der

Ränder des Lösungsraums. Für die Endbedingung einer Call-Option wäre der Beitrag zum Verlust bspw.:

$$\mathcal{L}_{bc,T} = \frac{1}{N_{bc,T}} \sum_{k=1}^{N_{bc,T}} |V_{NN}(S_k, T; w) - \max(S_k - K, 0)|^2 \quad (2.36)$$

2.3.3. Automatisches Differenzieren und Modellvarianten

Ein entscheidender Aspekt für die Realisierung von PINNs ist das sogenannte *Automatic Differentiation (AD)*. Um das PDE-Residuum $f(S, t)$ zu berechnen, müssen die partiellen Ableitungen von V_{NN} nach S und t (bis zur zweiten Ordnung für S) berechnet werden. AD ermöglicht dies auf exakte und effiziente Weise. Im Gegensatz zur numerischen Differenziation (z.B. über Differenzenquotienten), die Approximationsfehler einführt, die zu komplexen und ineffizienten Ausdrücken führen kann, nutzt AD die Kettenregel auf dem Rechengraphen des neuronalen Netzes. Da ein FNN aus einer Kette von differenzierbaren Operationen (lineare Transformationen und Aktivierungsfunktionen) besteht, kann der Gradient des Outputs anhand der Inputs exakt berechnet werden. Dieser Ansatz ist derselbe, der auch beim Backpropagation (Kapitel 2.2.2) zur Berechnung der Gradienten nach den Gewichten w verwendet wird, wird her aber auf die Eingabevariablen (S, t) angewendet.

Durch die Minimierung der kombinierten Verlustfunktion $\mathcal{L}(w)$ mittels Gradient Descent wird das neuronale Netz gezwungen eine Funktion zu erlernen, die nicht nur die Marktdaten interpoliert, sondern auch die zugrunde liegende Struktur der Black-Scholes-PDE sowie die definierten Randbedingungen respektiert. Dieser Ansatz, bei dem die PDE über Kollokationspunkte im gesamten Raum-Zeit-Bereich erzwungen wird, wird von Raissi et al. (2019) als Continuous Time Model bezeichnet. Alternativ dazu beschreiben Raissi et al. Discrete Time Models, bei denen Klassische numerische Diskretisierungsverfahren (z.B. Runge-Kutta-Verfahren) direkt in die Architektur des neuronalen Netzes integriert werden. Solche Modelle lernen, die Lösung von einem Zeitpunkt zum nächsten zu propagieren.

Für die Zielsetzung dieser Arbeit wird der Ansatz des *Continuous Time Models* verfolgt. Obwohl die strukturelle Form der Black-Scholes-PDE als bekannt vorausgesetzt wird, was zunächst auf ein Forward Problem hindeutet, verfolgt die Methodik in der praktischen Umsetzung in Kapitel 3 ein *Inverses Problem*. Konkret wird die implizite Volatilität σ nicht als fester, extern gegebener Parameter behandelt, sondern als zusätzliche Ausgabegröße des Modells approximiert. Das Modell lernt somit aus den historischen Daten nicht nur eine mögliche Preisoberfläche $V(S, t)$, sondern inferiert gleichzeitig jene Volatilität, die die Diskrepanz zwischen den Marktpreisen und der PDE-basierten Lösung minimiert. Dieser hybride Ansatz ermöglicht es, die theoretische Struktur der PDE zu wahren und sie gleichzeitig an die im Markt implizit enthaltenen Erwartungen anzupassen.

2.3.4. PINNs im Finanzkontext: Stand der Forschung

Aufbauend auf die Erläuterung der konzeptionellen und architektonischen Grundlagen von PINNs, insbesondere ihre Fähigkeit, PDEs durch eine speziell strukturierte Verlustfunktion zu approximieren (Kapitel 2.3.2), widmet sich dieses Kapitel dem aktuellen Stand der Forschung zu deren Anwendung im Finanzkontext. Wie bereits in Kapitel 2.2.4 dargelegt, hat sich die Integration von finanzmathematischen Modellen in Deep-Learning-Ansätze als ein dynamisches und vielversprechendes Forschungsfeld etabliert, das darauf abzielt, die jeweiligen Stärken von klassischen, parametrischen Modellen und flexiblen, datengetriebenen Modellen zu vereinen. Einen konkreten und methodisch innovativen Ansatz zur Realisierung dieser Synthese stellen die PINNs dar. Sie operationalisieren die Einbindung von fachspezifischen Wissen, indem die zugrunde liegenden theoretischen Modelle direkt als struktureller Regularisierer in die Verlustfunktion des neuronalen Netzes integriert wird.

Die initialen Arbeiten im Finanzkontext konzentrieren sich auf den Nachweis der prinzipiellen Eignung des von Raissi et al. (2019) etablierten Framework von PINNs zur Lösung der Black-Scholes-PDE (2.12). Diese Arbeiten dienen als „Proof-of-Concept“ und validieren den Ansatz gegenüber analytischen Lösungen und traditionellen numerische Verfahren. So belegen Wang et al. (2023), dass PINNs die Bewertung europäischer Optionen mit hoher Prognosegüte approximieren und dabei in der Implementierung einfach sind als numerische Verfahren, wie bspw. Finite-Differenzen-Methode (FDM). Bai et al. (2022) gehen einen Schritt weiter und schlagen eine verbesserte Architektur, ein sogenanntes *Improved Physics-Informed Neural Network (IPINN)*, mit lokal adaptiven Aktivierungsfunktionen vor, die eine schnellere Konvergenz und erhöhte Stabilität im Training ermöglicht. Dhiman & Hu (2023) konnten aufzeigen, dass PINNs sowohl auf simulierten als auch auf realen Marktdaten eine signifikant bessere Prognosegüte gegenüber verschiedenen Benchmarks erreichen. Damit wird deutlich, dass PINNs sich als effiziente *PDE-Solver*, die unabhängig von einer räumlichen oder zeitlichen Diskretisierung arbeiten, etablieren und schaffen die Voraussetzung für die Analyse komplexerer Modelle. Noguer i Alonso & Antolin Camarena (2023) zeigen auf, wie die miteinander verknüpften stochastischen Differenzialgleichungen des Heston-Modells direkt in das Training eines PINNs eingebettet werden kann.

Ein signifikanter Fortschritt ist die Anwendung von PINNs auf amerikanische Optionen, die durch die Möglichkeit der vorzeitigen Ausübung ein freies Randwertproblem darstellen und sich somit konzeptionell von europäische Optionen unterscheiden, welche klar definierte Randwerte aufzeigen (siehe Kapitel 2.3.2). Gatta et al. (2023) sowie Dhiman & Hu (2023) entwickeln hierfür Architekturen, die typischerweise zwei neuronale Netze simultan trainieren: eines zur Approximation des Optionspreises und ein weiteres zur Approximation der optimalen Ausübungsgrenze. Auch pfadabhängige Optionen, wie asiatische Optionen, deren Wert nicht nur vom aktuellen Aktienpreis, sondern vom Durchschnitt des Kursverlaufs abhängt, erweisen sich PINNs als überlegen. Park, Moon & Kim (2025) zeigen, dass PINNs die zugehörige höherdimensionale PDE effizient lösen und traditionelle Monte-Carlo-Simulationen in der Prognosegüte bei gleichzeitig reduzierter rechnerischer Komplexität übertreffen. Der PDE-Term der Verlustfunktion übernimmt dabei die Rolle

eines Priors im Sinne der bayesianischen Inferenz. Er repräsentiert das im Vorfeld gegebene Wissen über die theoretische Preis- und Volatilitätsdynamik des Heston-Modells ab und stellt sicher, dass die durch das PINN erlernte Lösung nicht nur durch Daten gestützt, sondern zugleich konsistent mit dem zugrunde liegenden Modell ist. Socaciu & Pascu (2025) bestätigen ebenfalls die Eignung von PINNs zur Lösung sowohl der Black-Scholes- als auch des Heston-Modells und heben die Möglichkeit hervor, das Training über verschiedene wirtschaftliche Szenarien hinweg zu parallelisieren, was die Effizienz für die Analyse von einer Vielzahl von Optionen mit unterschiedlichen Ausübungspreisen und Laufzeiten erhöht. Hainaut & Casas (2024) entwickeln in Ihrer Arbeit ein *parametric* PINN für das Heston-Modell, das durch die Einbeziehung der Modellparameter (z.B. Volatilität, Korrelation, Mean-Reversion, etc.) eine höhere Generalisierbarkeit erreicht. Anstatt für jede Parametrisierung ein separates Training durchzuführen, werden die Parameter als zusätzlicher Input in das Netz integriert. Die zugrunde liegende PDE bleibt weiterhin als Regularisierungsterm in die Verlustfunktion eingebettet. Auf diese Weise kann ein einziges trainiertes PINN Optionen für unterschiedliche Spezifikationen der Modellparameter bewerten.

Die aufgezeigte Literatur belegt das Potenzial von PINNs als flexiblen und leistungsfähigen Ansatz zur numerischen Lösung einer Vielzahl von PDE-basierten Bewertungsproblemen in der Finanzmathematik. Der Trend geht klar von der reinen Validierung an traditionellen Modellen wie dem Black-Scholes-Modell hin zur Anwendung auf komplexe Derivate und stochastische Prozesse, wobei die Stärken des Ansatzes, insbesondere die numerische Lösung ohne explizite Raumdiskretisierung und die Skalierbarkeit in höheren Dimensionen, im Vordergrund stehen.

Die vorliegende Arbeit knüpft direkt an diesen Forschungsstand an, verfolgt jedoch eine spezifische, hybrid Zielsetzung, die sich von den bisherigen Arbeiten unterscheidet. Während die meisten Studien PINNs als reine *PDE-Solver* einsetzen, die eine bekannte Gleichung approximieren, wird in dieser Arbeit die Black-Scholes-PDE als Regularisierungsterm für ein neuronales Netz verwendet, das primär auf realen Marktdaten trainiert wird. Dieser Ansatz positioniert sich gezielt zwischen rein datengetriebenen Modellen, denen es an theoretischer Fundierung mangelt, und rein modellbasierten PINNs, die als *PDE-Solver* agieren. Das Ziel ist es, die Flexibilität des neuronalen Netzes zur Erfassung von Marktphänomenen, die vom Black-Scholes-Modell nicht abgedeckt werden (z.B. *Volatility Smile*), mit der strukturellen Konsistenz der Black-Scholes-PDE zu verbinden. Dadurch soll die Generalisierungsfähigkeit des Modells, insbesondere in datenarmen Bereichen des Optionsraums, verbessert und gleichzeitig die Einhaltung finanzmathematischer Grundprinzipien, wie der Arbitragefreiheit, die der PDE inhärent ist, eingehalten werden.

3. Methodik

Die gewählte Methodik stützt sich auf aktuelle Erkenntnisse aus der Forschung zu Physics-Informed Neural Networks (Sirignano & Spiliopoulos, 2018; Raissi et al., 2019) sowie deren Anwendung im Finanzkontext (Noguer i Alonso & Camarena, 2023). Die Einbeziehung kontinuierlicher Dividendenrendite folgt etablierten Erweiterungen des Black-Scholes-Modells (vgl. Hull, 2022, S. 360), während der Einsatz neuronaler Netze zur Optionsbewertung durch empirische Studien im Bereich Deep Learning (Liu et al., 2019; Ke & Yang, 2019) motiviert wird.

Aufbauend auf den in Kapitel 2 dargelegten theoretischen Grundlagen, die sowohl die Limitationen klassischer Bewertungsmodelle als auch die Potenziale rein datengetriebener Ansätze beleuchtet haben, widmet sich dieses Kapitel der methodischen Umsetzung der vorliegenden Arbeit. Ziel ist die Entwicklung, Implementierung und Evaluierung zweier hybriden Bewertungsmodells: PINN Call und PINN Put, welche die finanzmathematische Theorie des Black-Scholes-Modells mit der Flexibilität eines neuronalen Netzes verbinden.

Hierbei basiert die methodische Umsetzung auf dem entwickelten Framework von Raissi et al. (2019). Dieses wird jedoch nicht, wie in vielen bisherigen Arbeiten, als reiner Löser für eine bekannte Differenzialgleichung eingesetzt. Stattdessen wird in dieser Arbeit ein hybrider Ansatz verfolgt, der die Modelle primär auf Basis von historischen Daten trainiert und die Black-Scholes-PDE (2.12) als Regularisierungsterm inkl. seiner Randbedingungen in die Verlustfunktion integriert. Damit positioniert sich die Methodik gezielt zwischen rein datengetriebenen Modellen, denen es an theoretischer Fundierung mangelt, und rein modellbasierten PINNs, die als reine *PDE-Solver* agieren.

Konkret wird das Problem der Optionsbewertung als *Inverses Problem* formuliert: Die implizite Volatilität σ wird nicht als externer, gegebener Parameter behandelt, sondern als zusätzliche Ausgabegröße approximiert. Die Modelle lernen somit nicht nur eine Preisoberfläche $V(S, t)$, die mit den historischen Daten konsistent ist, sondern inferieren gleichzeitig jene Volatilität, die den Gesamtfehler aus der Diskrepanz zu den beobachteten Preisen und dem Residuum der Black-Scholes-PDE minimiert. Dieser Ansatz soll die Flexibilität der Modelle zur Erfassung von Marktphänomenen (z.B. *Volatility Smile*), die vom klassischen Black-Scholes-Modell nicht abgedeckt werden, mit der strukturellen Konsistenz der Black-Scholes-PDE verbinden und so die Generalisierungsfähigkeit, insbesondere in datenarmen Bereichen, verbessern.

Zur systematischen Darstellung des Vorgehens ist dieses Kapitel in drei Unterkapitel unterteilt. Zunächst wird in Kapitel 3.1 die Datengrundlage detailliert beschrieben und der Prozess der Datenaufbereitung (*Data Preprocessing*) erläutert. Anschließend wird in Kapitel 3.2 eine Explorative Datenanalyse (EDA) durchgeführt, um den Datensatz und dessen Variablen sowie deren Korrelationen untereinander detailliert zu untersuchen. Der Kapitel 3.3 widmet sich der spezifischen Modellarchitektur, einschließlich der Struktur des neuronalen Netzes und der Gestaltung der hybriden Verlustfunktion. Abschließend werden in Kapitel 3.4 die Trainingskonfigurationen, die verschiedenen Trainingsvarianten sowie die

gewählten Hyperparameter spezifiziert.

3.1. Datengrundlage und Data-Preprocessing

Die empirische Grundlage der vorliegenden Arbeit bilden historische Marktdaten für europäische Optionen auf den S&P 500 Index (SPX). Der Datensatz wurde über den LSEG Workspace (ehemals Refinitiv Eikon) bezogen und umfasst den Zeitraum von Januar 2019 bis Januar 2024. Die Auswahl dieses Zeitraums ermöglicht die Untersuchung des Modells über verschiedene Marktphasen hinweg, einschließlich Perioden hoher Volatilität (z.B. während der COVID-19-Pandemie) und Phasen relativer Stabilität.

3.1.1. Beschreibung des Datensatzes

Der Datensatz enthält Transaktionsdaten für S&P 500 Optionen und umfasst sowohl Call- als auch Put-Optionen mit einer Vielzahl von Ausübungspreisen und Fälligkeitsterminen. Jede Beobachtung im Datensatz repräsentiert eine gehandelte Option an einem spezifischen Handelstag und enthält die folgenden, für die Modellierung relevanten Variablen:

Variable	Beschreibung
Basispreis (S)	Basispreis des S&P 500 Index zum Beobachtungszeitpunkt
Ausübungspreis (K)	Vertraglich festgelegter Ausübungspreis der Option
Restlaufzeit (t)	Restlaufzeit der Option in Jahren ($T - t$)
Risikofreier Zinssatz (r)	Risikofreier Zinssatz (US-Staatsanleihen mit entsprechender Laufzeit)
Dividende (q)	Kontinuierliche Dividendenrendite des S&P 500 Index
Implizite Volatilität (σ_{imp})	Implizite Volatilität, aus Marktpreisen ermittelt
Optionstyp	Call- oder Put-Option (kategoriale Variable)
Optionspreis (V_{market})	Marktpreis der Option (Zielvariable für die Modellierung)
Optionsvolumen	Handelsvolumen der Option pro Handelstag (Liquiditätsindikator)

Tabelle 1: Übersicht der im Datensatz enthaltenen Variablen für S&P 500 Optionen

3.1.2. Datenbereinigung und Feature Engineering

Das Ziel der Datenfilterung in der quantitativen Modellierung ist die Erstellung eines bereinigten und konsistenten Datensatzes, der sowohl mit den theoretischen Annahmen des genutzten Bewertungsmodells als auch mit den praktischen Gegebenheiten des Marktes im Einklang steht. Fehlerhafte Daten im vorliegenden Kontext umfassen typischerweise Daten von illiquiden Instrumenten, eindeutiger Erfassungsfehler oder Daten aus Marktphasen, in denen die Modellannahmen nachweislich nicht mehr gelten. Die folgende Sequenz von

Filtern ist darauf ausgelegt, diese problematischen Daten gezielt zu entfernen, während qualitativ hochwertige Informationen, einschließlich Daten aus Hochvolatilitätsphasen, wie dem COVID-19-Crash, erhalten bleiben.

- Liquiditätsfilter: Optionen mit sehr geringem Handelsvolumen sind oft nicht repräsentativ. Ihr Preis kann veraltet sein oder auf einem sehr weiten *Spread* beruhen, was bedeutet, dass der erfasste Preis nicht den tatsächlichen Preis widerspiegelt. Daher werden alle Optionen mit einem Volumen weniger als zehn entfernt.
- Restlaufzeitsfilter: Die Preisdynamik von Optionen mit extrem kurzer Restlaufzeit ($t < 1,5$ Tage) wird zunehmend erratisch und verletzt die Stetigkeitsannahme der Black-Scholes-PDE. Langlaufende Optionen ($t > 3$ Monate) unterliegen komplexeren Einflüssen wie nicht konstanten Zinssätzen. Um ein stabiles und liquides Umfeld zu schaffen, in dem die Black-Scholes-PDE am besten anwendbar ist, wird der Datensatz auf Optionen mit einer Restlaufzeit zwischen 1,5 Tagen (0.004 Jahren) und drei Monaten (0.25 Jahren) beschränkt.
- Moneyness-Filter: Die Moneyness (S/K) ist ein zentraler Preisfaktor. Optionen, die *im Geld (ITM)* oder *aus dem Geld (OTM)* sind, sind meist illiquide. Um die Modelle auf den Großteil der relevanten Marktaktivitäten zu fokussieren, ohne sich in die veranschaulichten Extreme zu begeben, wird ein breiter *Moneyness*-Bereich von $[0.5; 1.5]$ beibehalten. Optionen, die um eine Moneyness von 1,0 gruppiert sind, werden als *am Geld (ATM)* Optionen bezeichnet. Dies stellt sicher, dass die volle Krümmung des *Volatility Smiles* für die Modellierung erfasst wird.
- Filterung numerischer Artefakte: Ein einfacher Schwellenwert für die implizite Volatilität würde legitime Daten aus Krisenzeiten (z.B. COVID-19-Crash) fälschlicherweise entfernen. Stattdessen wird ein gezielter Filter angewendet, der Datenpunkte nur dann entfernt, wenn eine Kombination aus drei Signalen vorliegt: eine extrem hohe implizite Volatilität ($\sigma_{imp} > 120$ %), eine extrem kurze Restlaufzeit ($t < 0.01$ Jahre, ca. 3,5 Tage) und eine extreme *Moneyness* ($S/K < 0.8$ oder $S/K > 1.2$). Diese spezifische Konstellation führt zu numerischen Instabilität bei der Rückrechnung der Impliziten Volatilität aus dem Optionspreis und erzeugt dadurch bedeutungslose Werte, die keine verwendbaren Marktdaten darstellen.

Ferner wird zur strukturierten Kategorisierung unterschiedlicher Marktphasen ein regelbasierter Filter implementiert, der auf der impliziten Volatilität σ_{imp} basiert. Die Volatilität dient hierbei als Indikator für das erwartete Marktrisiko und die Unsicherheit über zukünftige Preisbewegungen. Der Filter teilt den Datensatz in drei Regime ein: *Low Volatility*, *Normal Volatility* und *High Volatility*. Die Klassifikation erfolgt durch die Bestimmung quantilbasierter Schwellenwerte, wobei das 25%-Quantil als untere Grenze und das 75%-Quantil als obere Grenze definiert werden. Werte oberhalb des oberen Schwellenwerts werden als *High Volatility* interpretiert, Werte unterhalb des unteren Schwellenwerts als *Low Volatility*, und Werte dazwischen als *Normal Volatility*. Die Einteilung ermöglicht es, verschiedene Marktbedingungen systematisch zu identifizieren und als erklärende Variable

für die Beantwortung der Forschungsfrage (FQ3) berücksichtigt.

Zur weiteren Differenzierung der Charakteristika von Optionen wurde eine Kategorisierung auf Basis der Moneyness vorgenommen. Hierbei wird die kontinuierliche Variable der Moneyness (S/K) in drei diskrete Kategorien überführt: *im Geld (ITM)*, *am Geld (ATM)* und *aus dem Geld (OTM)*. Dabei erfolgt die Zuordnung anhand vordefinierter Schwellenwerte: Werte größer als 1,03 werden als *ITM* klassifiziert, Werte im Intervall $[0,97; 1,03]$ als *ATM*, und Werte kleiner 0,97 als *OTM*.

Um die Konvergenz während des Trainings der Modelle zu verbessern und numerische Instabilitäten zu vermeiden, werden die numerischen Eingabevariablen (S, K, t, r, q) mittels einer Min-Max-Skalierung auf den Bereich $[-1; +1]$ normalisiert. Diese Transformation ist eine gängige Praxis, um sicherzustellen, dass alle Eingabevariablen in einem ähnlichen Wertebereich liegen, was den Optimierungsprozess erleichtert. Mathematisch lässt sich die Skalierung für einen beliebigen Wert X eines Features wie folgt darstellen:

$$X_{norm} = 2 * \frac{X - X_{min}}{X_{max} - X_{min}} - 1 \quad (3.1)$$

Hierbei sind X_{min} und X_{max} der minimale bzw. maximale Wert des Features im Trainingsdatensatz.

Der aufbereitete Datensatz wird Trainings-, Validierungs- und Testdaten im Verhältnis 80/10/10 aufgeteilt. Diese Aufteilung ermöglicht eine robuste Validierung der Modelle, wobei der Validierungsdatensatz zur Hyperparameteroptimierung und der Testdatensatz zur abschließenden Evaluation der Modelle verwendet wird. Die Stratifizierung erfolgt dabei nach dem zuvor gebildeten Moneyness-Klassifizierung (*ITM*, *ATM*, *OTM*). Durch diese Vorgehensweise wird sichergestellt, dass das proportionale Verhältnis der verschiedenen Kategorien in allen Teilmengen des Datensatzes erhalten bleibt und die Modelle repräsentativ trainiert sowie evaluiert werden können.

3.1.3. Quantitative Beschreibung des Datensatzes

Nach Anwendung der in Kapitel 3.1.2 beschriebenen Filter und Aufbereitungsschritte umfasst der finale Datensatz 206.553 Beobachtungen. Dieser bereinigte Datensatz bildet die empirische Grundlage für das Training und die Evaluation der Modelle. Eine quantitative Übersicht der zentralen Variablen liefert Tabelle 2:

Anhand der aufgezeigten Kennzahlen wird bereits die Heterogenität des Datensatzes ersichtlich. Der mittlere Optionspreis V_{market} liegt bei etwa 58,78 USD und steht einem Median von 9,40 USD gegenüber. In Verbindung mit der hohen Standardabweichung von 138,01 indiziert dies eine signifikante Rechtsschiefe der Preisverteilung. Diese Eigenschaft ist charakteristisch für die vorliegenden Finanzderivate und resultiert aus einer geringen Anzahl von Optionen mit hohem inneren Wert, sprich *ITM* Optionen die den Mittelwert überproportional beeinflussen.

Variable	Mean	Std	Min	25%	50%	75%	Max
V_{market}	58,78	138,01	0,01	1,52	9,40	53,30	2.284,87
S	3.964,66	908,37	2.237,40	3.135,96	3.940,59	4.496,19	6.090,27
K	3.759,12	986,31	1.800,00	2.920,00	3.720,00	4.450,00	6.000,00
t	0,072	0,049	0,005	0,038	0,066	0,093	0,249
σ_{imp}	27,25	16,56	2,92	15,66	22,76	33,88	183,84
r	2,48	2,10	-0,05	0,13	2,16	4,75	5,52
q	2,09	0,33	1,49	1,82	2,10	2,33	3,44
S/K	1,073	0,142	0,546	0,982	1,034	1,150	1,500

Tabelle 2: Deskriptive Statistik des bereinigten S&P 500 Optionsdatensatzes (Zeitraum: 2019-2024)

Die weiten Wertebereiche des Basispreises S und des Ausübungspreises K reflektieren die hohe Volatilität und die dynamische Preisbewegung während des Beobachtungszeitraums. Mit einer durchschnittlichen Restlaufzeit t von 0,072 Jahren (ca. 26 Tage) liegt der Schwerpunkt des Datensatzes auf kurzfristige Optionen. Eine erhebliche Varianz zeigt sich bei der impliziten Volatilität σ_{imp} und dem risikofreien Zinssatz r . Die Moneyness (S/K), dessen Mittelwert bei 1,073 liegt, zeigt eine Konzentration von Optionen im *ATM* Bereich.

Zusammenfassend lässt sich bereits festhalten, dass der Datensatz eine robuste und vielfältige Grundlage für die Modellierung darstellt. In den folgenden Kapiteln wird der Datensatz im Rahmen einer explorativen Datenanalyse detaillierter untersucht.

3.2. Explorative Datenanalyse

Ziel der explorativen Datenanalyse (EDA) ist es, durch deskriptive Statistiken (siehe Tabelle 2) und Visualisierungen ein tiefergehendes Verständnis für die zugrunde liegende Datenstrukturen, Verteilungen und potenzielle Zusammenhänge zwischen den Variablen zu entwickeln.

3.2.1. Univariate Datenanalyse

Die univariate Analyse konzentriert sich auf die Untersuchung der Verteilung einzelner, für die Optionsbewertung zentraler Variablen. Durch die Betrachtung von Histogrammen sowie der statistischen Kennzahl für Schiefe (*Skewness*) und Wölbung (*Kurtosis*) können Abweichungen von der Normalverteilung identifiziert und ökonomisch interpretiert werden. Im Folgenden werden zunächst die Verteilungen des Optionspreises V_{market} , der impliziten Volatilität σ_{imp} und der Moneyness (S/K) detailliert analysiert, bevor die weiteren Variablen zusammenfassend betrachtet werden.




Abbildung 3: Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.

Die Verteilung der Optionspreise V_{market} , dargestellt im oberen Teil von Abbildung 1, zeigt eine ausgeprägte rechtsschiefe Verteilung. Diese Beobachtung wird durch die in Tabelle 2 untermauert. Der Mittelwert von 58,78 USD liegt weit über dem Median von 9,40 USD. Ein *Skewness* von 5,23 signalisiert eine starke Asymmetrie nach rechts. Die *Kurtosis* von 37,17 (deutlich größer als 3) deutet auf eine stark leptokurtische Verteilung hin. Das bedeutet, die Verteilung hat einen spitzeren Gipfel und wesentlich schwerere Ränder (*heavy tails*) als eine Normalverteilung. Dieses Muster ist typisch für solche Finanzderivate. Der Großteil von Optionen, insbesondere *OTM* Optionen, besitzt einen geringen Preis und konzentriert sich nahe null. Eine kleine Anzahl von Optionen, vorliegend *ATM* Optionen, weist hingegen sehr hohe Preise auf und bildet den langen rechten Rand der Verteilung.

Auch die Verteilung der impliziten Volatilität σ_{imp} ist, wie im mittleren Teil von Abbildung 1 ersichtlich, rechtsschief. Die *Skewness* von 1,94 bestätigt die visuelle Beobachtung. Ein Großteil der Werte sind im unteren Bereich zwischen 10 % und 30 % angesiedelt, was normale Marktphasen repräsentiert. Ein *Kurtosis* von 5,90 weist ebenfalls eine leptokurtische Verteilung hin. Ereignisse, die zu extremer Volatilität führen, treten in den Daten häufiger auf, als es eine Normalverteilung vorhersagen würde. Die Verteilung spiegelt ein

bekanntes Phänomen an den Finanzmärkten wider: Phasen moderater Volatilität werden von selteneren, aber heftigen Volatilitätsspitzen unterbrochen (sog. *Volatility Clustering*). Der lange rechte Rand der Verteilung repräsentiert Stressphasen wie den Covid-19-Crash im Jahr 2020.

Im Gegensatz zu den anderen beiden Variablen ist die Verteilung der Moneyness (unterer Teil von Abbildung 1) annähernd symmetrisch. Der Verteilungsschwerpunkt liegt nahe dem Wert 1,0, was *ATM* Optionen entspricht. Die geringe *Skewness* von 0,79 deutet auf eine leichte Asymmetrie nach rechts hin. Die *Kurtosis* von 0,43 charakterisiert eine platykurtische Verteilung. Dies bedeutet, dass die Verteilung flacher ist und leichtere Ränder als eine Normalverteilung aufweist. Die platykurtische Form zeigt, dass die Daten eine hohe Konzentration von *ATM* Optionen aufweisen, wo das Handelsvolumen am höchsten ist. Die Strategie zur Filterung der Daten aus Kapitel 3.1.2 hat erfolgreich den relevantesten Bereich des Optionsmarktes erfasst.

Die Verteilung der Restlaufzeit t ist auf den Bereich von 1,5 Tagen bis zu 3 Monaten (0,005 bis 0,249 Jahren) beschränkt. Der Mittelwert liegt leicht über dem Median (0,066), was auf eine leichte Rechtsschiefe hindeutet. Der Einheitskurs S und Ausübungspreis K weisen beide eine breite Wertespanne auf, die die Entwicklung des S&P 500 Index von ~ 2.237 bis ~ 6.090 Punkten im Beobachtungszeitraum widerspiegelt. Ihre Verteilung sind nicht normal, sondern spiegeln die Trends und Niveaus des Marktes über die Jahre 2019 bis 2024 wider. Der Risikofreie Zinssatz r erstreckt sich von negativen Werten (-0,05 %) bis zu einem Maximum von 5,52 %. Dies illustriert die unterschiedlichen wirtschaftspolitischen Maßnahmen im Beobachtungszeitraum. Ähnlich dem Optionspreis ist das Optionsvolumen extrem rechtsschief. Während der Filter ein Mindestvolumen von 10 sicherstellt (siehe Kapitel 3.1.2), liegt der Median bei 99, der Mittelwert jedoch bei rund 710.




Abbildung 4: Boxplots der Verteilung von Optionspreis V_{market} , impliziter Volatilität σ_{imp} und Moneyness (S/K)

Die Abbildung 4 visualisiert die Verteilungen der drei zentralen Variablen Optionspreis V_{market} , implizite Volatilität σ_{imp} und Moneyness (S/K). Der Optionspreis V_{market} ist, wie auch schon zuvor festgestellt, stark rechtsschief, weshalb die y-Achse logarithmisch skaliert ist. Der Median liegt bei ca. 10^1 . Auffällig ist jedoch die sehr hohe Dichte an Ausreißern am oberen Ende der Verteilung, die Werte bis über 10^3 erreichen und auf eine randlastige Verteilung (*fat tails*) hindeutet.

Auch die Verteilung der impliziten Volatilität σ_{imp} ist stark rechtsschief. Während der Median bei ca. 0,25 (25 %) liegt und die zentrale Hälfte der Daten eng gestreut ist, zeigt sich eine extrem hohe Anzahl an Ausreißern mit Werten bis über 1,75 (175 %). Dies unterstreicht das Vorhandensein von Phasen extremer Volatilität im Datensatz.

Die Verteilung der Moneyness (S/K) ist um den Wert 1,0, sprich um den ATM-Bereich, zentriert. Im Gegensatz zu den anderen Variablen treten hier Ausreißer an beiden Enden auf. Es zeigt sich eine dichte Ansammlung von *ITM* Optionen (S/K bis ca. 0,55), sowie mehrere Ausreißer von *OTM* Optionen (S/K bis ca. 1,5) repräsentieren.

3.2.2. Zeitreihenanalyse

Um die dynamischen Marktbedingungen des Beobachtungszeitraums zu verstehen, wird nach der statistischen, univariaten Analyse die zeitliche Entwicklung des Basispreis S des S&P 500 Index sowie der durchschnittlichen täglichen impliziten Volatilität σ_{imp} untersucht. Abbildung 2 visualisiert diese beiden zentralen Zeitreihen.




Abbildung 5: Verlauf des S&P 500-Index (oben) und der durchschnittlichen impliziten Volatilität (unten) von 2019 bis Ende 2024. Der schattierte Bereich markiert den COVID-19-Crash Anfang 2020, in dem ein starker Kurseinbruch und ein sprunghafter Anstieg der Volatilität zu beobachten sind.

Der Basispreis S zeigt über den gesamten Zeitraum eine überwiegend positiven Trend, der jedoch von signifikanten Korrekturen unterbrochen wird. Besonders markant ist der Crash im März 2020 zu Beginn der COVID-19-Pandemie, gefolgt von einer V-förmigen Erholung und einem starken Bullenmarkt bis Ende 2021. Das Jahr 2022 war hingegen von einem Bärenmarkt geprägt, ausgelöst durch Inflationssorgen und steigenden Zinsen.




Abbildung 6: Zeitreihe der Veränderungen der impliziten Volatilität σ_{imp} von 2019 bis Ende 2024. Die Darstellung zeigt kurzfristige Schwankungen und Volatilitätsspitzen.

Die implizite Volatilität σ_{imp} verhält sich antizyklisch zum Aktienmarkt. In Phasen steigender Kurse und geringer Unsicherheit bewegt sich die Volatilität auf einem niedrigen Niveau. In Krisenzeiten explodiert sie förmlich, wie der Peak im März 2020 mit Werten von über 80 % zeigt. Dieses als *Volatility Clustering* bekannte Phänomen widerlegt die Annahme einer konstanten Volatilität fundamental, wie sie das Black-Scholes-Modell annimmt (siehe Kapitel 2.1.2).

3.2.3. Bivariate Datenanalyse

Nach der isolierten Betrachtung der einzelnen Variablen widmet sich die bivariate Analyse den linearen Beziehungen zwischen den Variablenpaaren. Zur Quantifizierung der Zusammenhänge wird die Pearson-Korrelationsmatrix herangezogen, die in Abbildung 3 visualisiert ist. Die Koeffizienten reichen von -1 (perfekter negativer linearer Zusammenhang) bis +1 (perfekter positiver linearer Zusammenhang).




Abbildung 7: Korrelationsmatrix der Optionsvariablen. Dargestellt sind die linearen Zusammenhänge zwischen Optionspreis, Moneyness, Restlaufzeit, impliziter Volatilität, Basispreis, Ausübungspreis, risikofreiem Zinssatz, Dividende und Optionsvolumen. Starke positive und negative Korrelationen heben Beziehungen zwischen Preisparametern und Marktfaktoren hervor.

Die Analyse der Korrelationsmatrix offenbart mehrere ökonomische plausible und für die Modellierung relevante Zusammenhänge. Die linearen Korrelationen zum Optionspreis V_{market} sind insgesamt schwach, was die stark nicht-lineare Eigenart der Optionspreisbildung widerspiegelt. Die Restlaufzeit weist mit +0,14 die stärkste positive Korrelation zum Optionspreis auf. Eine längere Restlaufzeit führt tendenziell zu einem höheren Optionspreis. Andere zentrale Faktoren wie die implizite Volatilität σ_{imp} (+0,07) oder der Basispreis (+0,06) zeigen eher schwache lineare Korrelationen zum Optionspreis V_{market} .

Anders verhält es sich zwischen der impliziten Volatilität σ_{imp} und der Moneyness. Hier liegt eine starke positive Korrelation von +0,61 vor. Dieser Wert deutet auf eine komplexe Volatilitätsstruktur hin, und zeigt auf, dass *ITM* Optionen, sprich Optionen, die weit im Geld sind, tendenziell eine höhere implizite Volatilität aufweisen als Optionen nahe am Geld (*ATM*). Weiterhin zeigt sich eine moderate negative Korrelation zum Ausübungspreis

K . Wenn der Ausübungspreis K tendenziell steigt, sinkt die implizite Volatilität σ_{imp} tendenziell, und umgekehrt. Die hier aufgezeigte negative Korrelation von -0,45 ist der numerische Ausdruck für die theoretische Definition des *Volatility Skew*, welche in Kapitel 2.1.2 erörtert wurde.

Die sehr starke positive Korrelation zwischen dem Basispreis S und dem Ausübungspreis K (+0,88) ist strukturell bedingt. Wenn der Basispreis über einen längeren Zeitraum steigt, verlagert sich der Handel in höhere Preisregionen und neue liquide Optionen gruppieren sich um den jeweils aktuellen Basispreis. Eine ausgeprägte negative Korrelation besteht zwischen dem Basispreis S und der Dividendenrendite q (-0,93). Dies ist ökonomisch plausibel, da die Dividendenrendite (Dividende geteilt durch den Basispreis) bei steigenden Kursen sinkt. Der risikofreie Zinssatz r korreliert positiv mit dem Basispreis S (+0,54), was die makroökonomische Entwicklung im Beobachtungszeitraum widerspiegelt.

Wird der Optionspreis V_{market} und seine wesentlichen Treiber detaillierter betrachtet, werden die nicht-linearen Beziehungen, die bereits durch die Korrelationsmatrix offenbart wurden, noch deutlicher. Abbildung 4 visualisiert diese Beziehungen mittels Streudiagrammen und unterscheidet dabei zwischen Call- (blau) und Put-Optionen (rot).




Abbildung 8: Zusammenhang zwischen Optionspreis V_{market} und zentralen Einflussgrößen für Call- (blau) und Put-Optionen (rot). Gezeigt sind die Beziehungen zu Moneyness (links), Restlaufzeit t (Mitte) und impliziter Volatilität σ_{imp} (rechts). Die logarithmische Skalierung verdeutlicht die Preisunterschiede über mehrere Größenordnungen hinweg.

Die Darstellung links (Optionspreis V_{market} vs. Moneyness (S/K)) verdeutlicht die fundamentale, konvexe Preisstruktur von Optionen. Für Call-Optionen steigt der Preis mit zunehmender Moneyness. Für *OTM* Optionen (Moneyness < 1) ist der Optionspreis V_{market} niedrig und besteht nur aus dem Zeitwert. Sobald die Option in den *ATM* Bereich kommt (Moneyness > 1), steigt der Optionspreis V_{market} an und nähert sich einer linearen Beziehung an, die durch den intrinsischen Wert dominiert wird. Für Put-Optionen ist das Verhalten spiegelbildlich. Der Optionspreis V_{market} ist am höchsten für Optionen, die im *ITM* Bereich sind und fällt mit steigender Moneyness rapide ab, bis er sich dem reinen Zeitwert annähert.

Die mittlere Darstellung (Optionspreis V_{market} vs. Restlaufzeit t) illustriert den Einfluss des Zeitwerts. Für beide Optionstypen ist ein positiver Zusammenhang erkennbar: Je länger die Restlaufzeit, desto höher ist tendenziell der maximale Optionspreis, da mehr Zeit für

eine vorteilhafte Entwicklung des Basispreises verbleibt und die Unsicherheit größer ist. Jedoch sind vorliegend die Punkte sehr breit gestreut. Dies zeigt, dass die Restlaufzeit allein nur eine begrenzte Erklärungskraft besitzt und ihr Einfluss stark von der Moneyness der Option abhängt. *ITM* Optionen und *OTM* Optionen haben einen geringeren Zeitwert als *ATM* Optionen.

Die rechte Darstellung (Optionspreis V_{market} vs. implizite Volatilität σ_{imp}) zeigt den Einfluss der erwarteten Schwankungsbreite. Auch hier ist ein klarer positiver Trend für Call- und Put-Optionen zu beobachten. Eine höhere implizite Volatilität σ_{imp} führt zu höheren Optionspreisen V_{market} , da die Wahrscheinlichkeit extremer Entwicklungen des Basispreises S zunimmt. Ähnlich wie bei der Restlaufzeit t ist die Streuung der Punkte erheblich. Der Einfluss der impliziten Volatilität σ_{imp} ist für *ATM* Optionen am stärksten ausgeprägt, was die große Preisspanne bei mittleren Volatilitätswerten erklärt.

3.3. Modellarchitektur des PINNs

Die Architektur des in der vorliegenden Arbeit entwickelten hybriden Modells zur Approximation von Optionspreisen basiert auf den in Kapitel 2.2.1 und Kapitel 2.3.2 erörterten Grundlagen neuronaler Netze und PINNs. Die Basis bildet dabei ein neuronales Netz, das nicht nur aus realen Marktdaten (siehe Tabelle 2) lernt, sondern zusätzlich durch die Black-Scholes-PDE (2.12) physikalisch regularisiert wird. Dieser hybride Ansatz zielt darauf ab, die hohe Flexibilität von neuronalen Netzen mit der theoretischen Robustheit finanzmathematischer Modelle, wie vorliegend dem Black-Scholes-Modell, zu verbinden.

Die Implementierung des grundlegenden Modells erfolgt unter Verwendung des Deep-Learning-Framework *Pytorch*. Aufgrund seiner dynamischen Berechnung der Graphen (engl. *Dynamic Computational Graph*), bei dem der gesamte Rechenablauf, wie in Kapitel 2.2 beschrieben, erst während der Programmausführung aufgebaut wird, ermöglicht *PyTorch* eine besonders effiziente *Automatic Differentiation* und bietet eine geeignete Grundlage für die Formulierung und Optimierung der komplexen Verlustfunktion des Modells.

Die Architektur lässt sich in zwei funktionale Hauptkomponenten unterteilen: Ein FNN, das als universeller Funktionsapproximator dient, um die komplexe Beziehung zwischen den Eingabevariablen und dem Optionspreis V_{market} sowie der impliziten Volatilität σ_{imp} abzubilden. Sowie eine PDE-Residual-Methode, die die Black-Scholes-PDE (2.12) als physikalischen Regularisierungsterm in die Verlustfunktion integriert. Diese Methode berechnet die für die PDE erforderlichen partiellen Ableitungen $(\frac{\partial V}{\partial t}, \frac{\partial V}{\partial S}, \frac{\partial^2 V}{\partial S^2})$ des Optionspreis $\hat{V}$ mithilfe der *Automatic Differentiation*.

Die folgende Beschreibung der Modellarchitektur orientiert sich an der zugrundeliegenden Implementierung in Python¹. Zunächst wird die Struktur des neuronalen Netzes als Funktionsapproximator erläutert, bevor im nachfolgenden Kapitel auf die Berechnung des PDE-Residuals und die Formulierung der hybriden Verlustfunktion eingegangen wird.

¹ Die Umsetzung in Python wird auf GitHub bereitgestellt: https://github.com/RitschAlex/pinn_black_scholes_pde

Im Folgenden wird zunächst ein Modell eingeführt, das später als Grundmodell für die Modelle PINN Call und PINN Put verwendet wird.

3.3.1. Struktur des neuronalen Netzes

Die Basis des Modells bildet ein MLP, wobei es sich in der vorliegenden Arbeit um eine Form des FNN, dessen theoretische Grundlagen in Kapitel 2.2.1 erläutert wurden, handelt. Das Netz ist darauf ausgelegt, die Optionspreisoberfläche $\hat{V}(S, t, K, r, q)$ und die korrespondierende implizite Volatilität $\hat{\sigma}(S, t, K, r, q)$ simultan zu approximieren.

Die Architektur des Netzes ist spezifisch auf die Problemstellung der Optionspreisbewertung ausgelegt. Der *Input Layer* des Netzes verarbeitet fünf zentrale finanzmathematische Variablen (siehe Tabelle 1), die einen Optionsschein definieren: den aktuellen Basispreis S_t , den Ausübungspreis K , die Restlaufzeit in Jahren t , den risikofreien Zinssatz r und die Dividende q .

Während ähnliche Arbeiten (Dhiman & Hu, 2023; Socaciu & Pascu, 2025) das klassische Black-Scholes-Modell anwenden und folglich die Dividende q auslassen, wird in der vorliegenden Arbeit diese Variable aktiv in die Optionspreisbewertung einbezogen. Dies hat zum Vorteil, dass mit der Dividende q der Effekt von Dividendenzahlungen korrekt eingepreist wird. Zudem wird in den zuvor genannten Arbeiten der risikofreie Zinssatz r sowie die Volatilität σ als Konstant angesehen, was ebenfalls der Annahme des klassischen Black-Scholes-Modells entspricht. Vorliegend wird der zum Transaktionsdatum der jeweiligen Option aktuelle *US 3-Month Treasury Bill* herangezogen, welcher als risikofreie, liquide und marktübliche Benchmark angesehen werden darf. Hinsichtlich der Variablen σ wurde bereits in Kapitel 2.3.3 wie auch zu Beginn dieses Kapitel erörtert, dass die Volatilität als Inverses-Problem behandelt und durch das Netz selber approximiert wird.

Die *Input Layer* besteht folglich aus fünf Neuronen und denkt die Eingabevariablen (S, K, t, r, q) ab. Bevor dem Netz die zuvor genannten Variablen jedoch zugeführt werden, werden diese durch Min-Max-Skalierung (3.1) normalisiert, um die Konvergenz während des Trainings zu beschleunigen und zu stabilisieren.

Die *Output Layer* ist so konzipiert, dass diese zwei voneinander abhängige Größen prognostiziert: den Optionspreis $\hat{V}$ und die Volatilität $\hat{\sigma}$. Dieser Ansatz ermöglicht es dem Netz, komplexe Phänomene wie den *Volatility Smile* implizit zu erfassen. Die *Output Layer* besteht demnach aus zwei Neuronen.

Zwischen den *Input* und *Output Layer* befinden sich mehrere vollständig miteinander verbundene *Hidden Layer*. Die genaue Anzahl der *Layer* und Neuronen pro *Layer* sind Hyperparameter, die im Rahmen des Trainings optimiert werden, was wiederum dem Modell ermöglicht, nicht-lineare und komplexe Beziehungen in den Daten zu erkennen und zu erlernen.

Als Aktivierungsfunktion in den *Hidden Layers* wird die *Tangens Hyperbolicus* (*Tanh*) verwendet:

$$\text{Tanh}(x) = \tanh(x) = \frac{\exp(x) - \exp(-x)}{\exp(x) + \exp(-x)}. \quad (3.2)$$

Diese Funktion bildet Werte auf das Intervall $[-1; 1]$ ab und ist im Gegensatz zur Sigmoid-Funktion, deren Ausgabe immer im Bereich $[0; 1]$ liegt, um den Nullpunkt zentriert. Die Skalierung auf $[-1; 1]$ sorgt dafür, dass die Gradienten „unbiased“ sind, also nicht in eine bestimmte Richtung tendieren, wie bei der Sigmoid-Funktion. Die Gradienten können sich ungefähr ausgleichen (positive und negative Richtung) und somit ein stabileres Training und schnellere Konvergenz gewährleisten (LeCun et al., 2000). Zudem trägt dies in geringerem Maß zur Abschwächung der Gradienteninstabilität (siehe Kapitel 2.2.3), da die Ableitung der *tanh*-Funktion im Zentrum (bei $x = 0$) mit bis zu 1,0 deutlich steiler ist als die der Sigmoid-Funktion, deren maximale Steigung lediglich 0,25 beträgt.

Ferner ist diese Eigenschaft besonders vorteilhaft in Kombination mit einer Min-Max-Skalierung (3.1) der Eingabedaten auf dasselbe Intervall $[-1; 1]$, da so die Verteilung der Werte über die *Layer* hinweg konsistent gehalten wird.

Um einem instabilen Gradientenverlauf weiter entgegenzuwirken, werden die Gewichte der linearen Schichten zudem mit der *Xavier Normal Initialization* initialisiert. Diese Methode passt die anfängliche Varianz der Gewichte an die Anzahl der Neuronen der *Input* und *Output Layer* an, wodurch die Varianz der Aktivierung, also der Ausgaben des vorherigen *Layers*, über alle *Layer* hinweg weitgehend konstant bleibt (Glorot & Bengio, 2010). Auf diese Weise wird ein gleichmäßiger Informationsfluss im Netz unterstützt und das Risiko instabiler Gradienten reduziert.

Der *Output Layer* ist so konzipiert, dass er zwei voneinander abhängige Größen approximiert: den Optionspreis V und die Volatilität σ . Das Modell gibt zunächst zwei unbeschränkte Werte aus. Diese werden anschließend transformiert, um sicherzustellen, dass sie finanzmathematisch sinnvolle Werte annehmen.

Der Preis einer Option kann fundamental nicht negativ sein und darf seinen inneren Wert, der durch den Payoff (z.B. $\max(S - K, 0)$ für eine Call-Option) definiert ist, nicht unterschreiten. Um diese theoretische Untergrenze im Modell abzubilden, wird der erste Output des Netzes durch eine *Softplus*-Funktion geleitet:

$$\text{Softplus}(x) = \frac{1}{\beta} * \log(1 + \exp(\beta * x)). \quad (3.3)$$

Die Softplus gewährleistet nicht nur positive Ausgabewerte, sondern bildet zugleich eine glatte und stetig differenzierbare Approximation der *ReLU*-Funktion $\max(0, x)$. Dadurch kann sie die charakteristische „geknickte“ Struktur der Payoff-Funktion adäquat abbilden. Anschließend wird die normalisierte Ausgabe durch eine Umkehrung der ursprünglichen Skalierung (3.1), bei der die aus dem Trainingsdatensatz ermittelten Parameter, der minimale Optionspreis und die Preisspanne, verwendet werden, um den Wert auf den

ursprünglichen Preisbereich zurückzurechnen:

$$\hat{V} = \text{Softplus}(x) * (\max(V_{\text{market}}) - \min(V_{\text{market}})) + \min(V_{\text{market}}). \quad (3.4)$$

Die zweite Ausgabe, die Volatilität $\hat{\sigma}$, wird ebenfalls durch eine *Softplus*-Funktion geleitet und anschließend so skaliert, dass innerhalb eines vordefinierten, plausiblen Bereichs liegt. Hierzu werden die kleinste sowie größte implizite Volatilität σ_{imp} der historischen Marktdaten aus dem Trainingsdatensatz verwendet:

$$\hat{\sigma} = \text{Softplus}(x) * (\max(\sigma_{\text{imp}}) - \min(\sigma_{\text{imp}})) + \min(\sigma_{\text{imp}}) \quad (3.5)$$

Mit den zuvor theoretischen Definitionen lässt sich die Modellarchitektur wie folgt grafisch aufzeigen.




Abbildung 9: Architektur des PINNs bestehend aus sechs verborgenen Schichten à 148 Neuronen und Tanh-Aktivierung. Die Ausgabe wird aufgeteilt und über Softplus zu $\hat{V}$ und $\hat{\sigma}$ transformiert.

3.3.2. Gestaltung der Black-Scholes-informierten Verlustfunktion

Die Architektur eines PINNs zeichnet sich durch eine hybride Verlustfunktion aus, die das Training des Netzes bestimmt. Wie in Kapitel 2.3.2 konzeptionell eingeführt, kombiniert dieser Ansatz eine datengetriebene Komponente mit einer theoriebasierten Regularisierung. Im Kontext dieser Arbeit bedeutet dies, dass empirische Informationen aus Marktdaten mit den finanzmathematischen Black-Scholes-Modell bzw. der Black-Scholes-PDE (2.12) zu vereinen.

In der vorliegenden Implementierung wird die Gesamtverlustfunktion $\mathcal{L}_{total}$ aus zwei einzelnen Verlustfunktionen gebildet: einem zusammengesetzten datenbasierten Verlustterm $\mathcal{L}_{data}$ und einem PDE-basierten Regularisierungsterm $\mathcal{L}_{pde}$, wobei die Gewichtung des PDE-Terms über einen Hyperparameter λ_{pde} gesteuert wird:

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda_{pde} \mathcal{L}_{pde} \quad (3.6)$$

Der Term $\mathcal{L}_{data}$ aggregiert die Fehler aus allen bekannten Informationen über den Optionspreis. Er behandelt die Rand- und Endbedingungen als eine Form von exakten Daten, die das Modell ebenso erlernen muss wie die beobachteten Marktpreise. Er setzt sich aus drei teilen zusammen:

$$\mathcal{L}_{data} = \mathcal{L}_{market} + \mathcal{L}_{tc} + \mathcal{L}_{bc} \quad (3.7)$$

Die primäre Aufgabe des Modells besteht darin, die am Markt beobachteten Optionspreise V_{market} akkurat zu approximieren. Der Term $\mathcal{L}_{market}$ quantifiziert die Abweichung zwischen dem vom Netz vorhergesagten Optionspreis $\hat{V}$ und dem tatsächlichen Marktpreis Y_{market} . Hierfür wird der mittlere quadratische Fehler, der *Mean Squared Error (MSE)*, über alle N_{market} Datenpunkte des Trainingsdatensatzes verwendet:

$$\mathcal{L}_{market} = \frac{1}{N_{market}} \sum_{i=1}^{N_{market}} (\hat{V}(S_i, K_i, t_i, r_i, q_i) - V_{market})^2 \quad (3.8)$$

Die PDE allein lässt unendlich viele Lösungen zu. Die Endbedingungen (*Terminal Conditions*) definieren den Wert der Option bei Fälligkeit $t = 0$. Zu diesem Zeitpunkt entspricht der Wert dem inneren Wert, d.h. dem Payoff (siehe Kapitel 2.1.1):

$$\text{Bei Call-Optionen: } V(S, K, t = 0) = \max(S - K, 0) \quad (3.9)$$

$$\text{Bei Put-Optionen: } V(S, K, t = 0) = \max(K - S, 0) \quad (3.10)$$

Der Term $\mathcal{L}_{tc}$ stellt somit sicher, dass das Modell diese Bedingungen für eine Menge von N_{tc} Punkten X_{tc} bei $t = 0$ lernt:

$$\mathcal{L}_{tc} = \frac{1}{N_{tc}} \sum_{i=1}^{N_{tc}} (\hat{V}(S_i, K_i, t = 0, r_i, q_i) - \text{Payoff}(S_i, K_i))^2 \quad (3.11)$$

Zusätzlich werden Randbedingungen (*Boundary Conditions*) für extreme Werte des Basispreis S definiert, die ebenfalls als harte Datenpunkte in das Training einfließen:

- Für $S \rightarrow 0$: Eine Call-Option ist wertlos und somit $V(S \rightarrow 0, t) = 0$, eine Put-Option entspricht dem diskontierten Ausübungspreis $V(S \rightarrow 0, t) = Ke^{-rt}$;
- Für $S \rightarrow \infty$: Eine Call-Option konvergiert gegen den diskontierten Ausübungspreis $V(S \rightarrow \infty, t) = Se^{-qt} - Ke^{-rt}$, eine Put-Option wird wertlos und folglich $V(S \rightarrow \infty, t) = 0$.

Diese Bedingungen werden in einem gemeinsamen Term $\mathcal{L}_{bc}$ über eine Menge N_{bc} speziell generierte Punkte X_{bc} an den Rändern des Definitionsbereichs von S zusammengefasst und die Abweichung zwischen dem vom Modell approximierten Optionspreis $\hat{V}$ und dem analytisch erwarteten Grenzwert V_{bc} minimiert:

$$\mathcal{L}_{bc} = \frac{1}{N_{bc}} \sum_{i=1}^{N_{bc}} (\hat{V}(S_i, K_i, t_i, r_i, q_i) - V_{bc}(S_i, K_i, t_i, r_i, q_i))^2 \quad (3.12)$$

Die entscheidende Komponente ist jedoch der Term $\mathcal{L}_{pde}$, die das Netz „physical-informed“ macht. Hierdurch wird die vom Modell approximierte Funktion $\hat{V}$ gezwungen, die Black-Scholes-PDE (2.12) zu erfüllen. Wie in Kapitel 2.1.2 hergeleitet und für die Restlaufzeit t formuliert, wird das Residuum f der PDE definiert als:

$$f(S, K, t, r, q) := \frac{\partial \hat{V}}{\partial t} - (r - q)S \frac{\partial \hat{V}}{\partial S} - \frac{1}{2} \hat{\sigma}^2 S^2 \frac{\partial^2 \hat{V}}{\partial S^2} + r\hat{V} \quad (3.13)$$

Der Term $\mathcal{L}_{pde}$ minimiert den mittleren quadratischen Fehler des Residuums über eine Menge von N_{colloc} Kollokationspunkten X_{colloc} , die im Lösungsraum verteilt sind:

$$\mathcal{L}_{pde} = \frac{1}{N_{colloc}} \sum_{i=1}^{N_{colloc}} |f(S_i, K_i, t_i, r_i, q_i)|^2 \quad (3.14)$$

Die partiellen Ableitungen werden dabei mittels *Automatic Differentiation* berechnet (siehe Kapitel 2.3.3).

3.3.3. Sampling der Rand-, End- und Kollokationspunkte

Wie zuvor dargestellt, aber auch in Kapitel 2.3.2 erörtert, basiert das Training eines PINNs auf einer hybriden Verlustfunktion, die sich aus mehreren Komponenten zusammensetzt. Jede dieser Komponenten erfordert eine spezifische Art von Trainingsdaten, um das PINN sowohl an die empirischen Marktpreise als auch an die zugrunde liegende Theorie, repräsentiert durch die Black-Scholes-PDE (2.12), anzupassen. Das Sampling dieser Punkt ist daher ein entscheidender Schritt, der die Konvergenz und die Generalisierungsfähigkeit des Modells maßgeblich beeinflusst. In diesem Abschnitt wird die methodische Vorgehensweise zur Generierung der Kollokationspunkte, der Punkte für die Endbedingungen (*Terminal Condition*) sowie der Punkte für die Randbedingungen (*Boundary Conditions*) aufgezeigt.

Kollokationspunkte erzwingen die Einhaltung der Black-Scholes-PDE (2.12) im Inneren des Lösungsraums. An diesen synthetisch erzeugten Punkten $X_C = S, K, t, r, q$ wird das Residuum der PDE minimiert, ohne dass ein empirischer Optionspreis bekannt sein muss.

Ein rein zufällig, uniforme Stichprobe aus dem gegebenen Parameterraum wäre ineffizient. Bestimmte Bereiche, wie Optionen *am Geld*, bei denen der Basispreis S nahe am Ausübungspreis K liegt, sind für die Preisdynamik besonders wichtig, da hier die Empfindlichkeit gegenüber Kursänderungen am höchsten ist (vgl. Hull, 2022, S. 430). Um die Performance des Trainings in diesem kritischen Bereich zu erhöhen, wird eine stratifizierte Sampling-Strategie verfolgt.

Zunächst wird ein vordefinierter Anteil von 25 % der Kollokationspunkte gezielt im Bereich von *ATM* Optionen generiert. Dies geschieht, indem die Moneyness (S/K) in einem engen Intervall um 1, konkret im Bereich $[0,97;1,03]$, gesampelt wird. Dies stellt sicher, dass die Modelle in diesem kritischen Bereich ausreichend „physikalisch“ informiert werden.

Die verbleibenden 75 % der Punkte werden so generiert, dass ihre Verteilung die strukturellen Eigenschaften der realen Marktdaten widerspiegelt. Anstatt einer gleichverteilten Moneyness wird für jeden Punkt i eine zunächst standardisierte Zufallsvariable $u_M^{(i)}$ aus einer Gleichverteilung gezogen:

$$u_M^{(i)} \sim U(0, 1) \quad (3.15)$$

Die Moneyness M^i jedes Punktes ergibt sich anschließend durch eine einfache Transformation dieser Zufallsgröße:

$$M^i = M_{min} + (M_{max} - M_{min}) \cdot \left(u_M^{(i)}\right)^{M_{skew}} \quad (3.16)$$

wobei M_{min} und M_{max} die unteren bzw. oberen Grenzen der Moneyness darstellen und der Parameter $M_{skew} > 1$ die Verzerrung der Verteilung bestimmt.

Dieser Ansatz gewährleistet, dass die erzeugten Kollokationspunkte eine Streuung aufweisen, die der empirischen Volatilität der Marktdaten entspricht. Dadurch werden die Modelle insbesondere in jeden Regionen des Parameterraums trainiert, in denen in der Realität das höchste Handelsvolumen beobachtet wird. Da Optionen mit kürzerer Laufzeit häufiger gehandelt werden (siehe Tabelle 2), wird die Restlaufzeit $t = T - t$ ebenfalls nicht gleichverteilt, sondern mittels Transformation innerhalb der vorgegebenen Grenzen t_{max} und t_{min} gesampelt. Zunächst wird eine Zufallsgröße für jeden Punkt i aus einer Gleichverteilung gezogen $u_t^{(i)} \sim U(0, 1)$, und die Restlaufzeit t anschließend durch

$$t = t_{min} + (t_{max} - t_{min}) \cdot \left(u_t^{(i)}\right)^{T_{skew}} \quad (3.17)$$

definiert. Diese Transformation erhöht die Dichte der Kollokationspunkte für kurze Restlaufzeiten innerhalb des zulässigen Wertebereichs $[t_{min}; t_{max}]$ und führt dazu, dass beide Modelle in diesen marktrelevanten Bereichen mehr Informationen erhalten.

Für das Modell PINN Call wird der Parameter $M_{skew} = 1,4$ und der Parameter $T_{skew} = 1,4$ gesetzt und es ergibt sich folgendes Sampling der Kollokationspunkten:




Abbildung 10: Verteilung der Kollokationspunkte des Modells PINN Call mit Häufigkeit und Streuung um den ATM Bereich. Zur besseren Übersicht des Streudiagramms wurden 10.000 Punkte zufällig ausgewählt.

Für das Modell PINN Put wird der Parameter $M_{skew} = 1,7$ und der Parameter $T_{skew} = 1,4$ gesetzt und es ergibt sich folgendes Sampling der Kollokationspunkten:




Abbildung 11: Verteilung der Kollokationspunkte des Modells PINN Put mit Häufigkeit und Streuung um den ATM Bereich. Zur besseren Übersicht des Streudiagramms wurden 10.000 Punkte zufällig ausgewählt.

Wie bereits zuvor erörtert, definieren die Endbedingungen (*Terminal Conditions*) den Wert einer Option zum Zeitpunkt ihrer Fälligkeit $t = T$, der exakt bekannt ist (siehe Kapitel 2.3.2). Um dem Netz diese fundamentale Regel beizubringen, wird eine Menge von Punkten X_{tc} generiert, bei denen die Zeitvariable t auf den Fälligkeitszeitpunkt $T = (90/365.25)$ bzw. $T = 0.25$ Jahre fixiert ist. Der Zielwert Y_{tc} für diese Punkte ist dann der exakte, analytisch berechnete Payoff (siehe Gleichung 3.9 für eine Call-Option bzw. 3.10 für eine Put-Option). Die Minimierung des Fehlers auf diesen Punkten zwingt das Netz, die korrekte Payoff-Funktion bei Fälligkeit zu erlernen.

Die Randbedingungen (*Boundary Conditions*) beschreiben das Verhalten des Optionspreises an den extremen Rändern (siehe Kapitel 2.1.3) des Lösungsraums und sind daher für eine stabile und korrekte Lösung der Black-Scholes-PDE besonders wichtig. Die Generierung dieser Punkte erfolgt für zwei Fälle:

1. Randbedingung für $S \rightarrow 0$: Wenn der Basispreis S auf null fällt, ist eine Call-Option wertlos. Zur Implementierung wird ein Satz von Datenpunkten generiert, bei dem $S = 0$ gesetzt und die anderen Eingabevariablen zufällig innerhalb ihre Grenzen gesampelt werden. Der zugehörige Zielwert Y_{bc} ist für eine Call-Option exakt null und für eine Put-Option $Ke^{-r(T-t)}$ (siehe Kapitel 3.3.2).
2. Randbedingung für $S \rightarrow \infty$: Wenn der Basispreis S sehr groß wird, spricht *deep-in-the-money* ist, verhält sich der Wert einer Call-Option approximativ wie der Basiswert selbst, abzüglich des diskontierten Ausübungspreises K . Da „unendlich“ numerisch nicht darstellbar ist, wird ein ausreichend großer Wert für S verwendet, vorliegend das Vierfache des maximalen Ausübungspreises K . Für diese Punkte wird der Zielwert Y_{bc} für eine Call-Option analytisch gemäß der Näherungsformel $V \approx Se^{-q(T-t)} - Ke^{-r(T-t)}$ berechnet, während er für eine Put-Option auf null gesetzt wird.




Abbildung 12: Darstellung der Rand- und Endbedingungen für Call-Optionen. Links ist der Payoff zum Zeitpunkt $T = 25$ in Abhängigkeit der Moneyness (S/K) gezeigt, rechts die Randbedingung für $S = 0$ und $S \rightarrow \infty$. Zur besseren Übersicht wurden jeweils nur 2.500 Punkte zufällig ausgewählt.




Abbildung 13: Darstellung der Rand- und Endbedingungen für Put-Optionen. Links ist der Payoff zum Zeitpunkt $T = 25$ in Abhängigkeit der Moneyness (S/K) gezeigt, rechts die Randbedingung für $S = 0$ und $S \rightarrow \infty$. Zur besseren Übersicht wurden jeweils nur 2.500 Punkte zufällig ausgewählt.

Die Kombination dieser drei systematisch generierten Punktemengen stellt sicher, dass die Modelle nicht nur lernen, reale Marktdaten zu reproduzieren, sondern auch die fundamentalen mathematischen und ökonomischen Anforderungen der Optionspreisbildung nach dem Black-Scholes-Modell zu internalisieren.

3.4. Training und Hyperparameter

Die erfolgreiche Konvergenz und Generalisierungsfähigkeit eines PINNs hängt entscheidend vom Trainingsprozess und der Wahl geeigneter Hyperparameter ab. In diesen Abschnitt werden der detaillierte Aufbau des Trainings sowie die zentralen Hyperparameter der in dieser Arbeit implementierten Modelle vorgestellt und deren konzeptionelle Begründung erörtert

3.4.1. Trainingsprozess und Batch-Strukturierung

Das Training der beiden Modelle ist als iteratives Verfahren über 50.000 Epochen konzipiert. Als Optimierungsalgorithmus bzw. *Optimizer* kommt *Adam* (Kingma & Ba, 2014) zum Einsatz, dessen adaptive Lernrate effizient und robust und bereits seit langem als Standard etabliert ist. Um die Konvergenz weiter zu optimieren, wird die Lernrate dynamisch durch einen *Scheduler* gesteuert. Die Lernrate wird um einen Faktor 0,5 reduziert, falls die ermittelte Differenz der Verlustfunktion über eine definierte Periode von 750 Epochen stagniert. Eine solche adaptive Anpassung ermöglicht eine schnelle Konvergenz in frühen Epochen und eine feinere Annäherung an das lokale Minimum in späteren Epochen.

Der dem Training zugrunde liegende Grundgesamtheit setzt sich aus verschiedenen Daten zusammen, die jeweils unterschiedliche Aspekte des vorliegenden Optimierungsproblems abbilden. Der empirische Teil besteht aus 65.439 Marktdaten X_{market} für das PINN Call Modell und 123.338 X_{market} Marktdaten für das PINN Put Modell. (siehe Tabelle 2). Um die Bedingungen, insbesondere Rand- und Endbedingungen, der Black-Scholes-PDE (2.12) zu erzwingen, werden die empirischen Marktdaten durch eine signifikant größere Menge synthetischer Daten ergänzt. Für das Modell PINN Call werden 196.317 Punkte X_{tc} für die *Terminal Conditions* und die gleiche Anzahl an Punkten X_{bc} für die *Boundary Conditions* verwendet. Im Fall des Modells PINN Put werden 298.410 X_{tc} für die *Terminal Conditions* und die gleiche Anzahl an Punkten X_{bc} für die *Boundary Conditions* verwendet. Für die „physics-informed“ Regularisierung wird zudem ein Pool von 163.598 Kollokationspunkten X_{colloc} für das Modell PINN Call und 248.676 Kollokationspunkte X_{colloc} für das Modell PINN Put generiert, die im ganzen Lösungsraum verteilt sind. Somit wird gewährleistet, dass die empirischen Marktdaten durch ein dichtes Netz an theoretischen und physikalischen Bedingungen gestützt werden und eine geeignete Optionspreisbewertung zulassen. Versuche haben gezeigt, dass die doppelte Anzahl von Marktdaten als Kollokationspunkte und die dreifache Anzahl von Marktdaten für jeweils die Rand- und Endbedingungen signifikant sind, um die Modelle aber auch die Black-Scholes-PDE hinreichend mit Daten zu versorgen. Auch Raissi et al. (2019) stellten bereits in ihrer grundlegenden Arbeit die Bedeutung einer hinreichenden Anzahl von Kollokationspunkten für ein erfolgreiches Training und eine hohe

Prognosegüte von PINNs fest. Dies gilt insbesondere für *Continuous Time Models*, wie sie in der vorliegenden Arbeit verwendet werden (siehe Kapitel 2.3.3). Bei dieser Art von Modellen wird die Einhaltung der PDE über Kollokationspunkte im gesamten Lösungsraum erzwungen.

Darüber hinaus werden *Mini Batches* verwendet, die heterogen zusammengesetzt sind. Dabei sind die empirischen Marktdaten zusammen mit den Punkten der Rand- und Endbedingungen zusammengelegt, während die Kollokationspunkte mithilfe eines weiteren *Batches* durchlaufen werden. Der *Data Batch* setzt sich zusammen aus X_{market} , X_{bc} und X_{tc} , wobei die Punkte unterschiedlich gewichtet werden. Die empirischen Marktdaten bilden mit 60 % den größten Anteil. Die *Terminal Conditions* X_{tc} werden mit 35 % gewichtet während die *Boundary Conditions* X_{bc} die verbleibenden 5 % einnehmen.

Diese 60/35/5 Gewichtung ist so gewählt, dass die Modelle primär von den etwas höheren gewichteten empirischen Marktdaten lernen und somit in der Lage sind, Phänomene wie den *Volatility Smile* zu erfassen, die vom klassischen Black-Scholes-Modell nicht abgebildet werden. Die Endbedingungen erhalten ebenfalls eine starke Gewichtung, da der Payoff am Verfallstag eine grundlegende, arbitragefreie Bedingung darstellt und als starker Anhaltspunkt für die Lösungsfunktion $\hat{V}(S, K, t, r, q)$ dient. Die Randbedingungen werden mit einer geringeren Gewichtung berücksichtigt, da diese Extremszenarien (siehe 3.3.3) sehr unwahrscheinlich, ihre Einhaltung aber dennoch für die theoretische Konsistenz notwendig sind.

Ferner werden die Indizes aller zugrundeliegenden Datenpools X_{colloc} , X_{market} , X_{bc} und X_{tc} zu Beginn jeder Epoche zufällig neu permutiert. Einerseits soll somit die stochastische Natur des Gradientenverfahrens maximiert, andererseits aber auch verhindert werden, dass die Modelle Muster aus der Reihenfolge der Daten lernt. Aus diesen neu gemischten Datenpools werden anschließend die sequenziellen *Mini Batches* für die jeweilige Epoche extrahiert.

3.4.2. Verlustfunktion und dynamische PDE-Gewichtung

Die Verlustfunktion $\mathcal{L}_{total}$ der Modelle, wie in Kapitel 3.3.2 hergeleitet, stellt eine gewichtete Summe aus dem datenbasierten Verlust $\mathcal{L}_{data}$ und dem physik-informierten Verlust $\mathcal{L}_{pde}$ dar:

$$\mathcal{L}_{total} = \mathcal{L}_{data} + \lambda_{pde} \mathcal{L}_{pde} \quad (3.18)$$

Die effektive Minimierung dieser hybriden Verlustfunktion erfordert eine Steuerung des Gewichtungsfaktors λ_{pde} , da die Gradienten von $\mathcal{L}_{data}$ und $\mathcal{L}_{pde}$ zu Beginn des Trainings stark konkurrieren können. Ferner unterliegen beide Verlustterme unterschiedliche Skalen und Gradientengrößen und eine zu frühe oder zu starke Gewichtung des PDE-Terms kann zu einer Destabilisierung des Trainings führen.

Um dies zu vermeiden, folgt die Gewichtung einer zeitlich gestaffelten Heuristik, die dem Prinzip des *Curriculum Learning* ähnelt. Initial wird $\lambda_{pde} = 0$ gesetzt, was dazu führt, dass

die Modelle ausschließlich aus den Daten X_{market} und den Rand- und Endbedingungen X_{bc} und X_{tc} lernen, um eine grundlegende Repräsentation der Lösungsfunktion $\hat{V}(S, K, t, r, q)$ zu approximieren.

Nach 1.500 Epochen wird der Gewichtungsfaktor λ_{pde} linear über 5.000 Epochen von null auf einen Zielwert erhöht. Für beide Modelle beträgt dieser Zielwert $\mathcal{L}_{pde} = 0,51$.

Allgemein gilt: Je umfangreicher und qualitativ besser die verfügbaren empirischen Daten, desto stärker kann die zugrundeliegenden PDE gewichtet werden, da die Modelle bereits ein robustes Verständnis der Datenstruktur besitzen. Ab Epoche 6.501 bleibt der Gewichtungsfaktor λ_{pde} konstant auf seinem Zielwert. In dieser Phase optimieren die beiden Modelle gleichzeitig die Anpassung an die empirischen Marktdaten und die Einhaltung der Black-Scholes-PDE, wodurch ein stabiles Gleichgewicht zwischen datengetriebene und „physics-informed“ Modellierung entsteht.

3.4.3. Analyse der zentralen Hyperparameter

Die Prognosegüte eines Modells wird maßgeblich durch das Zusammenspiel seiner Hyperparameter bestimmt. Anstatt einer isolierten Betrachtung ist deren Interdependenz entscheidend für ein erfolgreiches Training.

Die Architektur beider Modelle besteht aus sechs *Hidden Layers* à 148 Neuronen und der *tanh*-Funktion als Aktivierungsfunktion zwischen den *Layers* (siehe Abbildung 9). Eine ausreichende Tiefe und Breite sind notwendig, um die komplexen, nicht-linearen Strukturen der Optionspreisoberfläche zu erfassen. Dies schließt nicht nur den Optionspreis $\hat{V}$ selbst ein, sondern auch die zugrunde liegende implizite Volatilitätsstruktur $\hat{\sigma}$. Gleichzeitig erhöht eine zu hohe Kapazität das Risiko von *Overfitting*.

Die Größen der zuvor definierten *Mini Batches* werden wie folgt gewählt. Für den *Data Batch* werden 4.096 Punkte verwendet, während der *Collocation Batch* die dreifache Menge (12.288) Punkte beinhaltet. Eine ausreichend große Batch-Größe gewährleistet, dass die in jedem Trainingsschritt berechneten Gradienten eine repräsentative Stichprobe der Grundgesamtheit widerspiegeln. Dies ist insbesondere in der vorliegenden Arbeit von Bedeutung, da jeder *Data Batch* aus drei heterogenen Datenpools zusammengesetzt ist. Parallel dazu liegt eine wesentliche Herausforderung bei dem Training von PINNs in der Notwendigkeit, eine hohe Anzahl an Kollokationspunkten zu verwenden, um die Einhaltung der PDE im gesamten Lösungsraum zu gewährleisten. Die vorliegende gewählte Größe des *Collocation Batch* ist ausreichend, um in jedem Trainingsschritt eine robuste und repräsentative Ergebnisse der Verlustfunktion $\mathcal{L}_{pde}$ (3.14) zu erhalten, ohne den Rechenaufwand unverhältnismäßig zu erhöhen. Eine zu große Menge an Kollokationspunkten würde anderenfalls den Einfluss des *Data Batch* signifikant minimieren und die Einhaltung der Black-Scholes-PDE und somit die Minimierung des Verlustfunktion $\mathcal{L}_{pde}$ (3.14) priorisieren.

Somit ergeben sich folgende Hyperparameter für die Modelle PINN Call und PINN Put:

Hyperparameter	PINN Call	PINN Put
Epochs	50,000	50,000
Warm Up Epochs	1,500	1,500
PDE Ramp Up Epochs	5,000	5,000
Data Batch Size	4,096	6,144
Collocation Batch Size	12,288	18,432
Number of Collocation Batches	14	14
Number of Data Batches	16	17
PDE Weight Target	0.51	0.51
Learning Rate	4.0×10^{-4}	4.0×10^{-4}
Learning Rate Factor	0.5	0.5
Learning Rate Patience	750	750
Samples Collocation Points	163,598	248,676
Samples Market Data	65,439	99,470
Samples IC Points	196,317	298,411
Samples BC Points	98,159	149,205
Ratio Batch Size Market Points	0.6	0.6
Ratio Batch Size IC Points	0.35	0.35
Ratio Batch Size BC Points	0.05	0.05

Tabelle 3: Konfiguration der Hyperparameter für die Modelle PINN Call und PINN Put

4. Ergebnisse

4.1. Trainings- und Testergebnisse

Der folgende Abschnitt widmet sich der detaillierten Untersuchung des Trainingsverhaltens beider Modelle. Es wird einerseits untersucht wie sich die verschiedenen Komponenten der Verlustfunktion $\mathcal{L}_{total}$ über die insgesamt 50.000 Epochen verhalten. Andererseits werden auch die Größe der Gradienten der Verlustterme $\mathcal{L}_{data}$ und $\mathcal{L}_{pde}$ untersucht, um ein besseres Verständnis für die unterschiedliche Wirkung beider Verlustfunktionen zu gewinnen.

Wie bereits in Kapitel 3.4 erörtert erfolgt das Training in drei Phasen. In einer *Warm Up Phase* in der die Modelle ausschließlich auf Basis der empirischen Marktdaten sowie den Rand- und Endbedingungen trainiert werden, um eine solide Annäherung an die Datenpunkten zu gewährleisten. Ab Epoche 1.501, die *Ramp Up Phase*, wird linear der PDE-Term über seine Gewichtung λ_{pde} hinzugeführt. In der letzten Phase, ab Epoche 6.501, ist die Gewichtung in ihrem vollen Umfang (siehe Tabelle 2) vorhanden und die Modelle müssen kontinuierlich ein Gleichgewicht zwischen $\mathcal{L}_{data}$ und $\mathcal{L}_{pde}$ herstellen.

Diese unterschiedlichen Phasen spiegeln sich im Trainingsverlauf beider Modelle wider, weisen jedoch modellspezifische Eigenschaften auf.

Analyse des Trainingsverlaufes des PINN Call Modells

Grundlegend lässt sich festhalten, dass das Training des Modells insgesamt erfolgreich war. Das Modell konvergiert gut, wie an den stetig fallenden und sich stabilisierenden Verlustfunktionen und Validierungsmetriken zu erkennen ist. Die Gradienten zwischen dem Verlust $\mathcal{L}_{data}$ und dem Verlust $\mathcal{L}_{pde}$ scheinen gut ausbalanciert zu sein, was für PINNs entscheidend ist. Die vom Modell gelernte Volatilität $\hat{\sigma}$ bewegen sich in einem plausiblen und stabilen Bereich.




Abbildung 14: Verlauf der Verluste $\mathcal{L}_{data}$, $\mathcal{L}_{pde}$ und $\lambda_{pde}\mathcal{L}_{pde}$ des Modells PINN Call über die Trainingsepochen.

Die Verlustfunktion $\mathcal{L}_{total}$ setzt sich aus zwei Hauptkomponenten zusammen: dem Verlust $\mathcal{L}_{data}$ und dem Verlust $\mathcal{L}_{pde}$ (siehe Kapitel 3.3.2). Hierbei misst der Verlust $\mathcal{L}_{data}$ wie gut das Modell die gegebenen Datenpunkte (Marktdaten, Rand- und Endbedingungen) reproduziert. Er ist die Summe aus den Verlusten $\mathcal{L}_{market}$, $\mathcal{L}_{tc}$ und $\mathcal{L}_{bc}$. Der Verlust $\mathcal{L}_{pde}$ misst, wie gut die Ausgabe des Modells die Black-Scholes-PDE (2.12) erfüllt. Der gewichtete

Verlust $\lambda_{pde}\mathcal{L}_{pde}$ fließt tatsächlich in die Optimierung ein.




Abbildung 15: Verlauf der Verluste $\mathcal{L}_{market}$, $\mathcal{L}_{tc}$ und $\mathcal{L}_{bc}$ des Modells PINN Call über die Trainingsepochen.

Alle Verlustterme zeigen das klassische Verhalten eines erfolgreichen Trainings. Ein sehr starker Abfall in den ersten tausend Epochen, gefolgt von einer langsameren Konvergenz und schließlich einer Stabilisierung auf einem niedrigen Niveau (ein „Plateau“). Die logarithmische Skala der y-Achse macht diesen Trend sehr deutlich. Die einzelnen Verlustterme sind sehr „zackig“. Das ist bei der Verwendung von stochastischen Optimierern wie *Adam* normal und deutet nicht zwangsläufig auf ein Problem hin. Es zeigt, dass der Optimierer in jedem Schritt die Verlustlandschaft erkundet. Besonders für den Verlust $\mathcal{L}_{bc}$ ist dieses Verhalten deutlich erkennbar, da in diesem Fall ausschließlich zwischen zwei Extremen, $S = 0$ oder $S \rightarrow \infty$, unterschieden wird. Der rechte Graph zeigt den tatsächlichen Beitrag des PDE-Terms zum Gesamtverlust, sprich $\lambda_{pde}\mathcal{L}_{pde}$. Er folgt einem ähnlichen Trend wie der ungewichtete Verlust $\mathcal{L}_{pde}$, was darauf hindeutet, dass die Gewichtung λ_{pde} die Dynamik des Trainings nicht negativ beeinflusst bzw. die Black-Scholes-PDE über- oder untergewichtet hat.




Abbildung 16: Verlauf der Gradientenverhältnisse und -normen von PDE- und Datenverlust über die Trainingsepochen für das Modell PINN Call.

Ein häufiges Problem ist, dass die Gradienten der beiden Verluste $\mathcal{L}_{data}$ und $\mathcal{L}_{pde}$ sehr unterschiedliche Größenordnungen aufweisen, was dazu führt, dass das Training von einem der beiden Verlustterme dominiert wird. Die beiden Gradienten, *Data Gradient Norm* (orange) und *PDE Gradient Norm* (grün), schwanken stark, aber bewegen sich über den größten Teil des Trainings in einer ähnlichen Größenordnung (meist zwischen 10^4 und 10^6). Dies deutet darauf hin, dass keiner der beiden Gradienten vernachlässigbar klein wird und beide kontinuierlich zum erfolgreichen Training beitragen. Die *Gradient Ratio*, sprich das Verhältnis zwischen PDE und Daten, schwankt überwiegend zwischen ungefähr 0,1 und 5,0. Dies ist ein sehr guter Bereich und zeigt, dass die Gradienten gut ausbalanciert sind. Das Ziel von fortschrittlichen Gewichtungsschemata ist es oft, dieses Verhältnis nahe bei 1,0 zu halten.




Abbildung 17: Verlauf von MSE, MAE und Lernrate über die Trainingsepochen für das Modell PINN Call.

Die Metriken *Mean Squared Error (MSE)* und *Mean Absolute Error (MAE)* zeigen die Leistung des Modells auf einem separaten Validierungsdatensatz. Sowohl der MSE als auch der MAE fallen in den ersten ~ 15.000 Epochen stark ab und stabilisieren sich dann auf einem sehr niedrigen Niveau ($MSE \approx 20$ und $MAE \approx 2$). Die Fehler auf ungesehene Daten sind niedrig sowie stabil und zeigen, dass das Modell gut generalisiert und nicht *overfitted*. Die Lernrate, zu sehen im rechten Graphen, wird bei bestimmten Epochen (z.B. bei 13.000, 15.400, 21.500) schrittweise reduziert und zeigt klar, dass das in Kapitel 3.4.1 definierte Vorgehen einen positiven Einfluss auf den Trainingsverlauf hat. Der gewählte *Scheduler* hilft dem Modell in ein feineres Minimum der Verlustfunktion zu konvergieren, nachdem die größten Fortschritte mit einer höheren Lernrate erzielt wurden.




Abbildung 18: Verlauf von mittlerer, maximaler und minimaler Volatilität $\hat{\sigma}$ über die Trainingsepochen für das Modell PINN Call.

Die Werte zu *Mean Sigma*, *Max Sigma* und *Min Sigma* geben Aufschluss über die vom Modell gelernte Volatilität $\hat{\sigma}$. Ähnlich wie die einzelnen Verluste konvergieren auch diese Statistiken positiv. Nach einer anfänglichen instabilen Phase zu Beginn des Trainings stabilisieren sich die Werte nach Epoche 1.500. Die Instabilität zu Beginn ist ausgelöst, durch das nicht Vorhandensein der Black-Scholes-PDE. Das Modell probiert ausschließlich die Volatilität der verrauschten Daten zu erlernen. Die Werte nahe Epoche 50.000, *Mean Sigma* nahe 0,20 (20 %), *Max Sigma* nahe 1,1 (110 %) und *Min Sigma* nahe 0,04 (4 %), sind für eine typische Volatilitäts oberfläche (*Smile* oder *Skew*) absolut plausibel und repräsentieren positiv die vorhandene implizite Volatilität σ_{imp} der Marktdaten, insbesondere der Call-Optionen (siehe Tabelle 2 und Abbildung 7).

Analyse des Trainingsverlaufes des PINN Put Modells

Auch das Modell PINN Put erreicht eine positive Genauigkeit bei seinen Preisvorhersagen (niedriger MSE/MAE) und lernt gleichzeitig eine komplexe, physikalisch plausible Volatilitäts oberfläche, die die „Tail Events“ und extreme Marktphasen im Datensatz erfasst (siehe Tabelle 2 und Abbildung 7).




Abbildung 19: Verlauf der Verluste $\mathcal{L}_{data}$, $\mathcal{L}_{pde}$ und $\lambda_{pde}\mathcal{L}_{pde}$ des Modells PINN Put über die Trainingsepochen.

Die Konvergenz aller Verlustterme bleibt ein starkes positives Signal. Das Modell schafft es, die Fehler auf einem sehr heterogenen und volatilen Datensatz zu minimieren. Die Verluste $\mathcal{L}_{data}$ und $\mathcal{L}_{pde}$ konvergieren positiv und nach einem schnellen Abfall in den ersten 10.000 Epochen stabilisieren sie sich auf einem niedrigen Niveau im Bereich von 10^1 bis 10^2 . Dies deutet auf eine gute Anpassung an die Daten und die Physik hin.




Abbildung 20: Verlauf der Verluste $\mathcal{L}_{market}$, $\mathcal{L}_{tc}$ und $\mathcal{L}_{bc}$ des Modells PINN Put über die Trainingsepochen.

Die Verluste $\mathcal{L}_{market}$ und $\mathcal{L}_{tc}$ konvergieren auf sehr niedrige Werte um 10^1 . Der Verlust $\mathcal{L}_{bc}$ ist etwas höher und volatiler, was darauf hindeuten könnte, dass das Modell an den Rändern des Problembereichs mehr Schwierigkeiten hat. Die Normen der beiden Gradienten




Abbildung 21: Verlauf der Gradientenverhältnisse und -normen von PDE- und Datenverlust über die Trainingsepochen für das Modell PINN Put.

bewegen sich zwar über weite Strecken in einer ähnlichen Größenordnung (ungefähr 10^3 bis 10^6), aber die *PDE Gradient Norm* ist im Durchschnitt deutlich höher und volatiler als die *Data Gradient Norm*. Das *Gradient Ratio* liegt fast kontinuierlich deutlich über 1,0, oft im Bereich zwischen 10 und 100. Das bedeutet, dass die *PDE Gradient Norm* systematisch 10- bis 100-mal stärker ist als die *Data Gradient Norm*. Das Training wird also stärker vom PDE-Term dominiert. Jedoch scheint diese Imbalance kein „Fehler“ zu sein, sondern eine Eigenschaft des Problems selbst und des Datensatzes. Abbildung 7 zeigt deutlich, dass ein Großteil der Put-Optionen im *OTM* Bereich liegen während *ATM* und *ITM* Optionen proportional geringer ausfallen. Die Black-Scholes-PDE ist deutlich daran interessiert Optionen im *ATM* Bereich zu bewerten, während der Verlust $\mathcal{L}_{data}$ die *OTM* und *ITM* einfach erlernen kann. Die Tatsache, dass das Modell trotzdem zu exzellenten Ergebnissen konvergiert, spricht für die Robustheit des Adam-Optimierers und des gewählten *Scheduler* für die Lernrate.




Abbildung 22: Verlauf von mittlerer, maximaler und minimaler Volatilität $\hat{\sigma}$ über die Trainingsepochen für das Modell PINN Put.

Die vom Modell gelernte Volatilitätsoberfläche ist sehr komplex aber realistisch. Das Modell hat erfolgreich gelernt, nicht nur den „normalen“ Zustand des Marktes, sondern auch seine extremen Volatilitätsphasen abzubilden. Datenpunkte mit extremer Volatilität sind selten (das 99,9 % Quantil liegt bei 1,37). In den frühen Phasen des Trainings konzentriert sich das Modell darauf, den Großteil der Daten (mit niedriger Volatilität) korrekt abzubilden. Erst in den späteren Phasen, mit einer sehr kleinen Lernrate, hat das Modell die „Feinheit“, seine Parameter so anzupassen, dass auch diese seltenen, extremen Optionen korrekt modelliert werden. Der ansteigende Wert von *Max Sigma* zeigt, dass das Modell progressiv lernt, die extremen „Tails“ der Volatilitätsoberfläche korrekt abzubilden.





Abbildung 23: Verlauf von MSE, MAE und Lernrate über die Trainingsepochen für das Modell PINN Put.

Abschließend deuten die extrem niedrigen Validierungsfehler ($MSE/MAE \ll 1$) darauf hin, dass das Modell in der Lage ist, die Optionspreise $\hat{V}$ der Put-Optionen über den beobachteten Zeitraum mit sehr hoher Genauigkeit vorherzusagen.

4.2. Einfluss der Black-Scholes-Regularisierung

Im Folgenden wird die Generalisierungsfähigkeit der Modelle in spezifischen definierten, datenarmen Regionen des Testdatensatzes untersucht. Diese Regionen umfassen Optionen mit extremer Moneyness (S/K) (unteres/oberes 5 %-Quantil), sehr kurzen Restlaufzeiten t (unteres 5 %-Quantil) sowie extremen Basispreisen S und impliziten Volatilitäten σ_{imp} (oberes 5 %-Quantil). Es wird analysiert, inwiefern die Black-Scholes-Regularisierung die Prognosegüte der Modelle in genau diesen Bereichen verbessert, um Forschungsfrage (FQ1) zu beantworten und Hypothese (H1) zu prüfen.



(a) Optionspreisfläche PINN Call im Vergleich zu den verrauschten Optionspreisen V_{market} (b) Volatilitätsoberfläche PINN Call im Vergleich zu der beobachteten impliziten Volatilität σ_{imp}

Abbildung 24: Vergleich der Volatilitäts- und Optionspreisflächen des Modells PINN Call

Die Black-Scholes-informierte Regularisierung hat einen positive und stabilisierende Wirkung auf die Generalisierungsfähigkeit des Modells PINN Calls in datenarmen Regionen. Die Black-Scholes-PDE (2.12) zwingt das Modell, eine global konsistente, glatte und arbitragefreie Preis- und Volatilitätsfläche zu erlernen (siehe Abbildung 24a und 24b). Anstatt sich auf einzelne, potenziell verrauschte Optionspreise zu verlassen, lernt das Modell die zugrundeliegende finanzmathematische Struktur der Black-Scholes-PDE, was eine robuste Interpolation in Bereichen mit wenigen Datenpunkten ermöglicht.

Jeder einzelne Punkt in Abbildung 24a stellt einen am Markt beobachteten Optionspreise V_{market} dar. Es ist zu erkennen, dass die Punkte gestreut sind und Rauschen enthalten. Zudem sind sie nicht gleichmäßig verteilt. Es gibt Bereiche mit vielen Punkten (hohe Datendichte) und andere, datenarme Regionen. In Abbildung 24b stellen die Punkte die implizite Volatilität σ_{imp} dar. Auch hier ist die Streuung und das Rauschen der Marktdaten deutlich sichtbar.

Diese strukturelle Überlegenheit führt zu einer signifikanten Reduktion des Vorhersagefehlers. Ein direkter Vergleich zeigt, dass das Modell PINN Call einen *Mean Absolute Error (MAE)* von nur 8,73 aufweist. Im Gegensatz dazu kollabiert die Genauigkeit des klassischen Black-Scholes-Modells, das auf den dazugehörigen impliziten Volatilitäten σ_{imp} basiert, und resultiert in einem MAE von 338,56.

Metrik	PINN Call	Black-Scholes Call
MSE	273,10	240.170,65
RMSE	16,53	490,07
MAE	8,73	338,56

Tabelle 4: Vergleich der Prognosegüte zwischen PINN Call und Black-Scholes Call für Forschungsfrage (FQ1)

Zudem zeigt die Tabelle 5 einen fundamentalen Unterschied in der Prognosegüte. Während das Modell PINN Call seine hohe Genauigkeit beibehält, scheitert das klassische Black-Scholes-Modell an der numerischen Instabilität der impliziten Volatilität in diesen extremen Bereichen. Die geringen Fehlerwerte des Modells zeigen, dass seine Vorhersagen stabil bleiben. Der Grund dafür ist die gelernte, glatte Volatilitätsoberfläche (Abbildung 24b), die nicht von den Schwankungen einzelner Optionspreise abhängig ist.





Abbildung 25: Gegenüberstellung der Modell-basierten Optionspreise $\hat{V}$ und empirischen Optionspreisen V_{market} für europäische Call-Optionen

Die Abbildung 25 visualisiert diesen Unterschied perfekt. Die Vorhersage des Modells PINN Call (rot) sind eng um die ideale Linie ($y = x$) zentriert. Die Vorhersage des Black-Scholes-Modells (blau) streuen extrem und zeigen signifikante Ausreißer, was die mangelnde Robustheit des Ansatzes unterstreicht.



(a) Optionspreisoberfläche PINN Put im Vergleich zu den verrauschten Optionspreisen V_{market}

(b) Volatilitätsoberfläche PINN Put im Vergleich zu der beobachteten impliziten Volatilität σ_{imp}

Abbildung 26: Vergleich der Volatilitäts- und Optionspreisflächen des Modells PINN Put

Die Ergebnisse des Modells PINN Put bestätigen die Ergebnisse des Modells PINN Call. Die Black-Scholes-Regularisierung erweist sich auch in diesem Fall als entscheidender Faktor für die Erzeugung stabiler und genauer Vorhersagen, insbesondere in den datenarmen und für das Black-Scholes-Modell problematischen Regionen des Lösungsraums. Die Abbildung 26a zeigt die vom Modell gelernte Preisoberfläche. Im Gegensatz zum Modell PINN Call steigt der Optionspreis $\hat{V}$ mit dem Ausübungspreis K . Die Oberfläche ist glatt und frei von Artefakten, was belegt, dass das Modell auch in datenarmen Regionen eine plausible Interpolation vornimmt. Abbildung 26b zeigt die vom Modell gelernte Volatilitätsoberfläche. Wie beim Modell PINN Call wird eine glatte, kontinuierliche Funktion gelernt, die das typische *Volatility Smile* widerspiegelt. Dies befreit das Modell von der Notwendigkeit, für jeden einzelnen Datenpunkt eine potenziell instabile Volatilität zu berechnen.

Metrik	PINN Put	Black-Scholes Put
MSE	189,88	80.534,04
RMSE	13,78	283,79
MAE	5,77	183,62

Tabelle 5: Vergleich der Prognosegüte zwischen PINN Put und Black-Scholes Put für Forschungsfrage (FQ1)

Die Metriken auf dem gefilterten Testdatensatz belegen die signifikante Generalisierungsfähigkeit des Modells PINN Put. Mit einem RMSE von 13.78 und einem MAE von 5.77 erzielt das Modell eine bemerkenswert hohe Genauigkeit in genau den Regionen, die für das Black-Scholes-Modell besonders schwierig abzubilden sind.




Abbildung 27: Gegenüberstellung der Modell-basierten Optionspreise $\hat{V}$ und empirischen Optionspreisen V_{market} für europäische Put-Optionen

Abbildung 27 visualisiert diesen quantitativen Unterschied. Die Vorhersagen des Modells (rote Punkte) liegen eng an der Linie der perfekten Übereinstimmung. Im Gegensatz dazu explodieren die Fehler des Black-Scholes-Modell (blaue Punkte). Die breite Streuung und die extremen Ausreißer belegen dessen Versagen in diesen datenarmen Regimen.

Abschließend lässt sich die Forschungsfrage (FQ1) wie folgt beantworten: Die Black-Scholes-Regularisierung hat einen fundamental positiven und stabilisierenden Einfluss auf die Generalisierungsfähigkeit beider Modelle. Dieser Einfluss ist nicht nur auf einen Optionstyp beschränkt, sondern stellt ein generelles Prinzip dar. Die Hypothese (H1) wird durch die quantitativen und qualitativen Ergebnisse für beide Modelle eindeutig und vollumfänglich bestätigt.

4.3. Vergleich der Modelle mit dem klassischen Black-Scholes-Modell

Im Folgenden wird die Prognosegüte der entwickelten Modelle im Vergleich zum Black-Scholes-Modell, insbesondere dessen analytischen Lösungen (siehe Kapitel 2.1.2), analysiert. Die Untersuchung erfolgt separat für die Modelle PINN Call und PINN Put, um eine differenzierte Beurteilung der Prognosegüte zu gewährleisten. Ziel ist die Beantwortung der Forschungsfrage (FQ2) und die Überprüfung der Hypothese (H2).

Die erste Analyse konzentriert sich auf die Bewertung der Prognosegüte des Modells PINN Call. Die Metriken für den Testdatensatz zeigen eine eindeutige Überlegenheit des Modells.

Metrik	PINN Call	Black-Scholes Call
MSE	116,62	71.041,98
RMSE	10,80	266,54
MAE	5,61	150,06

Tabelle 6: Vergleich der Modellgüte zwischen PINN Call und Black-Scholes Call

Der *Mean Absolute Error (MAE)* des Modells PINN Call liegt bei einem niedrigen Wert von 5,61, während das Black-Scholes-Modell im Durchschnitt um 150,06 vom Optionspreis V_{market} abweicht. Die Diskrepanz beim *Mean Squared Error (MSE)*, der große Fehler stärker gewichtet, ist mit 116,60 zu 71.041,9 noch extremer.




Abbildung 28: Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.

Die Abbildung 28 untermauert die quantitativen Ergebnisse aus Tabelle 6. Die linke Darstellung zeigt, dass die Fehler des Modells PINN Call überwiegend klein sind und keine systematische Struktur aufweisen. Dies deutet darauf hin, dass das Modell eine Preisstruktur der Optionen gut erlernt hat.

Die rechte Darstellung zeigt ein klares, systematisches Fehlmuster, das als *Volatility Skew* bekannt ist. Insbesondere *OTM* Optionen werden systematisch überbewertet (blau), während *ITM* Optionen tendenziell unterbewertet werden (rot). Diese systematische Verzerrung ist eine bekannte Schwäche des Black-Scholes-Modells.

Auch das Modell PINN Put zeigt eine positive Prognosegüte.

Metrik	PINN Put	Black-Scholes Put
MSE	63,71	24.988,88
RMSE	7,98	158,08
MAE	3,35	89,52

Tabelle 7: Vergleich der Modellgüte zwischen PINN Put und Black-Scholes Put

Die Fehlermaße für das Modell PINN Put zeigen einen gleichen Trend auf und liegen in einem sehr niedrigen Bereich. Im Vergleich dazu weist das Black-Scholes-Modell mit einem MAE von 89,52 und einem MSE von fast 25,000 erneut signifikante Ungenauigkeiten auf.




Abbildung 29: Vergleich der Verteilungen zentraler Kennzahlen von Call- und Put-Optionen, einschließlich Basispreis, Ausübungspreis, Laufzeit, Volatilität, Zinssatz, Dividende, Moneyness und Optionspreis.

Die Fehlerpunkte sind auch hier überwiegend nahe null (hellgrau) und zeigen kein starkes systematisches Muster. Es ist eine leichte Tendenz zur Überbewertung (blau) bei *ITM* Optionen zu erkennen, die Fehler bleiben jedoch absolut gesehen sehr klein. Das Black-Scholes-Modell zeigt erneut ein starkes systematisches Fehlermuster. Das Bild ist spiegelbildlich zu dem Black-Scholes-Modell für Call-Optionen: *ITM* Optionen werden stark überbewertet (blau) während *OTM* Optionen leicht unterbewertet werden (rot). Dies bestätigt, dass die Unzugänglichkeit des Black-Scholes-Modells (Annahme konstanter Volatilität) für beide Optionstypen gelten und dass die PINN Modelle diese erfolgreich überwindet.

Die durchgeführten Analysen für beide Modelle führen zu einem konsistenten und eindeutigen Ergebnis. Beide Modelle sind in der Lage, Optionspreise mit deutlich höherer Genauigkeit zu bewerten. Es werden die Bewertungsfehler im Vergleich zum traditionellen Black-Scholes-Modell um signifikante Größenordnungen reduziert und dessen bekannte systematische Verzerrungen, wie den Volatility Smile/Smirk, eliminiert.

Die Hypothese (H2), dass die Modelle PINN Call und PINN Put signifikant geringere mittlere Fehlermaße erzielen, wird für beide Modelle vollumfänglich bestätigt. Sowohl für das Modell PINN Call als auch für das Modell PINN Put sind die MSE-, RMSE- und MAE-Werte signifikant niedriger als die des Black-Scholes-Modells. Dies belegt die überlegene Fähigkeit der Modelle, die komplexe, nicht-lineare Preisoberfläche des Optionsmarktes abzubilden.

4.4. Unterscheidung der Prognosegüte zwischen Call- und Put-Optionen


Zur Beantwortung der Forschungsfrage, ob sich die Leistung des PINN-Modells zwischen Call- und Put-Optionen unterscheidet (FQ3), wird eine tiefgehende, vergleichende Analyse durchgeführt. Im Mittelpunkt dieser Untersuchung steht nicht primär die absolute Prognosegüte der Optionspreise $\hat{V}$, gemessen durch Fehlermetriken wie MSE oder MAE. Stattdessen konzentriert sich die Analyse auf die Fähigkeit der Modelle, die zugrundeliegende Preisstruktur des Optionsmarktes zu erfassen und abzubilden.

Diese Preisstruktur manifestiert sich in der impliziten Volatilitäts Oberfläche, einer komplexen, dreidimensionalen Darstellung der impliziten Volatilität $\hat{\sigma}$ in Abhängigkeit von Moneyness und Restlaufzeit.


Die folgende Analyse bewertet daher die Leistung der Modelle, indem sie die vom Modell gelernte Volatilitäts Oberfläche mit den tatsächlichen Marktdaten für Call- und Put-Optionen über verschiedene Marktregime hinweg vergleicht.

Werden zunächst die Marktdaten betrachtet zeigt sich, dass die Moneyness einen Mittelwert von ungefähr 0,98 aufweist und *OTM* Optionen geringfügig überwiegen., was für Call-Optionen typisch ist. Die Große Spanne von 0,62 bis 1,50 stellt sicher, dass das Modell über ein breites Spektrum von *ITM* bis *OTM* Optionen getestet wird. Die implizite Volatilität σ_{imp} hat einen Mittelwert von 0,195 (19,5 %), was für den S&P 500 in dem vorliegenden Zeitraum plausibel scheint. Der Maximalwert von 1,20 (120 %) ist extrem hoch und stammt aus der Zeit des COVID-19-Crashes im März 2020.

Die Abbildungen zeigen die vom Modell PINN Call gelernten Volatilitäts Oberflächen im Vergleich zu den tatsächlichen Marktdaten (Punkte). Die Fähigkeit des Modells, diese komplexe, nicht-lineare Oberfläche zu approximieren, ist ein direktes Maß für die Prognosegüte des Modells.



(a) *Low Volatility* Volatilitätsoberfläche PINN Call (b) *High Volatility* Volatilitätsoberfläche PINN Call



(c) *Normal Volatility* Volatilitätsoberfläche PINN Call

Abbildung 30: Volatilitätsoberflächen verschiedener Markt Regime des Modells PINN Call im Vergleich zur impliziten Volatilität σ_{imp}

Abbildungen 30a zeigt die Volatilitätsoberfläche für das *Low Volatility* Markt Regime. Die Punkte liegen in einem relativ niedrigen Volatilitätsbereich (ca. 0,05 bis 0,13). Die vom Modell approximierte Volatilitätsoberfläche ist relativ flach, was korrekt ist für ein niedriges Volatilitätsumfeld. Das Modell scheint die Struktur der Daten sehr gut zu erfassen. Die Oberfläche verläuft sauber durch die Mitte der Punktwolke. Ein leichtes *Volatility Smile* ist erkennbar und wird vom Modell nachgebildet.

Abbildungen 30b zeigt die Volatilitätsoberfläche für das *High Volatility* Market Regime, welches bis weit über 0,35 (35 %) reicht und Ausreißer bis 1,2 (120 %) aufzeigt. Die Volatilitätsoberfläche ist steil und stark gekrümmt. Insbesondere für Optionen mit niedriger Moneyness (*OTM* Optionen) steigt die Volatilität stark an. Dies ist der klassische *Volatility Skew*, der in Stressphasen extrem ausgeprägt ist. Das Modell scheint diese extreme Form gut zu erfassen. Die Oberfläche folgt dem steilen Anstieg und der allgemeinen Form der Punktwolke. Die Streuung der Punkte ist hier naturgemäß viel größer, aber das Modell findet einen robusten Mittelweg.

Abbildungen 30c stellt den häufigsten Fall dar (50 % der Daten). Die Volatilität liegt zwischen den beiden anderen Regimen. Der *Volatility Skew* ist deutlicher als in Abbildungen 30a dem *Low Volatility* Regime aber nicht so extrem wie im *High Volatility* Regime. Auch in diesem Fall scheint die vom Modell gelernte Volatilitätsoberfläche die Daten sehr gut zu repräsentieren.

Für Put-Optionen liegt der Mittelwert der Moneyness bei 1,134 und zeigt eine deutliche Übergewichtung von *OTM* Optionen. Dies bestätigt die grundlegende Dynamik am Optionsmarkt. Genau in diesem Bereich werden Put-Optionen zur Portfolio-Absicherung (*Delta Hedging*) gekauft, was zu der aufgezeigten Verzerrung führt (siehe Tabelle 2 und Abbildung 7). Die implizite Volatilität σ_{imp} liegt im Mittelwert bei 0,32 (32 %) und im Maximalwert bei 1,58 (158 %). Die durchschnittliche implizite Volatilität von Put-Optionen ist um mehr als 60 % höher als bei Call-Optionen. Dies ist eine direkte Quantifizierung des asymmetrischen Risikos und der „Angst“ im Optionsmarkt. Die extremen Maximalwerte bei Put-Optionen deuten auf noch heftigere Aufschläge in Stressphasen hin.


Werden die Volatilitätsoberflächen für die einzelnen Regime betrachtet zeigt sich für das Modell PINN Put ein ähnliches Bild.

Bereits im *Low Volatility* Regime ist die Volatilitätsoberfläche keine flache Ebene mehr. Wie in Abbildung 31a erkennbar, erzeugen *OTM* Options einen steilen Anstieg der Volatilität. Dies ist der klassische *Volatility Skew*. Das Modell erfasst diese Struktur, aber die zugrundeliegende Form ist bereits komplexer als bei den Call-Optionen.


In Abbildungen 31c, im Regime zwischen *Low Volatility* und *High Volatility* ist der *Volatility Skew* noch stärker ausgeprägt. Die Volatilitätsoberfläche steigt für Optionen mit hoher Moneyness steil an. Die Streuung der Punkte um die vom Modell gelernte Oberfläche herum erscheint größer als bei den Call-Optionen, was auf eine beginnende Schwierigkeit des Modells hindeutet, eine perfekte Passung zu finden.

Für Abbildung 31b ist das Bild nochmal deutlich anders. Die Volatilität für *OTM* Optionen explodiert förmlich nach oben. Die vom Modell gelernte Oberfläche wird zu einer extrem steilen Wand. Viel wichtiger ist jedoch die massive Streuung der Punkte. Die Punkte bilden eine breite, fast chaotische Wolke, durch die das Modell versucht, eine mittlere Oberfläche zu legen. Es ist visuell erkennbar, dass die Prognosegüte des Modells hier signifikant leidet. Die Abweichung der einzelnen Punkte von der Oberfläche sind viel größer als in den anderen Regimen.

Basierend auf dieser vergleichenden Analyse kann festgehalten werden, dass die Modellleistung sich zwischen Call- und Put-Optionen signifikant unterscheidet. Das Modell PINN Put zeigt eine sichtlich und messbar schlechtere Anpassungs- und Prognosegüte der Volatilitätsoberfläche für Put-Optionen im Vergleich zu Call-Optionen. Dies manifestiert sich insbesondere durch die komplexere und steilere Volatilitätsstruktur, die für das Modell PINN Put schwieriger zu erlernen ist. Zudem ist die Streuung der Marktdaten um die vom Modell PINN Put gelernte Volatilitätsoberfläche wesentlich größer, insbesondere in Phasen hoher Volatilität.



(a) *Low Volatility* Volatilitätsoberfläche PINN Put (b) *High Volatility* Volatilitätsoberfläche PINN Put



(c) *Normal Volatility* Volatilitätsoberfläche PINN Put

Abbildung 31: Volatilitätsoberflächen verschiedener Markt Regime des Modells PINN Put im Vergleich zur impliziten Volatilität σ_{imp}

Die Hypothese (H3) wird durch die aufgezeigten Ergebnisse nachdrücklich bestätigt. Der Unterschied in der Modellgüte, hinsichtlich der erlernten Volatilität $\hat{\sigma}$, ist im *High Volatility* Regime am signifikantesten. Während das Modell PINN Call die extreme Situation noch gut meistert, kämpft das Modell PINN Put sichtlich mit der verrauschten Struktur der Daten

5. Diskussion

5.1. Zusammenfassung der zentralen Ergebnisse

Die empirische Analyse aus Kapitel 4 lieferte entscheidende Erkenntnisse zur Beantwortung der Forschungsfragen. Als Grundlage für die nachfolgende Diskussion und kritische Einordnung werden die wesentlichen Ergebnisse im Folgenden rekapituliert.

Die Analyse des Trainingsprozesses (Kapitel 4.1) belegt die erfolgreiche Konvergenz beider Modelle, PINN Call und PINN Put. Die Verlustfunktionen zeigten einen stetigen Abfall und stabilisierten sich auf einem niedrigen Niveau, was auf eine robuste Modelanpassung hindeutet. Die Validierungsmetriken (MSE und MAE) bestätigten eine hohe Generalisierungsfähigkeit auf ungesehenen Daten ohne Anzeichen von Overfitting. Ein zentrales Ergebnis war die Beobachtung der Gradientendynamik: Während beim Modell PINN Call eine ausgewogene Balance zwischen dem datengetriebenen und dem PDE-basierten Verlustterm erreicht wurde, zeigte sich beim Modell PINN Put eine stärkere Dominanz des PDE-Terms. Dies ist auf die spezifische Datenverteilung von Put-Optionen zurückzuführen. Beide Modelle lernten erfolgreich komplexe und ökonomisch plausible Volatilitätsflächen, die charakteristische Marktphänomene wie den *Volatility Skew* abbilden.

Die Untersuchung des Einflusses der Black-Scholes-informierten Regularisierung (FQ1) (Kapitel 4.2) offenbarte deren fundamental positiven und stabilisierenden Effekt, insbesondere in datenarmen Regionen des Optionsraums. Indem die Modelle gezwungen wurden, eine global konsistente und arbitragefreie Preisoberfläche gemäß der Black-Scholes-PDE zu erlernen, wurde eine robuste Interpolation ermöglicht. Dies führte zu einer drastischen Reduktion der Bewertungsfehler im Vergleich zum klassischen Black-Scholes-Modell, dessen Prognosen in diesen Bereichen aufgrund instabiler impliziter Volatilitäten kollabierten. Beispielsweise reduzierte sich der MAE für Call-Optionen von 338,56 auf 8,73. Diese strukturelle Überlegenheit bestätigt die Hypothese (H1), dass die Regularisierung mittels der Black-Scholes-PDE zu stabileren und robusteren Vorhersagen führt.

Der direkte Leistungsvergleich auf dem gesamten Testdatensatz (FQ2) (Kapitel 4.3) demonstrierte die signifikante Überlegenheit beider PINN Modelle gegenüber dem klassischen Black-Scholes-Modell. Die Fehlermaße (MSE, MAE, RMSE) beider PINN-Modelle waren um mehrere Größenordnungen geringer. Während die Modelle präzise und fehlerarme Bewertungen lieferten, wies das Black-Scholes-Modell hohe Fehler und systematische Verzerrungen (*Volatility Smirk/Smile*) auf, indem es beispielsweise *OTM* Optionen systematisch über- und *ITM* Optionen unterbewertete. Die beiden PINN Modelle eliminierten diese bekannten Schwächen erfolgreich, was die Hypothese (H2) vollumfänglich bestätigt.

Die vergleichende Analyse der Prognosegüte zwischen Call- und Put-Optionen (FQ3) (Kapitel 4.4) erfolgte anhand der Fähigkeit der Modelle, die jeweilige implizite Volatilitätsfläche über verschiedene Marktregime hinweg zu approximieren. Es zeigte sich, dass das Modell PINN Call eine durchweg hohe Anpassungsgüte an die Marktdaten aufwies und

die Volatilitätsstruktur in Phasen niedriger, normaler und hoher Volatilität präzise nachbildete. Im Gegensatz dazu wies das Modell PINN Put eine messbar schlechtere Leistung auf. Dies ist auf die inhärent komplexere, steilere und verrauschtere Volatilitätsstruktur von Put-Optionen zurückzuführen, die insbesondere in Stressphasen (hohe Volatilität) stark ausgeprägt ist. Die Streuung der Marktdaten um die gelernte Oberfläche war für Put-Optionen signifikant größer, was die Hypothese (H3) bestätigt.

5.2. Vorteile und Limitationen des Ansatzes

Trotz der überzeugenden Ergebnisse, die in Kapitel 4 präsentiert wurden, ist eine kritische Auseinandersetzung mit den Stärken und Schwächen des gewählten Ansatzes notwendig. Die Leistungsfähigkeit der hybriden Modelle ist untrennbar mit den methodischen Entscheidungen aus Kapitel 3 verbunden. Diese umfassen die Datenaufbereitung, die Modellarchitektur und das Training. Im Folgenden werden die zentralen Vorteile und Limitationen des gewählten Vorgehens systematisch beleuchtet.

Vorteile des hybriden PINN-Ansatzes

Ein grundlegender Vorteil des Ansatzes ist die in Kapitel 4.3 nachgewiesene, signifikant höhere Prognosegüte bei Optionspreisen im Vergleich zum klassischen Black-Scholes-Modell. Durch die Kombination eines flexiblen neuronalen Netzes (Kapitel 3.3.1) mit der strukturellen Regularisierung durch die Black-Scholes-PDE (Kapitel 3.3.2) überwinden die Modelle die restriktiven Annahmen des klassischen Black-Scholes-Modells und erlernen komplexe, nicht-lineare Preisstrukturen direkt aus den Marktdaten.

Anders als rein datengetriebene Modelle ist der hier gewählte Ansatz durch die Integration der Black-Scholes-PDE ökonomisch fundiert. Die systematische Berücksichtigung der PDE sowie der Rand- und Endbedingungen (Kapitel 3.3.3) stellt sicher, dass die gelernte Preisoberfläche glatt, stetig und arbitragefrei ist. Dies verleiht den Modellen eine strukturelle Robustheit, die, wie in Kapitel 4.2 gezeigt, insbesondere in datenarmen Regionen zu stabilen Interpolationen führt, wo rein datengetriebene Ansätze versagen würden.

Ein weiterer wesentlicher Vorteil der gewählten Modellarchitektur (Kapitel 3.3.1) ist die simultane Approximation des Optionspreises $\hat{V}$ und der impliziten Volatilität $\hat{\sigma}$. Die Modelle sind nicht auf potenziell verrauschte oder instabile, extern berechnete implizite Volatilitäten als Input angewiesen. Stattdessen inferiert es eine global konsistente und glatte Volatilitätsfläche (siehe Kapitel 4.2, Abb. 9b und 11b), die ökonomische Phänomene wie den *Volatility Skew* und *Volatility Smile* abbildet. Dies erhöht die Robustheit der gesamten Modelle erheblich.

Zudem konnte die sorgfältige Datenbereinigung und das Feature Engineering (Kapitel 3.1.2) eine qualitativ hochwertige Datengrundlage erstellen, die es den Modellen ermöglichte, auch in volatilen Marktphasen (wie dem COVID-19-Crash, siehe Kapitel 3.2.2) stabile Muster zu erlernen. Der Ansatz ist somit in der Lage, dynamische Marktregime zu verarbeiten und ist nicht auf stationäre Marktbedingungen beschränkt.

Limitationen und Herausforderungen

Obwohl die Regularisierung eine Stärke ist, stellt sie zugleich eine Limitation dar. Die Modelle sind inhärent an die Struktur der Black-Scholes-PDE gebunden. Sie können zwar die Annahme konstanter Volatilität aufheben, sind aber nicht in der Lage, fundamentale Marktphänomene abzubilden, die außerhalb des Black-Scholes-Frameworks liegen, wie beispielsweise Sprungprozesse (Jump-Diffusion) oder stochastische Volatilität. In Marktphasen, in denen diese Effekte dominant sind, könnte die PDE-Regularisierung die Lernfähigkeit der Modelle einschränken.

Im Gegensatz zur einfachen Anwendung einer analytischen Formel ist der entwickelte Ansatz rechenintensiv und komplex. Der Trainingsprozess (Kapitel 3.4.1) erfordert eine große Anzahl an Epochen, und die Konvergenz hängt empfindlich von der Wahl der Hyperparameter ab (Kapitel 3.4.3). Insbesondere die Gestaltung der hybriden Verlustfunktion und die dynamische Gewichtung des PDE-Terms (Kapitel 3.4.2) stellen eine anspruchsvolle Optimierungsaufgabe dar. Eine suboptimale Konfiguration kann zu instabilem Training oder einer Dominanz eines Verlustterms führen.

Trotz der physikalischen Regularisierung bleiben die Modelle datengetriebene Ansätze. Die Qualität der Prognosen hängt maßgeblich von der Repräsentativität des Trainingsdatensatzes (Kapitel 3.1) ab. Obwohl der Datensatz verschiedene Marktphasen umfasste, könnte die Prognosegüte in zukünftigen, strukturell völlig neuartigen Krisen nachlassen. Zudem wurden durch die Datenfilterung (Kapitel 3.1.2) extrem illiquide Optionen entfernt, wodurch die Prognosegüte in diesen Randbereichen des Marktes nicht validiert werden kann.

Wie die Analyse in Kapitel 4.4 klar zeigte, war die Fähigkeit des Modells, die Volatilitätsoberfläche zu approximieren, für Put-Optionen geringer als für Call-Optionen. Die komplexere und stärker verzerrte Preisstruktur von Put-Optionen, insbesondere in Phasen hoher Volatilität, stellte eine größere Herausforderung dar. Dies deutet darauf hin, dass die gewählte Modellarchitektur und Trainingsstrategie bei extrem asymmetrischen und verrauschten Daten an ihre Grenzen stoßen kann.

Die dynamische Gewichtung des PDE-Terms (λ_{pde}) wurde über eine vordefinierte, lineare Anstiegsphase implementiert (Kapitel 3.4.2). Dies ist eine heuristische Methode, die auf Erfahrungswerten basiert. Es gibt keine theoretische Garantie, dass dieser Ablauf optimal ist. Fortgeschrittenere Methoden, wie adaptive Gewichtungsschemata, die das Gleichgewicht der Gradienten während des Trainings automatisch anpassen, könnten die Konvergenz und die finale Modellgüte potenziell weiter verbessern.

Ferner folgt das Sampling der Kollokationspunkte (Kapitel 3.3.3) einem vordefinierten, statischen Schema, das Bereiche höherer Marktaktivität priorisiert. Ein fortschrittlicherer Ansatz wäre ein adaptives Sampling, bei dem während des Trainings iterativ mehr Kollokationspunkte in den Regionen des Lösungsraums platziert werden, in denen das Residuum der PDE am größten ist. Dies könnte die Effizienz des Trainings steigern, da die Rechenleistung auf die problematischsten Bereiche konzentriert würde.

5.3. Implikationen der Arbeit für Theorie und Praxis

Die vorliegende Arbeit entfaltet weitreichende Implikationen für die finanzmathematische Theorie sowie für die quantitative Praxis im Finanzwesen. Die erfolgreiche Implementierung und Validierung eines hybriden Physics-Informed Neural Network (PINN) zur Optionsbewertung stellt einen bedeutsamen Beitrag dar und eröffnet möglicherweise den Weg für neue Ansätze in der Modellierung von Finanzderivaten.

Die vorliegende Arbeit positioniert partielle Differenzialgleichungen (PDEs) in einem neuen Kontext. Anstatt die Black-Scholes-PDE als eine Gleichung zu betrachten, die numerisch oder analytisch gelöst werden muss, wird sie als weiche Nebenbedingung (*soft constraint*) innerhalb der Verlustfunktion eines neuronalen Netzes genutzt. Dieser interessante Ansatz eröffnet neue Forschungswege, bei denen komplexe finanzmathematische Modelle (z.B. Heston, Jump-Diffusion-Modelle) nicht mehr als inkompatibel zu maschinellen Lernverfahren angesehen werden, sondern als integraler Bestandteil, der den Lernprozess leitet und ökonomisch plausible Lösungsräume sicherstellt.

Ferner ermöglichen die Modelle das implizite Erlernen der gesamten Volatilitätsoberfläche, ohne eine spezifische parametrische Form vorauszusetzen. Dies bietet ein leistungstarkes Werkzeug für die empirische Finanzmarktforschung. Anstatt Modelle an die Daten zu fitten, können Phänomene wie der Volatility Skew und die Terminstruktur der Volatilität direkt aus den Marktpreisen in einer nicht-parametrischen Weise extrahiert und visualisiert werden. Dies erlaubt eine flexiblere und potenziell realitätsnähere Analyse der Markterwartungen und Risikopräferenzen.

Die Stabilität der Modelle, selbst in Phasen hoher Volatilität, machen sie zusätzlich zu einem idealen Werkzeug für Stresstests. Risk-Manager können extreme Marktszenarien simulieren, ohne dass die Modelle aufgrund von Instabilitäten in den Input-Parametern (wie der impliziten Volatilität) versagt. Die Fähigkeit, plausible Preise auch für hypothetische, noch nicht am Markt gehandelte Optionen zu interpolieren, erhöht die Aussagekraft von Szenarioanalysen und die Reduzierung von Modellrisiken.

Zudem ist der traditionelle Prozess der Kalibrierung komplexer stochastischer Volatilitätsmodelle oft rechenintensiv und numerisch instabil. Der hier vorgestellte Ansatz bietet das Potenzial, diesen Prozess zu vereinfachen und zu beschleunigen. Anstatt explizite Modelle zu kalibrieren, kann ein trainiertes PINN direkt als Preisinstrument eingesetzt werden.

5.4. Fazit

Die vorliegende Arbeit entwickelte und evaluierte einen hybriden Deep-Learning-Ansatz zur Bewertung europäischer Optionen, der die Black-Scholes-PDE als Regularisierungsterm in das Training eines neuronalen Netzes integriert.

Die zentralen empirischen Ergebnisse belegen, dass dieser Physics-Informed Neural Network (PINN) Ansatz dem klassischen Black-Scholes-Modell in Bezug auf Prognosegüte, Robustheit und Generalisierungsfähigkeit signifikant überlegen ist. Die Modelle waren in

der Lage, bekannte systematische Bewertungsfehler wie den *Volatility Smile* und *Skew* erfolgreich zu eliminieren und die Prognosegüte, gemessen an Metriken wie dem *Mean Absolute Error*, um mehrere Größenordnungen zu verbessern. Der entscheidende Faktor für diesen Erfolg ist die physikalische Regularisierung. Diese fungiert nicht nur stabilisierend für das Training, sondern zwingt die Modelle, eine ökonomisch konsistente und arbitragefreie Preis- und Volatilitäts Oberfläche zu erlernen. Dies ermöglichte plausible Interpolationen selbst in datenarmen und hochvolatilen Regionen des Optionsmarktes, in denen das klassische Modell aufgrund instabiler impliziter Volatilität versagte.

Im Zuge der Analyse und Ergebnisse konnten alle aufgestellten Hypothesen bestätigt werden. Die Black-Scholes-PDE steigerte die Generalisierungsfähigkeit (H1), der PINN-Ansatz erzielte eine höhere Prognosegüte (H2), und es zeigten sich nachvollziehbare Unterschiede in der Prognosegüte angesichts der komplexeren Preisstruktur von Put-Optionen (H3). Trotz dieser positiven Resultate sollten die Limitationen solch eines Ansatzes nicht vernachlässigt werden, wie etwa der inhärenten Bindung an die Grundstruktur des Black-Scholes-Modells.

Zusammenfassend demonstriert die Arbeit erfolgreich, dass die Zusammensetzung aus finanzmathematischer Theorie und datengetriebener Flexibilität ein leistungsstarkes Exempel darstellt, um robustere und realitätsnähere Bewertungsmodelle für komplexe Finanzderivate zu schaffen.

Literatur

- [1] Caio Almeida u. a. „Can a Machine Correct Option Pricing Models?“ In: *Journal of Business & Economic Statistics* 41.3 (Sep. 2022), S. 995–1009.
- [2] Henrik Amilon. „A neural network versus Black–Scholes: a comparison of pricing and hedging performances“. In: *Journal of Forecasting* 22.4 (2003), S. 317–335.
- [3] Yuexing Bai, Temuer Chaolu und Sudao Bilige. „The application of improved physics-informed neural network (IPINN) method in finance“. In: *Nonlinear Dynamics* 107.4 (Jan. 2022), S. 3655–3667.
- [4] Julia A. Bennell und Charles M. Sutcliffe. „Black-Scholes Versus Artificial Neural Networks in Pricing FTSE 100 Options“. In: *SSRN Electronic Journal* (2003).
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning (Information Science and Statistics)*. 1. Aufl. Springer, 2007.
- [6] Fischer Black und Myron Scholes. „The Pricing of Options and Corporate Liabilities“. In: *Journal of Political Economy* 81.3 (Mai 1973), S. 637–654.
- [7] R. Cont. „Empirical properties of asset returns: stylized facts and statistical issues“. In: *Quantitative Finance* 1.2 (Feb. 2001), S. 223–236.
- [8] John C. Cox, Stephen A. Ross und Mark Rubinstein. „Option pricing: A simplified approach“. In: *Journal of Financial Economics* 7.3 (Sep. 1979), S. 229–263.
- [9] Freddy Delbaen und Walter Schachermayer. „A general version of the fundamental theorem of asset pricing“. In: *Mathematische Annalen* 300.1 (Sep. 1994), S. 463–520.
- [10] Emanuel Derman und Iraj Kani. „Riding on a Smile“. In: *Risk* 7 (Jan. 1994).
- [11] Ashish Dhiman und Yibei Hu. *Physics Informed Neural Network for Option Pricing*. 2023.
- [12] Bruno Dupire. *Pricing with a Smile*. 1994.
- [13] Eugene F. Fama und Kenneth R. French. „The Cross-Section of Expected Stock Returns“. In: *The Journal of Finance* 47.2 (Juni 1992), S. 427.
- [14] Federico Gatta u. a. „Meshless methods for American option pricing through Physics-Informed Neural Networks“. In: *Engineering Analysis with Boundary Elements* 151 (Juni 2023), S. 68–82.
- [15] Richard Glende. *Untersuchungen zur Direction-of-Change Prognose im Querschnitt von Aktienuniversen*. Mai 2023.
- [16] Xavier Glorot und Yoshua Bengio. „Understanding the difficulty of training deep feedforward neural networks“. In: *International Conference on Artificial Intelligence and Statistics*. 2010.

- [17] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [18] Donatien Hainaut und Alex Casas. „Option pricing in the Heston model with physics inspired neural networks“. In: *Annals of Finance* 20.3 (Aug. 2024), S. 353–376.
- [19] Michael Hanke. „Adaptive Hybrid Neural Network Option Pricing“. English. In: *Journal of Computational Intelligence in Finance* (1999).
- [20] J. Michael Harrison und David M Kreps. „Martingales and arbitrage in multiperiod securities markets“. In: *Journal of Economic Theory* 20.3 (Juni 1979), S. 381–408.
- [21] Thomas Heimer und Sebastian Arend. *The genesis of the Black-Scholes option pricing formula*. Frankfurt School - Working Paper Series 98. Frankfurt a. M., 2008.
- [22] Sepp Hochreiter. *Untersuchungen zu dynamischen neuronalen Netzen*. Apr. 1991.
- [23] Sepp Hochreiter, A. Steven Younger und Peter R. Conwell. „Learning to Learn Using Gradient Descent“. In: *Artificial Neural Networks — ICANN 2001*. Hrsg. von Georg Dorffner, Horst Bischof und Kurt Hornik. Berlin, Heidelberg: Springer Berlin Heidelberg, 2001, S. 87–94.
- [24] Kurt Hornik. „Approximation capabilities of multilayer feedforward networks“. In: *Neural Networks* 4.2 (1991), S. 251–257.
- [25] John Hull. *Options, futures, and other derivatives*. Eleventh edition, global edition. Harlow, England: Pearson, 2022.
- [26] James M. Hutchinson, Andrew W. Lo und Tomaso Poggio. „A Nonparametric Approach to Pricing and Hedging Derivative Securities Via Learning Networks“. In: *The Journal of Finance* 49.3 (Juli 1994), S. 851–889.
- [27] Jens Carsten Jackwerth. „Recovering Risk Aversion from Option Prices and Realized Returns“. In: *SSRN Electronic Journal* (1996).
- [28] Jens Carsten Jackwerth. „Recovering Risk Aversion from Option Prices and Realized Returns“. In: *Review of Financial Studies* 13.2 (Apr. 2000), S. 433–451.
- [29] Alexander Ke und Andrew Yang. *Option Pricing with Deep Learning*. 2019.
- [30] Diederik P. Kingma und Jimmy Ba. *Adam: A Method for Stochastic Optimization*. 2014.
- [31] Yann A. LeCun u. a. „Efficient BackProp“. In: *Neural Networks: Tricks of the Trade*. Springer Berlin Heidelberg, 2012, S. 9–48.
- [32] Wenda Li. „Application of Machine Learning in Option Pricing: A Review“. In: *Proceedings of the 2022 7th International Conference on Social Sciences and Economic Development (ICSSSED 2022)*. Atlantis Press, 2022.

- [33] Shuaiqiang Liu, Cornelis W. Oosterlee und Sander M. Bohte. „Pricing Options and Computing Implied Volatilities using Neural Networks“. In: *Risks* 7.1 (2019).
- [34] Mary Malliaris und Linda Salchenberger. „A neural network model for estimating option prices“. In: *Applied Intelligence* 3.3 (Sep. 1993), S. 193–206.
- [35] Robert C. Merton. „Option pricing when underlying stock returns are discontinuous“. In: *Journal of Financial Economics* 3.1–2 (Jan. 1976), S. 125–144.
- [36] Miquel Noguer i Alonso und Daniel Maxwell. „Physics-Informed Neural Networks (PINNs) in Finance“. In: *SSRN Electronic Journal* (2023).
- [37] Razvan Pascanu, Tomas Mikolov und Yoshua Bengio. „On the difficulty of training recurrent neural networks“. In: *Proceedings of the 30th International Conference on Machine Learning*. Hrsg. von Sanjoy Dasgupta und David McAllester. Bd. 28. Proceedings of Machine Learning Research 3. Atlanta, Georgia, USA: PMLR, 17–19 Jun 2013, S. 1310–1318.
- [38] Rita Pimentel u. a. „Option pricing with deep learning: a long short-term memory approach“. In: *Decisions in Economics and Finance* (Apr. 2025).
- [39] M. Raissi, P. Perdikaris und G.E. Karniadakis. „Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations“. In: *Journal of Computational Physics* 378 (Feb. 2019), S. 686–707.
- [40] Mark Rubinstein. „Implied Binomial Trees“. In: *The Journal of Finance* 49.3 (1994), S. 771–818.
- [41] Justin Sirignano und Konstantinos Spiliopoulos. „DGM: A deep learning algorithm for solving partial differential equations“. In: *Journal of Computational Physics* 375 (2018), S. 1339–1364.
- [42] Tiberiu Socaciu und Paul Paşcu. „Physics-Informed Neural Networks in Pricing Financial Options“. In: *BRAIN. Broad Research in Artificial Intelligence and Neuroscience* 16.2 (Juni 2025), S. 474.
- [43] Park Sungwon, Moon Kyoung-Sook und Kim Hongjoong. „Asian Option Pricing Using the Physics-Informed Neural Networks Method“. In: *Economic Computation and Economic Cybernetics Studies And Research* 59.1/2025 (März 2025), S. 5–20.
- [44] Laurens Van Mieghem, Antonis Papapantoleon und Jonas Papazoglou-Hennig. *Machine learning for option pricing: an empirical investigation of network architectures*. 2023.
- [45] Xiang Wang, Jessica Li und Jichun Li. „A Deep Learning Based Numerical PDE Method for Option Pricing“. In: *Computational Economics* 62.1 (Juni 2022), S. 149–164.

- [46] Jingtao Yao, Yili Li und Chew Lim Tan. „Option price forecasting using neural networks“. In: *Omega* 28.4 (Aug. 2000), S. 455–466.